État de l’art critique - du langage aux distributions de trajectoires de marché

Recherche principale bornée au 13 octobre 2026 ; compléments sur les sources de données et la disponibilité des poids vérifiés le 14 octobre 2026. Note de recherche, sans entraînement, sans expérience prédictive exécutée. Les performances citées sont celles des auteurs, pas des reproductions indépendantes. Cette revue ciblée ne constitue pas une recherche systématique exhaustive. Les pages évolutives sont décrites telles que consultées ; leur contenu actuel ne prouve pas qu’elles étaient identiques lors de la publication d’un article.

Conclusion scientifique

L’hypothèse « encoder des bougies comme des tokens, puis apprendre à prédire les tokens suivants » est réalisable et possède déjà une antériorité directe : Kronos. La version plus structurée « représenter gap, corps, mèches et volume puis générer une distribution de trajectoires » possède aussi une antériorité très récente : KiT. Le projet reste intéressant : la priorité de recherche est un langage de marché commun à plusieurs actifs et temporalités, dont on peut mesurer ce qu’il conserve, détruit et permet de généraliser. Un modèle fondation multi-marchés, éventuellement couplé à la microstructure et dépassant un milliard de paramètres, reste dans le périmètre si les données et les mesures de scaling le justifient. La disponibilité réelle des informations, la calibration du risque et l’utilité des représentations sont des hypothèses à tester, pas une invention déjà démontrée.

Le choix initial le plus défendable est un comparatif contrôlé de tokenizers et de modèles de taille modeste, suivi d’une montée en charge mesurée. Ces petites expériences servent à qualifier les erreurs, comparer plusieurs régimes d’échelle et estimer une loi de progression avant les dépenses massives ; elles ne fixent pas un plafond d’ambition. Les variantes nombreuses ne doivent pas toutes être optimisées sur le même jeu de test. Aucun résultat publié consulté ne prouve à lui seul la prévisibilité de tous les prix dans tous les régimes.

1. Les antériorités les plus proches

Kronos - Shi et al., 2025. Le papier décrit un autoencodeur de bougies OHLCVA, une quantification binaire sphérique avec sous-tokens grossier/fin, puis un Transformer causal autorégressif. Les auteurs annoncent plus de 12 milliards de bougies, 45 places et plusieurs fréquences. Le gain relatif de 93 % concerne un RankIC de prévision de séries de prix ; ce chiffre ne constitue pas une probabilité de prévoir correctement la prochaine variation. Les métriques de prix, de rendement terminal et de volatilité sont distinctes. L’échantillonnage produit plusieurs continuations possibles. L’annexe décrit le filtrage de segments atypiques : sa pertinence pour des crises de crypto doit être étudiée. Cette lecture couvre l’architecture, les métriques et plusieurs annexes, sans reproduction. Papier, sections 3, 4 et annexes B-D.

Le dépôt distingue aujourd’hui mini : 4,1 M paramètres et contexte 2 048 ; small : 24,7 M et contexte 512 ; base : 102,3 M et contexte 512. Large : 499,2 M figure dans la famille mais est indiqué non publié. Un tutoriel ne doit donc pas promettre le téléchargement de Large. Code et cartes small/tokenizer affichent MIT. Le tokenizer est un artefact distinct du prédicteur. L’accès à ces poids ne donne pas automatiquement les droits ni les fichiers de leur corpus complet. Dépôt officiel, carte small, carte tokenizer.

KiT - Zhang et Li, 28 septembre 2026. Cette prépublication est antérieure à la date de notre étude. Elle génère des trajectoires OHLCV par flow matching, avec représentation continue en log-ratios de gap, corps, mèches et volume, au lieu d’une quantification discrète. Trois tailles annoncées : 31, 101, 284 M. L’évaluation utilise entraînement jusqu’à fin 2023, validation 2024-2025 et test du 1er janvier au 10 avril 2026. Les auteurs annoncent un RankIC moyen de rendement de 0,0571. C’est une revendication récente, à reproduire. Leur

comparaison emploie notamment TimesFM sur clôtures univariées : elle ne prouve donc pas la supériorité contre toutes ses configurations multivariées. Papier, sections 3-4 et annexe A.

Le dépôt KiT consulté contient des dossiers de code, données et checkpoints, et déclare AGPL-3.0. La liste de tâches et les noms de checkpoints ne suffisent pas à établir la disponibilité, la provenance et les conditions de chaque poids. Ne pas remplacer cet audit par « le papier promet une publication ». Les licences des composants effectivement réutilisés devront être examinées séparément. Dépôt officiel et licence déclarée.

FinCast - Zhu et al., 2025. Le dépôt des auteurs décrit un Transformer à décodeur, une spécialisation par mélange d'experts et une perte combinant prédiction ponctuelle et probabiliste, préentraîné sur plus de 20 milliards de points financiers. C'est une autre antériorité à la spécialisation financière et aux quantiles. Nous avons consulté résumé et dépôt, pas validé le protocole complet ni les droits de chaque checkpoint. Résumé, implémentation officielle.

LENS, auparavant PLUTUS dans certaines bibliographies. L'identifiant arXiv 2408.10111 résout actuellement vers *LENS: Large Pre-trained Transformer for Exploring Financial Time Series Regularities*. Employer le titre courant tout en expliquant cette variation évite de compter artificiellement deux preuves indépendantes. La présente note ne reprend aucun chiffre de performance. Notice primaire actuelle.

DELPHYNE - Ding et al., 2025. Les auteurs examinent les limites du transfert de séries générales à la finance et proposent un modèle préentraîné adapté. Le résumé affirme des résultats favorables avec peu d'ajustement. Cela motive notre ablation « généraliste contre financier », mais ne tranche pas celle-ci sur notre futur corpus multi-marchés. Lecture ici limitée à la notice et au résumé. Notice primaire.

MarS et MarketGPT. Ces travaux déplacent la modélisation vers les événements et carnets. La section 7 examine leur tokenisation après consultation supplémentaire des méthodes. Il faut distinguer apprendre à produire un marché plausible, prévoir ce qui va se passer et simuler l'impact de nos propres ordres. Une bonne imitation observationnelle ne garantit pas la validité d'une intervention dans un simulateur. MarS, MarketGPT.

2. Modèles généralistes et choix d'architecture

Référence	Élément vérifié dans les sources primaires	Implication pour notre étude
Chronos, 2024	Normalisation, quantification scalaire, vocabulaire discret, Transformer entraîné par entropie croisée, prévisions échantillonnées.	Antériorité très nette du « langage numérique » ; tester la perte due à la quantification.
Chronos-Bolt, carte officielle	Encodeur-décodeur T5, patches de valeurs et prévision directe de quantiles multi-horizons ; small ≈47,7 M.	Référence rapide ; ne pas l'assimiler au tokenizer de Chronos initial.
Chronos-2, 2025	Encodeur seul, patches continus, attention temporelle et attention entre séries groupées ; cibles, covariables passées et covariables futures connues.	Référence multivariée pertinente ; « attention non causale sur contexte observé » ne signifie pas fuite si aucun futur inconnu n'entre.
Carte Chronos-2	120 M paramètres, poids déclarés Apache-2.0.	Ne pas reprendre des tableaux secondaires qui lui attribuent 205 M ou un encodeur-décodeur.
TimesFM, papier initial	Préentraînement d'un décodeur à patches sur séries réelles et synthétiques.	Un token peut être un vecteur continu de plusieurs observations ; il n'a pas besoin d'être un mot.

Référence	Élément vérifié dans les sources primaires	Implication pour notre étude
TimesFM, dépôt officiel	Version 2.5 : 200 M, contexte jusqu'à 16 k, tête optionnelle de quantiles ; version 3 annoncée en août 2026 avec multivarié et covariables natifs.	Ne pas figer l'état de l'art à la seule 2.5 ; respecter la différence de licence.
TimesFM-3, carte	Attention entre variables, contexte par patches de 32, horizon par patches de 64 ; carte et poids distincts du papier initial.	Départ pour un benchmark de recherche, sans déduction automatique sur l'emploi commercial local.
Moirai initial, 2024	Modèle universel entraîné sur de nombreuses séries, tenant compte de dimensions et fréquences diverses.	Un modèle mutualisé peut traiter plusieurs actifs ; son transfert doit rester mesuré.
Moirai 2.0, 2025	Décodeur seul, patches, quantiles et prédiction de plusieurs tokens ; les auteurs observent des plafonds de gain avec la taille.	Plus grand n'est pas automatiquement meilleur ; choisir selon les ablations et le coût.
Sundial, 2025	TimeFlow Loss par flow matching pour la distribution du patch suivant, sans tokenisation discrète.	Le paradigme prochain élément reste possible en continu ; il faut comparer discret et continu.
Time-MoE, 2024/2025	Modèles temporels à mélange d'experts à grande échelle.	Une option de montée en charge, pas une justification de complexité dans un POC.
TiRex-2, juillet 2026	xLSTM multivarié, covariables et streaming ; coût annoncé constant par patch ; 38,4 M actifs univariés, 44,1 M supplémentaires multivariés.	Alternative à examiner si le coût des fenêtres glissantes domine. Résumé consulté, aucune mesure de latence indépendante.
PatchTST, 2022/2023	Patching et indépendance entre canaux dans le modèle présenté.	Baseline d'architecture légère ; tester ensuite la valeur de l'interaction entre canaux.
TimesNet, 2022/2023	Représentation 2D des variations temporelles pour plusieurs tâches.	Concurrent utile, sans considérer les périodicités comme nécessairement stables en finance.
DLinear, 2022/2023	Des modèles linéaires simples rivalisent avec certains Transformers dans le protocole étudié.	Garder une baseline simple ; ce résultat ne réfute pas tous les Transformers futurs.
TOTEM, 2024	Embeddings temporels tokenisés pour plusieurs tâches.	La reconstruction de données et l'utilité prédictive du codebook sont deux évaluations différentes.

La plupart des lignes ci-dessus sont des lectures de résumés et de cartes. Pour Chronos-2, Moirai 2.0, Kronos et KiT, des sections de méthode ont aussi été examinées. Aucun classement agrégé provenant de ces familles n'est transposé à notre expérience scientifique : données, horizons, métriques, accès aux covariables et budget d'ajustement diffèrent.

TimeGPT et ambiguïté « TimesGPT ». Le papier historique est *TimeGPT-1*. Le dépôt officiel consulté présente désormais *TimeGPT-2.1* et l'accès par un client API. Il ne faut donc pas transformer la disponibilité du SDK en affirmation de disponibilité libre des poids. La recherche ciblée n'a pas établi un modèle canonique distinct nommé « TimesGPT » pertinent pour ce projet. TimeGPT-1, Nixtla officiel.

3. Licences : quatre objets différents

Un article, un programme, des poids et un corpus ne sont pas le même objet juridique. La licence de la page arXiv n'est pas la licence du modèle. L'affichage d'une licence sur la carte reste à enregistrer avec une révision précise au moment du futur téléchargement.

Artefact	Constat vérifié les 13-14 octobre 2026	Conséquence de sélection
Kronos code ; small ; tokenizer-base	MIT dans dépôt et cartes précités	Candidat prioritaire ; provenance du corpus à documenter séparément.
Chronos code ; Chronos-2 ; Bolt-small	Apache-2.0 dans dépôt et cartes précitées	Candidats accessibles pour expérimentation ; auditer les données choisies pour l'ajustement.
TimesFM code et poids ≤2.5	Apache-2.0 selon dépôt officiel	Option de comparaison locale.
TimesFM-3, poids	Licence spéciale limitant les poids téléchargés à des usages non commerciaux et hors production ; utilisation commerciale distincte par services Google autorisés	Vérifier que les usages de recherche envisagés entrent dans le périmètre autorisé. Texte de licence.
Uni2TS code / Moirai-2.0-R-small poids	Code Apache-2.0 ; poids CC-BY-NC-4.0	Ne pas inférer les droits des poids à partir du code. Code, carte poids.
KiT code	AGPL-3.0 déclarée ; droits précis des checkpoints non confirmés ici	Antériorité et piste de recherche, audit complémentaire avant intégration.
TiRex première génération	Dépôt déclarant une licence communautaire NXAI	Ne pas écrire « Apache/MIT » par défaut. Dépôt.
TiRex-2 code et poids	Apache-2.0 dans le dépôt et la carte du checkpoint ; 82,5 M paramètres totaux affichés	Licence différente de la première génération. Les fonctionnalités commerciales PRO ne sont pas automatiquement celles de la version publique. Code, poids.
M3 code et poids	CC-BY-NC-4.0 ; tiny 10 M, small 25 M, base 75 M et tokenizer annoncés publiés, dossiers correspondants présents ; large 366 M et xlarge 1,27 B non publiés	Piste de recherche non commerciale ; permission écrite nécessaire pour l'usage commercial selon la licence. Les fichiers n'ont pas été téléchargés ni exécutés. Licence code, carte poids, arbre des fichiers.
TimeGPT	Client API public, modèle servi à distance dans la documentation consultée	Référence optionnelle ; coût, version fixe et droits d'usage à établir avant tout appel.

Ces constats concernent les artefacts observés. Aucun paquet, poids ou corpus n'a été installé ou redistribué dans cette étude.

4. Ce que la littérature ne permet pas de conclure

Le papier de Tan et al. montre, sur trois méthodes et leurs benchmarks, que retirer le LLM textuel peut conserver ou améliorer les résultats avec un coût moindre. Cela critique un mécanisme particulier : greffer un modèle de langage préentraîné sur texte à des nombres. Ce n'est pas une démonstration d'inutilité des modèles numériques préentraînés, ni une preuve d'impossibilité du projet. Article NeurIPS 2024.

Une étude de mai 2026 sur un instrument de futures et plusieurs années de bougies de cinq minutes rapporte des résultats hors échantillon non significatifs pour LSTM et boosting. Ce résultat négatif est utile contre la présomption « il suffit d'avoir quelques années de données ». Un seul marché, une seule cible et quelques

modèles ne constituent pas une borne universelle sur le volume minimal nécessaire. Lecture limitée au résumé et à la notice. Mesfin, 2026.

Une autre étude 2026 sur Chronos rapporte un gain des entrées multivariées pour actions et taux, mais une dégradation lorsque certains ensembles hétérogènes sont mélangés. Cela suggère une ablation des groupes de covariables. Les métriques rapportées dans le résumé sont RMSE/MAPE ; elles n'établissent pas un profit net. Lecture limitée au résumé. Das et al., 2026.

TIME, prépublication de février 2026, propose des tâches et jeux récents pour traiter notamment contamination, qualité et pertinence opérationnelle. La conclusion utile pour nous est méthodologique : constituer un test privé postérieur aux coupures vérifiables des modèles, avec cibles et horizons correspondant à la question scientifique. Son leaderboard n'est pas un substitut à ce test. Qiao et al., 2026.

5. Synthèse originale : décisions de recherche

Les propositions de cette section sont nos recommandations à tester, pas des résultats expérimentaux ni des revendications de priorité.

Définir l'objet. Une bougie est une observation partielle du marché. De nombreux chemins intrabougie et carnets différents produisent le même OHLCV. Un rendu graphique ajoute une perte liée à la résolution, aux axes et au style. Commencer avec les nombres conserve davantage d'information. Une branche image devient pertinente si l'on teste une information visuelle supplémentaire ou une invariance bénéfique, pas parce que le mot « chartiste » l'impose.

Séparer trois espaces. L'espace observable contient les informations réellement disponibles. L'espace latent les représente. L'espace de sortie contient la distribution des prix futurs. Une reconstruction précise n'établit pas que le latent prédit bien ; une information perdue peut être sans importance pour une cible et indispensable pour une autre.

Préserver la géométrie. Le décodeur doit satisfaire $H \geq \max(O,C)$, $L \leq \min(O,C)$, $V \geq 0$. Une paramétrisation par ouverture, corps signé et amplitudes non négatives peut l'assurer. Pour les mèches et volumes exactement nuls, prévoir explicitement la masse en zéro : une transformation strictement positive ne peut pas tout représenter exactement. L'échelle de normalisation est calculée à partir du passé disponible ; les paramètres globaux sont ajustés sur entraînement uniquement.

Ne pas confondre multi-échelle et information nouvelle. Une heure recomposée à partir de douze bougies de cinq minutes apporte un biais inductif et une compression, pas douze observations indépendantes supplémentaires. À 10 h 35, la bougie complète 10 h-11 h n'existe pas encore. Le modèle doit recevoir la dernière bougie horaire close, ou un état partiel explicitement horodaté et masqué.

Définir « causal ». Il s'agit d'abord de causalité temporelle : aucune entrée inconnue au moment de décision. Cela ne prouve pas une relation causale économique. Une attention bidirectionnelle sur le passé entièrement observé peut être valide. Un masque causal sur un Transformer ne répare pas un scaler calculé avec le futur, un tokenizer ajusté sur le test ou une sélection d'actifs rétrospective.

Choisir le niveau de distribution. Des quantiles par horizon décrivent des marges, pas la distribution jointe du chemin. Deux modèles peuvent avoir les mêmes marges et des probabilités très différentes d'atteindre un stop avant un objectif. Pour des règles dépendantes du parcours, évaluer des trajectoires conjointes et la dépendance intertemporelle. Produire seulement la trajectoire moyenne est insuffisant pour estimer un événement extrême.

Éviter les réglages de génération textuelle mal transposés. Une température et un top-p qui embellissent une continuation peuvent dégrader la calibration financière. Tronquer le vocabulaire peut retirer précisément les événements rares nécessaires à l'estimation du risque. Comparer distributions non tronquées et distributions réglées, avec scoring probabiliste et couverture des queues. Une série réaliste visuellement n'est pas une preuve de probabilité juste.

Trois représentations à comparer à capacité comparable. R1 : tokens scalaires par quantiles ajustés sur entraînement ; R2 : codebook appris sur vecteurs de bougies ; R3 : patches continus avec sortie probabiliste structurée. Ajouter les descriptions humaines de figures comme têtes auxiliaires seulement après une définition reproductible. Éviter d'imposer une grammaire de figures chartistes dont la valeur prédictive n'a pas été mesurée.

Ablations indispensables. Prix seuls contre OHLCV ; covariables de marché ajoutées par groupe ; séquence ordonnée contre perturbation temporelle appropriée ; modèle ajusté contre gelé ; petit contre plus grand à données constantes ; discrétisation contre continu à budget proche ; modèle seul contre ensemble simple ; risque avec abstention contre même risque sans abstention. Chaque test doit expliquer un mécanisme précis ; ne pas lancer toutes les combinaisons sans hypothèse.

Mesures nécessaires. Qualité des données, violations géométriques, erreur de reconstruction par quantile, log-score lorsqu'une densité est disponible, CRPS/WIS pour les marges, scores multivariés ou statistiques ciblées pour les chemins, calibration des événements, stabilité entre périodes et coût de calcul. Les scores de direction, dispersion et trajectoire sont publiés séparément. Un score de token favorable ne garantit pas une meilleure prévision des prix.

Thèse de recherche défendable. « Quelle représentation de marché permet à un même modèle génératif d'apprendre des régularités transférables entre actifs, horizons et régimes, tout en conservant la précision, les contraintes et l'incertitude nécessaires aux tâches futures ? » La prévision des accroissements de prix, de la dispersion et des trajectoires constitue différentes évaluations de cette représentation. Une conclusion négative bien contrôlée sur l'une de ces tâches reste un résultat de R&D.

6. Doutes, points surprenants et journal de vérification

- L'antériorité directe est plus forte qu'attendu : Kronos reprend l'intuition du langage des bougies ; KiT traite déjà plusieurs améliorations structurelles proposées spontanément.
- Une famille moderne n'exige pas des milliards de paramètres : plusieurs références sont de l'ordre de quelques millions à quelques centaines de millions. La taille est une variable expérimentale, pas la définition de la pertinence.
- Des versions d'une même famille changent profondément : Chronos discret, Bolt à patches et Chronos-2 multivarié ne doivent pas être comparés sous une seule étiquette.
- Des poids peuvent être restreints alors que le code est permissif. Moirai 2.0 et TimesFM-3 constituent des exemples concrets vérifiés.
- « LCM » est déjà utilisé pour *Large Concept Models*. Un nom propre accompagné de « modèle fondation des séquences de marché » évite de cantonner le projet à des figures chartistes à un marché particulier ; trois noms de travail sont proposés en section 10. Antériorité du sigle.
- Les dates relatives des moteurs de recherche ne sont pas fiables pour établir une chronologie ; les notices arXiv et annonces datées ont été préférées. KiT (28/09/2026), TiRex-2 (01/07/2026) et TimesFM-3 (08/2026) sont bien antérieurs au 13/10/2026 dans les sources consultées. Les compléments de disponibilité et de données ont été vérifiés le 14/10 ; ils ne constituent pas la preuve d'une disponibilité historique inchangée.
- La version HTML de KiT rend certains signes de tableaux de façon ambiguë ; nous n'en recopions pas les lignes détaillées. Les chiffres retenus proviennent des phrases explicites des auteurs. Ils restent à contrôler au moment d'une reproduction.
- L'historique complet des corpus, leur recouvrement avec nos futurs tests et la disponibilité de tous les checkpoints ne sont pas établis. Un test historique avec coupure de préentraînement inconnue doit être marqué potentiellement contaminé, même si aucun ajustement local n'a utilisé son futur.

Le prochain livrable utile est donc un protocole expérimental préenregistré et un registre des données/checkpoints. Cela donne une voie réaliste vers un POC scientifique ; la prévisibilité et le transfert restent des hypothèses ouvertes.

7. Complément prioritaire : quel langage pour les courbes et les événements ?

Nagy et al., 2023. Un modèle autorégressif de messages du carnet utilisait déjà un tokenizer numérique et des couches de type state space, avec un simulateur Jax-LOB. Le mécanisme de génération événementielle n'exige donc pas, par définition, un Transformer. Notice et résumé consultés. Article primaire.

MarketGPT, détail de conversion. Les messages regroupent horodatage, type, référence d'ordre, côté, taille et prix. Le tokenizer produit 24 tokens par message, avec plusieurs tokens pour prix et temps. Environ 91 millions de messages de 20 actifs deviennent 2,19 milliards de tokens, mais le corpus ne couvre que huit jours. Les auteurs rapportent qu'une variante de type BPE réduisait le temps d'inférence mais dégradait la qualité dans leurs expériences. Ils distinguent explicitement réalisme génératif et prévision du futur. Le vocabulaire annoncé présente une petite incohérence arithmétique dans le texte (12 012 + 98 versus total annoncé 12 111) ; ne pas en reprendre un total comme référence vérifiée. Méthodes et limites.

MarS, détail de conversion. Le modèle d'ordres représente le tuple type/prix/volume/intervalle et ajoute un état du carnet. Les discrétisations annoncées conduisent à 49 152 combinaisons. Un second modèle agrège les ordres en images et apprend des codes VQ-VAE. L'annexe mentionne 16 milliards de tokens d'ordres de 500 actions liquides chinoises sur 2017-2023. Ce sont deux granularités et deux compromis information/calcul, pas une obligation d'utiliser une image de chandelier. Méthode, annexes B-C.

TradeFM, février 2026. Le papier présente un modèle de 524 M paramètres et plus de 9 000 actions. La tokenisation combine catégories, prix relatifs, volumes transformés et temps interévénement ; les indices forment un token composite parmi 16 384 possibilités. Des variables contextuelles restent à côté du token prédit. L'entraînement est indiqué à 10,7 milliards de tokens, avec coupure temporelle et test géographique séparé. Cette antériorité est directement pertinente pour l'ambition multi-actifs. Les données sont propriétaires ; ni les chiffres ni le guide de reproductibilité ne doivent être confondus avec un corpus librement réutilisable. Papier, sections 5-7.

M3, prépublication 2026. Le modèle associe état initial du carnet, tokens d'événements VQ appris et génération autorégressive avec matching déterministe. Encodeur et décodeur du tokenizer sont causaux. Les auteurs soulignent une différence entre ancre mid-price observée à l'entraînement et ancre simulée au déroulement ; ils proposent une ancre d'ouverture fixe pour limiter ce décalage. C'est une antériorité post-Kronos au langage événementiel appris et à son articulation avec un état explicite. La notice affiche 29 juillet 2026 malgré l'identifiant 2608.19227 ; cette discordance de métadonnées doit être conservée dans le registre. Les deux dates restent antérieures à notre borne. Méthode et annexe tokenizer.

Causal Market Simulator, notice du 8 octobre 2026. Un travail tout récent distingue l'impact d'un ordre du prix qui aurait eu lieu sans cet ordre. Il teste un PFN avec un prior synthétique causal puis du transfert. Les auteurs eux-mêmes indiquent que les observations empiriques sont compatibles avec un transfert causal sans le démontrer. Cette piste appartient à une phase avancée de simulation, pas à la preuve immédiate d'un tokenizer de bougies. Seul le résumé a été lu. La conférence mentionnée en novembre 2026 est future à notre borne ; la notice prépublication est déjà datée du 8 octobre. Notice primaire.

Recommandation de conception : une grammaire typée, pas des phrases françaises

Le langage recherché n'a pas besoin de mots humains. Un token est une unité de représentation ; le « sens » utile apparaît lorsque les relations entre ces unités aident plusieurs tâches et généralisent. La première expérience scientifique doit ainsi tester le tokenizer indépendamment du grand modèle. Sinon, les capacités du réseau peuvent masquer un vocabulaire inefficace ou une fuite.

Un alphabet expérimental peut comporter trois familles. Les **tokens de contrôle** décrivent source, modalité, marché, calendrier, intervalle, fin de session, manque de données et révision. Les **tokens d'observation** portent une bougie, un événement ou un petit patch. Les **tokens de contexte** portent état de liquidité, échelle passée et information effectivement connue. Ils ne sont pas tous des cibles à prédire. Leur disponibilité est définie avant l'entraînement.

Le mapping « livre = actif, chapitre = période, phrase = motif » aide l'intuition mais peut induire une mauvaise segmentation. Un actif change de régime ; plusieurs actifs partagent des événements ; un même choc traverse plusieurs places. Il faut plutôt tester « corpus = collection d'histoires synchronisées ; séquence = fenêtre d'observations ; unité = événement ou patch ; contexte = conditions de marché ». Les figures chartistes nommées sont des annotations facultatives de motifs appris, et non l'alphabet obligatoire.

Les cinq niveaux ci-dessous constituent des variantes à départager, pas cinq briques à empiler immédiatement :

1. **Quantification par champs.** Un prix relatif, un corps, une mèche et un volume deviennent des identifiants de bins. Lisible et diagnostiquable, mais augmente la longueur et rend les dépendances entre champs coûteuses.
2. **Token composé.** Les catégories des champs sont combinées en un identifiant unique. Court, mais le vocabulaire croît comme le produit des résolutions : dix dimensions à 32 niveaux donneraient 32^10 états, avant même la temporalité. La parcimonie du corpus rend une table directe inadaptée.
3. **Token appris conjoint.** Un encodeur causal compresse le vecteur d'observation vers un code VQ/BSQ ou des codes factorisés. Plus compact, mais il faut vérifier saturation, utilisation du codebook et stabilité entre marchés. Un vocabulaire qui s'effondre vers quelques codes peut donner une bonne perte moyenne tout en détruisant les événements rares.
4. **Token hiérarchique plus résidu.** Une partie grossière, une partie fine puis un résidu continu conservent une résolution adaptée. L'intérêt attendu est le partage de structure sans sacrifier la précision près des seuils. L'ordre des sous-tokens devient une décision architecturale et doit être ablaté.
5. **Patch continu et sortie continue.** Le réseau travaille sur des embeddings sans dictionnaire discret. C'est une hypothèse concurrente obligatoire : le bénéfice pourrait provenir du préentraînement séquentiel, non de la discrétisation.

Le critère de réussite du tokenizer n'est pas seulement l'erreur quadratique de reconstruction. Il faut une courbe débit-distorsion : nombre de bits ou tokens par observation contre erreur en points de base, déformation des queues, violations géométriques, précision des volumes, perte sur indicateurs calculés et modification de l'ordre des événements. Une compression qui change fréquemment lequel de deux seuils est touché en premier est inacceptable pour cette tâche, même si la courbe reconstruite semble identique à l'œil.

La **fidélité sémantique** doit être définie par des propriétés calculables : signe du rendement, franchissement de barrière, distance au spread, ordre et durée des événements, cumul de volume, cohérence des agrégations. Ces propriétés ne sont pas toutes connaissables à partir d'OHLCV ; lorsqu'elles exigent la microstructure, le tokenizer ne doit pas inventer l'information absente.

Corpus : beaucoup de courbes, mais surtout des informations différentes

L'intuition de réunir de nombreux actifs et horizons est justifiée comme stratégie d'apprentissage partagé. L'expérience doit toutefois dissocier le nombre d'enregistrements du nombre d'expériences indépendantes. Vingt actifs corrélés pendant une même crise ajoutent des observations transversales utiles ; ils n'ajoutent pas vingt crises. Douze versions temporelles du même historique ne créent pas douze fois autant de nouveauté. Le cas MarketGPT ci-dessus illustre pourquoi « milliards de tokens » et « diversité historique » sont des notions différentes.

Construire un manifeste de couverture : classes d'actifs, places, horizons, années, crises, liquidité, règles de cotation, géographies, instruments disparus et interruptions. Mesurer concentrations et dépendances par

blocs. Prévoir des tests qui retirent successivement une période entière, un groupe d'actifs, une place puis une classe d'actifs. Un modèle qui prédit un actif nouveau pendant une période déjà mémorisée ne prouve pas le même transfert qu'un modèle confronté à une période et à un marché inconnus.

Ne pas rendre toutes les séries artificiellement identiques. La normalisation enlève les unités arbitraires, mais l'échelle de volatilité, le tick relatif, le spread, le calendrier, le caractère spot ou dérivé et la maturité peuvent porter une information prédictive. Conserver des canaux de contexte causaux pour ces éléments, ainsi que des masques de disponibilité. Le modèle peut apprendre une structure commune avec des adaptations par famille plutôt qu'un universalisme forcé.

Architecture ambitieuse et rôle exact du calcul

Une direction de R&D cohérente est un système à plusieurs résolutions : encodeur local d'événements ou bougies ; compression causale en tokens ; mémoire lente de sessions/régimes ; attention entre actifs contemporains déjà observés ; décodeurs adaptés aux bougies, à la microstructure et au risque. Les échanges entre échelles doivent respecter l'horloge de connaissance. Un moteur déterministe peut imposer les règles du carnet lorsque l'on simule des événements. Ce schéma est une proposition composite, dont les composants ont des antériorités ; sa valeur dépend d'ablations qui isolent les gains.

Le préentraînement pourrait combiner prochain token, reconstruction masquée dans des fenêtres entièrement passées, cohérence entre agrégations et prédiction de distributions à plusieurs horizons. La perte globale doit éviter qu'une tâche facile et abondante, comme reconstruire un niveau de prix, domine une tâche rare mais importante. Les coefficients sont choisis sur validation et leur sensibilité publiée. Les données manquantes ne deviennent pas de faux zéros ; les actifs sans carnet complet peuvent contribuer à la branche bougies avec un masque de modalité.

Un passage 10 M → 100 M → 1 B+ paramètres est une expérience possible. Il doit varier aussi le volume et la diversité des données : agrandir seulement le réseau ne teste pas correctement le scaling. La littérature étudie déjà les pertes en fonction de taille, données et calcul, avec effet de l'architecture. Elle ne fournit pas une loi universelle transformant FLOPs en profit. Yao et al., notice et résumé.

Le calcul peut réduire les erreurs d'approximation et d'optimisation, permettre plus de contextes et estimer mieux certaines distributions. Il ne restaure pas une annonce future absente des entrées, ne crée pas une histoire de crise supplémentaire et ne supprime pas l'aléa conditionnel. La frontière à étudier relie information disponible, biais de représentation, capacité, diversité et calcul. Une faible performance locale ne suffit pas à en déduire un plafond universel.

8. Corpus réel : voies d'acquisition multi-marchés

Le projet peut partir de données réellement observées et ne dépend pas de la génération de courbes artificielles. Les sources ci-dessous sont identifiées sur leur documentation primaire ; aucun abonnement ni achat n'a été effectué. Ce catalogue décrit des voies d'accès ; le document 07 distingue désormais les petites collectes réellement acquises et auditées. Un futur manifeste distinguera clairement « disponible chez le fournisseur », « droit acquis », « reçu », « contrôlé » et « admis dans l'entraînement ».

Source réelle	Contenu et intérêt scientifique	Limites établies et action de sélection
Binance Public Data / Vision	Archives quotidiennes et mensuelles de bougies, trades et trades agrégés, spot et futures ; l'annonce Binance situe les historiques publics à partir de 2017. La date de début dépend toutefois du symbole et du produit : ne pas attribuer 2017 à tous les contrats. Annonce primaire, dépôt officiel.	Checksums et corrections d'archives documentés ; changement d'unité des timestamps spot à partir de janvier 2025. Surtout, la licence MIT du code n'est pas celle des données : voir le paragraphe dédié ci-dessous.

Source réelle	Contenu et intérêt scientifique	Limites établies et action de sélection
Kraken, archives de trades	Page officielle consultée le 14/10 : tous les trades publics par paire, depuis le premier trade de la paire jusqu'au 30/09/2026, archives et incréments trimestriels. Prix, volumes et timestamps permettent de reconstruire plusieurs granularités depuis une même source élémentaire. Archives officielles.	L'API OHLC est une autre voie, limitée aux 720 derniers enregistrements ; sa dernière bougie est en cours. Les archives résolvent la profondeur historique, sans donner le carnet ni garantir les droits de redistribution des données ou poids. Limite API primaire.
Coinbase Exchange	API primaire de bougies par produit, utile comme autre place, comme contrôle croisé et pour construire un corpus progressif. Documentation des bougies.	Maximum 300 bougies par requête ; granularités déterminées ; historique possiblement incomplet et absence de bougie quand il n'y a pas de tick. Une absence n'est donc pas automatiquement une panne. Distinguer accès public, droit de stockage massif et droits d'entraînement ou de distribution, non établis par cette seule page.
Tardis.dev	Flux crypto historiques capturés : trades, mises à jour du carnet, quotes et autres canaux selon la place. Pour Binance spot, certaines grandes paires depuis le 30/03/2019, toutes les paires depuis le 05/03/2021 selon la fiche ; couverture à examiner par canal. Couverture primaire Binance, API historique.	Les horodatages locaux ajoutés aident l'audit de disponibilité. Des snapshots de carnet sont obtenus par REST et marqués comme générés : ils ne sont pas des événements WebSocket natifs. Samples du premier jour du mois accessibles sans clé ; corpus complet et droits commerciaux à vérifier contractuellement avant engagement.
Databento, actions et dérivés cotés	Catalogue documenté incluant actions, futures, options et FX ; places comme Nasdaq, CME Globex et OPRA. Schémas selon produit : OHLCV, trades, prix/tailles par niveau ou ordres individuels. Des extraits réels sont proposés dans le catalogue pour contrôler la qualité. Catalogue primaire, schémas.	La profondeur, les schémas et l'origine de capture varient par dataset ; on ne généralise pas « tous les ordres, toutes les années » à l'offre entière. La fiche comporte une section de licence et une estimation du coût. L'historique et le live ont des conditions distinctes ; collecter leurs droits avant d'entraîner un produit. Démarrage officiel.

Droits du corpus témoin. Les conditions Binance Vision consultées le 14 octobre 2026 prévoient la recherche personnelle hors production et encadrent séparément les autres usages. Les données dérivées conservent attribution et conditions applicables ; l'utilisation ici est descriptive et scientifique. Conditions primaires.

Pourquoi les données réelles ne suffisent pas à elles seules. Un trade réel peut être dupliqué entre fournisseurs. Un historique d'actifs survivants peut être exact ligne par ligne et néanmoins biaisé. Une correction de transaction reçue le lendemain ne devait pas être connue la veille. Un contrat futures continu obtenu par raccordement peut créer des mouvements qui n'ont jamais été négociables. Le pipeline envisagé doit conserver source, instrument réel, échéance, timestamp d'événement, timestamp de réception lorsqu'il existe, version et règles de correction. Les chandeliers à plusieurs horizons sont des vues dérivées de cette base, et leur parenté reste enregistrée.

Priorité de collecte proposée. D'abord réunir des années et des marchés diversifiés dans une branche bougies/trades, avec instruments disparus lorsque la source le permet ; parallèlement sélectionner quelques sous-corpus riches en microstructure pour tester le langage événementiel. Ensuite étendre actions, indices via instruments cotés, taux, énergie et matières premières par contrats réels. L'extension doit inclure calendriers, maturités, devises et unités, sans prétendre qu'une normalisation efface ces différences. Une table par source consigne couverture par actif/date/champ, part manquante, profondeur du carnet, corrections, droit d'entraînement, droit d'exploitation des poids et droit de redistribution. Les sources synthétiques éventuelles restent séparées et ne remplacent ni le corpus réel, ni son test final.

Le nombre de sources ne doit pas servir de métrique d'avancement : trois fournisseurs des mêmes BTC/USDT sur la même période donnent surtout un contrôle de qualité, alors qu'un historique de crise supplémentaire ou une famille d'actifs peu représentée apporte une diversité différente. L'objectif est la couverture mesurable des mécanismes et régimes de marché.

9. Vérifications récentes : chronologie, fichiers publiés et limites de preuve

Référence	Statut documentaire et artefact au moment de cette étude	Limite à conserver dans le dossier
KiT, 28/09/2026	Prépublication et dépôt primaire accessibles ; dossiers de checkpoints visibles, code AGPL-3.0.	Nous n'avons pas établi une liste complète de fichiers de poids effectivement récupérables avec leurs licences propres. La présence d'un dossier n'est pas une validation d'exécution.
M3, identifiant 2608.19227	Carte et arborescence Hugging Face vues le 14/10 : tiny/small/base et tokenizer présents, modèles 366 M/1,27 B déclarés non publiés ; CC-BY-NC-4.0.	Notice affichant 29/07/2026 alors que l'identifiant correspond à août : discordance conservée, pas corrigée arbitrairement. Aucun poids exécuté.
TiRex-2, 01/07/2026	Dépôt et carte de poids Apache-2.0 ; 82,5 M paramètres totaux ; versions excluant certains jeux de benchmarks documentées.	Décontamination d'un benchmark généraliste ne prouve pas absence de contamination de notre propre corpus financier. Les droits et fonctions de TiRex-1, TiRex-2 et PRO diffèrent.
TimesFM-3, annonce août 2026	Dépôt/carte et licence spéciale de poids accessibles.	Disponibilité publique n'implique pas usage commercial ou production autorisé ; séparer les services hébergés et les poids téléchargés.
Causal Market Simulator, 08/10/2026	Notice prépublication accessible ; seule la notice et le résumé ont été lus.	Une conférence indiquée en novembre est encore future ; ne pas la présenter comme un événement déjà tenu ni attribuer une validation indépendante au papier.
Archives Kraken, page consultée le 14/10	Le corps de page affiche une mise à jour du 12/10 et la couverture jusqu'au 30/09/2026.	Un résultat indexé antérieur indiquait juin : le corps récent est retenu. Il faut dater la capture et vérifier le manifeste du futur téléchargement plutôt que déduire la couverture du seul résumé moteur.

Les résultats empiriques de 2026 cités sont des revendications des auteurs et, pour certains, des prépublications récentes. Nous n'avons trouvé aucune preuve permettant de convertir leur disponibilité en garantie de prévision généralisable sur nos données. Les liens primaires sont fournis à proximité des affirmations dans cette note ; aucune citation secondaire n'a été utilisée pour établir une licence de poids.

Nom retenu pour ce dossier

TRAME est le nom de travail retenu par la synthèse, pour un modèle génératif des structures de marché. Les alternatives Séquora, Traméa, Orvéa, Palimpseste et Morphose restent des propositions éditoriales. Aucune disponibilité juridique ou de domaine n'est revendiquée.

10 Mise à jour du 14 octobre : marché latent, GPT et échelle

Le cadrage actif porte sur la prévision scientifique multi-marchés. L'ancienne annexe d'exploitation est conservée uniquement dans la version 1 archivée. Le papier 01 et le document 08 distinguent partage de grammaire, information croisée et état commun partiel. Aucun modèle prédictif n'a été entraîné pour cette mise à jour.

TimesFM-3, annoncé le 31 août 2026, constitue une antériorité importante pour l'attention entre séries dans un Transformer temporel. Les mécanismes et les limites des sorties marginales sont analysés au document 08. L'annonce est une source primaire des auteurs, pas une reproduction indépendante. Annonce technique.

Les travaux d'Edwards et de Yao motivent une mesure des effets d'échelle. Leurs résultats ne constituent pas une loi universelle des prix financiers ; les détails et restrictions sont discutés dans le document 05. Edwards et al., Yao et al..

La notion de facteur partagé possède une longue histoire économétrique. Stock et Watson proposent de résumer un grand nombre de prédicteurs par des composantes avant de prévoir une série. Cette référence empêche de présenter le seul « Marché commun » comme une idée nouvelle. Notre programme ajoute des questions sur les langues, les masques et le transfert. Article des auteurs.

Le catalogue NYSE Daily TAQ annonce une histoire remontant à 1993, ce qui ouvre une voie de recherche pour les épisodes de 2000 et de 2008, sous conditions d'accès à établir. Il n'atteste pas une qualité uniforme de chaque variable à la seconde sur toute cette période. Les données BCE constituent une voie distincte pour les références quotidiennes de devises. NYSE, BCE : séries de référence.

Les nouveaux manifestes locaux documentent les observations effectivement reçues. Les sources synthétiques mentionnées dans certains modèles de la littérature n'ont pas été substituées aux observations réelles des mesures TRAME. Les petits exemples artificiels des tests de calcul sont identifiés comme tels.