TRAME

Langage génératif et prix bruts

Édition 2.4 - 16 octobre 2026. Nouveau chapitre 13 : sortie GPT, limites de distribution et audit de cibles réelles. Les documents 00-12 sont conservés ; 13 précise et amende P1-B0 en révision 0.2.

Lecture rapide : synthèse 00, puis section 1 du chapitre 13. Plan général : 11. Aucun modèle construit ou entraîné ; les nouveaux résultats concernent la reconstruction historique et des calculs de conception.

00 Synthèse accessible - page 2 ; 3 pages

01 Papier de recherche - page 5 ; 5 pages

02 Atlas des langages - page 10 ; 9 pages

03 Faisabilité technique - page 19 ; 3 pages

04 Tutoriel du POC au système - page 22 ; 3 pages

05 Validation et panel critique - page 25 ; 15 pages

06 État de l'art et sources - page 40 ; 12 pages

07 Premières mesures réelles - page 52 ; 5 pages

08 Marché latent et GPT - page 57 ; 7 pages

09 Corpus, langage typé et protocole - page 64 ; 9 pages

10 Du langage à l'expérience contrôlée - page 73 ; 12 pages

11 Plan de recherche et personas - page 85 ; 4 pages

12 Témoins numériques et génération causale - page 89 ; 7 pages

13 Tête générative et audit des cibles - page 96 ; 7 pages

Statut des preuves

304 920 présentations de cibles issues de 15 360 cotations distinctes. Audit limité à la partition BCE 1999-2009 déjà exploratoire ; aucune performance prédictive. Les bornes de queues et les fonctions numériques restent des sujets de qualification.

Personas simulés, sans validation indépendante. Anciennes éditions et rapports conservés ; protocole prédictif amendable.

TRAME : apprendre les structures du Marché

La recherche en trois pages

Édition scientifique 2.2, 15 octobre 2026. Les versions précédentes sont archivées ; les conclusions restent révisables. Aucun modèle prédictif n'a été construit ou entraîné.

Votre demande est de construire une théorie puis un programme expérimental pour apprendre les courbes comme un modèle GPT apprend des séquences. Il faut trouver le langage numérique, les données et l'architecture permettant d'anticiper la suite des prix. L'objet est scientifique : quelles structures existent, lesquelles sont apprenables et comment les mesurer sur des observations nouvelles ?

TRAME reste un nom de travail. Il évoque les relations entre actifs, époques et échelles de temps. Le projet doit pouvoir porter sur l'or, les indices, les actions, les devises et d'autres marchés suffisamment documentés. Les choix du premier petit échantillon ne fixent pas sa destination.

Deux intuitions deviennent deux expériences

Première possibilité : chaque actif parle sa langue. Un modèle commun apprend plusieurs langues, mais utilise surtout le passé de l'actif qu'il doit prévoir. Cette mise en commun peut aider un instrument peu documenté grâce aux motifs appris ailleurs.

Deuxième possibilité : les actifs sont des observations différentes d'un état de marché partagé. Ils ne racontent pas exactement la même chose : certains réagissent à la monnaie, d'autres à la croissance, à une entreprise ou à une offre physique. Le modèle chercherait ce qu'ils partagent tout en conservant leurs particularités.

Nous comparerons donc un modèle par actif, un modèle partagé sans information croisée, puis un modèle qui observe plusieurs actifs simultanément. Cette distinction est essentielle : bénéficier de beaucoup de courbes pendant l'entraînement ne prouve pas que leurs mouvements simultanés aident à prédire.

À quoi ressemble le langage ?

Une bougie peut devenir un objet structuré : ouverture relative au dernier prix, corps signé, mèches, activité, durée et disponibilité. Une simple référence quotidienne ne contient pas tous ces éléments : nous ne les inventons pas. Les nombres peuvent être continus, découpés en paliers ou écrits avec un vocabulaire ; les unités accompagnent le contenu.

Une image, des pourcentages et une suite de signes mettent en valeur des propriétés différentes. **Changer l'écriture peut faciliter l'apprentissage sans ajouter d'information ; réduire une amplitude à son signe en efface.** Le protocole sépare ces effets. Une représentation détaillée peut préserver un signal qu'une écriture simple perd ; cette dernière peut aussi mieux généraliser avec peu de données.

Pourquoi privilégier un GPT et beaucoup de données ?

Un Transformer peut apprendre des dépendances entre des événements éloignés et entre plusieurs séries. Nous le retenons comme architecture principale à étudier. L'idée proposée est un GPT hiérarchique : détails récents à la seconde si disponibles, passé plus ancien regroupé en minutes, heures et journées, puis échanges d'information entre actifs. Les fenêtres ne contiennent que ce qui était observable à leur date.

Il ne faut pas confondre le principe GPT avec l'obligation de transformer chaque nombre en mot ou de générer un symbole à la fois. Des sorties continues et des prévisions par blocs restent possibles. Des architectures récurrentes et des modèles simples serviront de comparaisons, sans devenir le centre du projet.

Votre objection au petit POC est retenue : une mauvaise prévision avec un petit réseau ne condamne pas son langage. Il faut varier séparément taille du réseau, quantité de données, diversité des actifs, longueur du passé et précision de l'encodage. Nous chercherons des courbes de progression, pas un verdict après un seul essai.

La littérature observe déjà des effets d'échelle sur des séries temporelles, mais pas une garantie universelle sur les prix financiers. Plus de calcul peut aider à exploiter une information difficile ; il ne suffit pas à recréer une amplitude effacée par un encodage, ni une nouvelle extérieure jamais observée. Les documents 01, 05 et 08 développent cette distinction.

Plusieurs histoires et plusieurs vitesses

Les épisodes de 2000, de 2008 et de la pandémie sont des contextes utiles. Nous voulons aussi des périodes ordinaires : un modèle entraîné presque uniquement sur les crises apprendrait une fréquence de crise artificielle. Les événements servent à vérifier la robustesse ; leurs noms attribués après coup ne deviennent pas des informations disponibles avant qu'ils surviennent.

Une longue histoire quotidienne et une histoire plus récente à la seconde sont complémentaires. Transformer artificiellement une observation quotidienne en milliers de secondes n'ajoute rien. À une seconde, les pauses de cotation, les observations inchangées et les différences de calendrier doivent être représentées explicitement.

Ce que les données ont déjà changé

Trois sources réelles ont été auditées : 58 240 bougies horaires complètes pour une étude de reconstruction, 33 792 références quotidiennes de six devises, et six histoires mensuelles de matières premières avec 732 valeurs chacune de 1960 à 2020, dont l'or. Aucun score de prévision n'a encore été calculé.

L'audit récent a révélé que le traitement prévu pour les valeurs hors dictionnaire n'aurait reçu aucun exemple à l'ajustement, tout en étant sollicité dans 40 contextes du franc suisse au développement. Nous proposons donc une **base numérique utilisée partout, complétée par des corrections symboliques**. Ce langage est explicitement hybride ; la correction ne démontre pas encore une meilleure prévision.

Le cas extrême venait d'un ancien cours exprimé dans l'unité d'une période récente très calme. Il motive l'étude de plusieurs échelles, sans constituer une découverte de signal. Autre distinction : plus de huit millions de valeurs présentées dans les fenêtres répétaient seulement 33 672 prix distincts. Les répétitions ne créent pas l'histoire manquante.

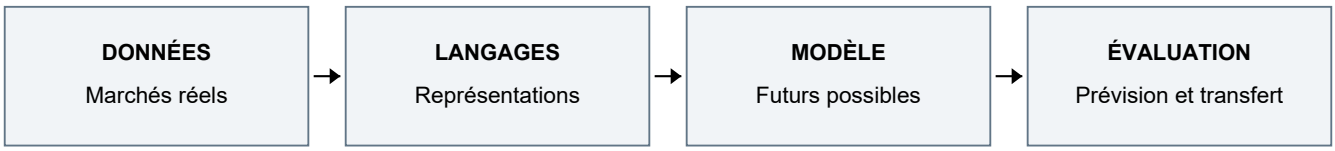
Ce qui reste à prouver

P1-A comparera les écritures du passé avec une sortie commune de quantiles du prix. P1-B étudiera ensuite la génération des prochains symboles. Un masque causal ne suffit pas : la normalisation et les états de génération doivent aussi respecter l'information disponible. Budgets, réglages, diagnostics de convergence et évaluation indépendante restent à arrêter.

Pour la mise à jour technique, lire **10, Du langage à l'expérience contrôlée**, qui amende les propositions antérieures lorsqu'elles diffèrent. Lire ensuite 08 pour le Marché latent et le GPT, 02 pour les langages, 09 pour les observations et le corpus. Le papier 01, la faisabilité 03, le tutoriel 04, la validation 05 et l'état de l'art 06 complètent le dossier.

Le panel est simulé ; il ne remplace pas une validation indépendante. La prochaine preuve recherchée reste une amélioration reproductible sur de nouveaux prix, attribuable à un dispositif précis. Un résultat négatif sera conservé avec sa portée exacte ; il ne condamnera pas automatiquement tout un langage.

TRAME : langage, état de marché et prévision des trajectoires



Chaque étape a son propre critère de réussite.

Proposition scientifique révisée

Version 2 du 14 octobre 2026. Programme de recherche, résultats descriptifs limités au document 07, aucune expérience prédictive exécutée. Cette version remplace le cadrage applicatif de la première étude.

Résumé

Nous étudions l'apprentissage auto-supervisé des trajectoires de prix au moyen de modèles de séquences de type GPT. L'hypothèse centrale n'est pas qu'une figure chartiste possède un nom, mais qu'une représentation adéquate d'observations multi-actifs et multi-échelles permet d'apprendre des régularités transférables. Deux mécanismes sont distingués : mutualiser l'apprentissage de langues propres aux actifs ; inférer un état latent partagé dont chaque actif constitue une observation partielle. Ils exigent des expériences différentes.

La contribution proposée est un programme reliant précision de représentation, prévision probabiliste, information inter-actifs et passage à l'échelle. Le langage peut être discret, continu ou hybride. L'architecture principale proposée est un Transformer hiérarchique à attention temporelle et inter-actifs, avec masques de disponibilité et sorties géométriquement cohérentes. La priorité au GPT est une hypothèse de travail, pas un résultat comparatif.

Le programme vise les prix observés et leurs trajectoires futures sur plusieurs familles de marchés. Les critères sont l'exactitude, la calibration, la dépendance temporelle, le transfert et la robustesse. Aucun résultat présenté ici n'établit l'existence d'une régularité prédictive nouvelle. Une expérience de reconstruction vérifie seulement certaines propriétés des langages proposés.

1 Ce qui est transposé du langage

L'analogie comporte quatre objets : un corpus d'observations, des unités de représentation, un objectif de prédiction et des compétences transférables. Elle n'exige ni mots français, ni modèle préentraîné sur Internet. Une bougie est un paquet de mesures ; un segment est un groupe d'observations ; une séquence est un contexte historique. Une série entière ne correspond donc pas naturellement à un unique token ni nécessairement à une unique langue.

Le préentraînement génératif de GPT était déjà conçu pour transférer des représentations vers d'autres tâches. L'émergence ultérieure de capacités complexes motive l'étude d'autres domaines, mais n'implique aucun théorème d'émergence universelle. GPT, travail initial.

Le texte et les prix sont produits par des processus différents. Les prix reflètent des interactions, des règles institutionnelles et des informations extérieures incomplètement observées. Une distribution prévisible peut porter sur la dispersion ou les dépendances sans rendre la prochaine variation déterministe. Nous devons

mesurer les composantes prévisibles séparément, au lieu de demander au score global de répondre à toutes les questions.

2 Objet mathématique et information disponible

Pour l'actif a, X[a,t] regroupe les observations portant sur un intervalle terminé à t. Chaque observation possède aussi une date de disponibilité d[a,t]. La filtration F_t contient seulement les observations dont d[a,s] <= t, ainsi que les métadonnées connues à t. Nous visons une loi jointe :

```
p_theta({P[a,t+h]} pour a dans A et h dans H | F_t)
```

P est un prix observé précisément défini : dernière transaction, cours de référence, indice calculé ou autre mesure documentée. Ces objets ne sont pas interchangeables. H contient des horizons physiques, par exemple 1, 10 et 60 secondes sur une branche fine, puis 5 minutes, 1 heure et 1 jour sur d'autres expériences. Ces valeurs sont des propositions, pas les horizons d'un test déjà effectué.

Pour un prix strictement positif, on peut prévoir les accroissements `r[a,t,h]=ln(P[a,t+h]/P[a,t])`, puis reconstruire les prix par l'ancre P[a,t]. Cela conserve l'objectif prix brut tout en contrôlant les différences d'échelle. Si un instrument peut prendre une valeur nulle ou négative, une transformation adaptée telle qu'asinh et son échelle passée doivent être définies ; appliquer log de force serait une erreur de domaine.

Les scores seront publiés à la fois dans les unités natives de chaque actif et dans une unité normalisée définie avant le test. Une moyenne d'erreurs en dollars entre des actifs de prix très différents n'est pas un score universel. Une moyenne normalisée seule peut, inversement, masquer une erreur absolue importante. Les deux lectures sont nécessaires.

3 Deux hypothèses sur les langues

H1 : une grammaire partagée, des histoires séparées

On apprend un paramètre commun theta sur de nombreuses séries, mais la prévision de l'actif a utilise uniquement son histoire et ses métadonnées. Des adaptateurs peuvent capturer ses particularités. Ce modèle teste un transfert de paramètres : les courbes d'autres actifs servent de données d'apprentissage, sans apporter nécessairement une observation contemporaine supplémentaire.

Une amélioration de H1 face à des modèles individuels soutiendrait l'existence de régularités réutilisables. Elle ne démontrerait ni un état global du Marché ni des causalités entre actifs. Il faut contrôler le nombre total d'observations, le budget d'optimisation et la taille des réseaux pour attribuer correctement le gain.

H2 : plusieurs observations d'un état commun

Considérons un état global S_t et un état spécifique U[a,t]. Une écriture conceptuelle est :

```
S[t+1] ~ p(S[t+1] | S[<=t], E[<=t])
```

```
U[a,t+1] ~ p(U[a,t+1] | U[a,<=t], S[<=t], M[a])
```

```
X[a,t] ~ p(X[a,t] | S[t], U[a,t], M[a], masque[a,t])
```

E représente un contexte extérieur disponible ; M les propriétés de l'instrument. Ce modèle n'affirme pas que toutes les courbes sont des traductions exactes. Une information spécifique, un bruit d'observation et un calendrier propre restent nécessaires. L'état commun peut avoir plusieurs facteurs et plusieurs vitesses.

Les modèles à facteurs constituent une antériorité importante : résumer de nombreux prédicteurs par des facteurs puis prévoir une série a été étudié bien avant les Transformers. Notre piste étendrait ce principe par des observations hétérogènes et une dynamique non linéaire, sans revendiquer l'invention de l'idée de facteur commun. Stock et Watson, 2002.

H2 sera comparée à H1 avec une information croisée autorisée puis supprimée, décalée ou permutée selon des contrôles explicités. Si l'alignement des autres actifs n'apporte rien, la version testée de H2 perd du soutien. Un résultat positif exige de vérifier les décalages de publication et les dépendances triviales entre instruments.

4 Ce que puissance et langage peuvent changer

Soit X le passé observé, Z=f(X) son encodage et Y une cible future. À distribution fixe, avec une densité et des entropies finies, la perte logarithmique idéale d'un prédicteur q s'écrit :

`E[-log q(Y|Z)] = H(Y|X) + I(Y;X|Z) + E_Z KL(p(Y|Z) || q(Y|Z)).`

Cette identité suppose Z déterministe de X, ou une randomisation indépendante de Y conditionnellement à X. Elle distingue l'incertitude restante même avec X, l'information prédictive perdue par l'encodage, et l'écart du prédicteur à la meilleure loi conditionnelle basée sur Z. Pour des variables continues, il s'agit de densités relatives à une mesure commune ; des losses de tokens de vocabulaires différents ne sont pas automatiquement comparables.

Augmenter les paramètres, les données et le calcul peut réduire le dernier terme. Ajouter de vraies observations complémentaires peut réduire le premier. Remplacer une quantification destructrice par une représentation plus précise peut réduire le deuxième. À l'inverse, conserver toute l'information n'assure pas qu'un petit réseau saura l'exploiter efficacement.

Le résultat fondamental pour ce projet est donc double : **un échec à petite échelle ne réfute pas un langage ; une promesse de calcul illimité ne prouve pas qu'une information existe dans ce langage.** Aucun des termes idéaux n'est connu exactement sur les marchés réels. Nous étudierons leurs manifestations par ablations et courbes de progression, sans annoncer avoir mesuré l'incertitude irréductible du Marché.

5 Construction du langage

Pour une bougie positive, un encodage de base comprend g=ln(O/C_précédent), b=ln(C/O), u=ln(H/max(O,C)), d=ln(min(O,C)/L). Les mèches u et d sont non négatives et peuvent être exactement nulles. Le volume, s'il existe avec une définition fiable, devient v=ln(1+V/V_ref). La référence V_ref et une éventuelle échelle de volatilité sont calculées sur le passé strict.

La reconstruction conserve une géométrie valide par construction. Les marqueurs de zéro, d'absence de donnée, d'absence de transaction et de fermeture du marché restent différents. Une série de cours de référence sans volume ne reçoit pas un volume inventé. Les temps de début, de fin, de disponibilité et le type de mesure sont partie intégrante du langage.

Trois familles principales sont étudiées : vecteurs continus ; vocabulaire appris ou quantifié ; symboles discrets accompagnés d'un résidu continu. Les mots peuvent porter sur un champ, une bougie, un patch ou un événement. Les représentations par signes, ordre, rythme, spectre, graphe ou figures sont des branches d'ablation, avec leur information perdue explicitée dans l'atlas 02.

Une hypothèse nouvelle à éprouver est le **vocabulaire progressif** : un symbole décrit la forme grossière ; des symboles supplémentaires décrivent l'amplitude et un résidu rare. Le nombre de symboles devient variable, mais doit être borné et son coût mesuré. Les détails d'une bougie close peuvent être encodés ensemble ; aucun token disponible avant sa clôture ne doit dépendre de son extrême final.

6 Architecture proposée et ordre de génération

La branche principale est un Transformer de type GPT, initialisé pour le domaine temporel. Un encodeur local produit des tokens par actif et par patch déjà achevé. Une attention temporelle accède au passé autorisé. Une attention entre actifs fusionne les observations simultanément disponibles, avec âge de la dernière observation et masque de marché fermé. Des tokens de mémoire à différentes résolutions résument le passé ancien.

La prévision jointe pose une difficulté : un ordre arbitraire des actifs peut introduire un biais. Deux solutions seront confrontées. La première génère un état commun futur puis des états spécifiques, avec dépendances résiduelles autorisées. La seconde génère un bloc de futurs avec un mécanisme joint continu ou discret, en testant sa sensibilité à l'ordre des actifs. Une simple tête indépendante par actif ne suffit pas à revendiquer une loi jointe expressive.

L'attention bidirectionnelle entre données toutes déjà observées peut être admissible. En revanche, un décalage d'une seconde dans la disponibilité réelle peut invalider une relation anticipatrice apparente. Les masques doivent porter sur les dates de disponibilité, pas seulement les indices du tableau. L'agrégation d'une heure ne peut être consultée pendant cette heure comme si son cours de clôture était connu.

La proposition se situe dans une littérature active. Moirai traite plusieurs variables, Chronos-2 étudie le contexte multivarié ; TimesFM-3 propose une alternance d'attention temporelle et inter-séries. Ces références soutiennent des composants possibles, pas une supériorité démontrée pour nos prix. Le document 08 détaille les choix et leurs antériorités. Moirai, Chronos-2, TimesFM-3.

7 Objectifs d'apprentissage et évaluation

L'objectif principal sera une prévision probabiliste sur la même cible physique pour tous les langages. Une perte auxiliaire de reconstruction peut stabiliser l'encodeur ; une tâche de correspondance entre vues peut tester le transfert. Leurs poids sont choisis sur validation et publiés. Une tâche auxiliaire facile ne doit pas masquer un mauvais score de prévision.

Une densité continue permet le log-score si ses conventions sont fixées. Des échantillons de trajectoires peuvent être évalués par CRPS marginal et scores multivariés complémentaires ; des quantiles marginaux seuls ne définissent pas la dépendance entre pas futurs. Les erreurs de moyenne, médiane, dispersion et direction seront séparées. Le score principal et ses agrégations sont fixés avant l'ouverture du test.

Un modèle de persistance, des modèles linéaires/factoriels et des modèles de volatilité constituent des références scientifiques. Les Transformers seront comparés à quantité d'information et budget documentés. Une branche récurrente peut mesurer un contraste architectural ; la priorité de travail au GPT ne transforme pas cette préférence en preuve.

Les séparations comportent des dates futures, des actifs non utilisés, une famille de marché réservée et une évaluation prospective. Les changements d'indice, de symbole, de contrat et les actifs disparus sont conservés. Une archive actuelle ne certifie pas à elle seule la version exacte d'une donnée disponible en 2008.

8 Étudier les effets d'échelle sans enfermer l'hypothèse

Le plan varie paramètres N, observations originales D, diversité V, contexte L et précision R. Une famille de courbes `loss(N,D,V,L,R)` est plus informative qu'un classement de trois tokenizers à une seule taille. On distinguera budget égal et taille égale, répétitions des mêmes fenêtres et nouvelles observations, apprentissage insuffisamment optimisé et saturation apparente.

Des lois d'échelle ont été observées pour des Transformers temporels. Les expériences d'Edwards et collaborateurs motivent ce programme ; celles de Yao et collaborateurs soulignent aussi que l'architecture

modifie le comportement. Elles ne fournissent pas des exposants universels à copier pour les prix à la seconde. Edwards et al., Yao et al..

Une courbe plate sur une petite plage de tailles restera un résultat local. Il faudra examiner l'optimisation, l'information, le mélange de domaines et les limites de contexte. Une poursuite peut être justifiée par une hypothèse nouvelle précise ; multiplier les calculs sans diagnostic rendrait l'hypothèse impossible à distinguer d'une affirmation irréfutable. Le document 05 définit cette discipline.

9 Ce qui rendrait la recherche nouvelle

Ni le Transformer temporel, ni la tokenisation de bougies, ni le facteur de marché ne sont nouveaux isolément. La contribution pourrait être une expérience démontrant qu'un langage progressif conserve mieux une information prédictive transférable ; une factorisation commune/spécifique améliorant des actifs jamais vus ; ou une loi empirique reliant diversité réelle, résolution et capacité sur plusieurs familles de prix.

Des motifs sans nom humain peuvent être découverts, mais leur nouveauté devra être distinguée de saisonnalités, d'une volatilité persistante et d'artefacts de source. Un catalogue de motifs sera accompagné d'exemples éloignés dans le temps, de contre-exemples et de tests sur des séries réservées. Une attention élevée sur un motif ne constitue ni une explication causale ni une validation de sa prédictivité.

10 État des preuves et questions ouvertes

Le programme possède désormais un appareil de reconstruction vérifié sur un petit corpus réel, présenté au document 07. Il ne possède pas encore de résultat de prévision, de transfert multi-marchés ou de passage à l'échelle. Le jeu de calibration initial ne couvre ni la seconde ni les grandes familles d'actifs proposées. Il constitue une vérification méthodologique, pas une réduction de l'ambition.

Les principaux inconnus sont la quantité d'information prédictive accessible, le vocabulaire permettant de l'apprendre efficacement, le degré de partage entre actifs et les besoins de données pour les régimes rares. Ils sont transformés en questions expérimentales dans les documents 04, 05 et 08. Le projet continue en révisant les hypothèses à partir des résultats, sans transformer une intuition prometteuse en certitude préalable.

TRAME et les langages possibles du marché

Atlas des représentations et conversion des courbes en tokens

14 octobre 2026. Recherche conceptuelle. TRAME est un nom de travail proposé, sans affirmation de disponibilité de marque. Le nom renvoie à une structure qui se construit dans le temps et à plusieurs fils d'information. Le projet cherche une grammaire des marchés, pas seulement des chandeliers. Alternatives envisagées : Palimpseste, pour les lectures superposées d'une même histoire ; et Morphose, pour les transformations de régime. TRAME est retenu dans ce dossier pour sa simplicité.

Mise à jour scientifique 2, 14 octobre 2026. L'exemple historique reste une démonstration de conversion. Le document 07 ajoute une mesure réelle de distorsion ; le document 08 ouvre la comparaison GPT et marché latent.

1 La question essentielle

Un token n'est pas nécessairement un mot, ni un prix, ni une bougie. C'est une unité de représentation donnée à un modèle de séquences. Il peut être un identifiant discret appris, un vecteur continu de plusieurs observations, un événement ou une combinaison de ces éléments. Le mot « langage » désigne l'alphabet, la structure des unités, l'ordre des éléments et leurs dépendances.

Un LLM qui lit le texte « le prix augmente de 2 % » utilise un tokenizer de texte. Un modèle financier peut recevoir directement un identifiant qui signifie une zone de rendement, ou un vecteur contenant rendement et durée. Dans ce second cas, aucun détour par le français n'est nécessaire. Les embeddings et la tête de sortie sont propres au domaine ; réutiliser une architecture Transformer ne signifie pas conserver le vocabulaire ou les poids d'un assistant conversationnel.

Notre proposition est de ne pas choisir immédiatement un seul alphabet. Il faut constituer une **bibliothèque de transpositions**, comparer ce qu'elles préservent, puis apprendre éventuellement à combiner celles qui apportent des informations complémentaires. Le modèle peut apprendre des régularités que nous n'avons pas nommées. Cette capacité doit être mesurée sur un futur non utilisé pour les découvrir.

2 Le contrat d'une langue de marché

Chaque langue candidate est décrite par neuf champs : observation source ; transformation ; instant auquel elle devient calculable ; unité et durée ; état auxiliaire nécessaire ; information perdue ; reconstruction ; événements impossibles ; tâche de validation. Ce contrat empêche une représentation séduisante de masquer une fuite ou une perte décisive.

Exemple : « hausse » représente le signe d'une variation. Pour reconstruire un prix, il manque la magnitude, la durée et un niveau initial. Un vocabulaire hausse/baisse peut reconnaître des séquences de signes ; il ne décrit pas une trajectoire de risque complète. On peut l'enrichir par durée et amplitude, ou le conserver volontairement pauvre comme expérience de contrôle.

Les champs inconnus ne deviennent pas zéro. Zéro volume, aucun événement, capteur absent, session fermée et réponse perdue sont cinq situations différentes. Une grammaire doit disposer de masques et de marqueurs explicites. Elle doit aussi distinguer prix de transaction, bid, ask, mid, mark et oracle.

3 Une vraie bougie transformée pas à pas

3.1 Provenance et limite de cet exemple

Pour sortir de l'exemple inventé, un petit fichier historique réel a été inspecté : archive Binance Vision BTCUSDT spot, bougies horaires de mars 2020. Le fichier et son CHECKSUM ont été téléchargés pour cette étude documentaire ; leur SHA-256 correspond. Il contient **743 bougies uniques**, avec une interruption entre les ouvertures du 4 mars à 09:00 et 11:00 UTC. La cause du trou n'a pas été établie. Le mois théorique comporte 744 heures : une archive authentique n'est donc pas automatiquement une grille complète.

La bougie choisie commence le **12 mars 2020 à 12:00 UTC**, soit 13:00 à Paris ce jour-là. Son choix illustre la représentation d'une forte amplitude ; il ne constitue pas une sélection d'évaluation. L'archive a été reçue en octobre 2026 : elle n'atteste pas la latence de publication en 2020. Aucun modèle n'a été entraîné, aucun résultat prédictif calculé sur ce fichier.

Source : archive réelle Binance Vision, description des champs. Les conditions consultées distinguent recherche personnelle hors production et usages nécessitant des droits supplémentaires : cet exemple reste limité à la recherche personnelle. Il ne définit pas le corpus multi-marchés visé. Conditions de données.

3.2 Données brutes

Champ	Valeur réelle	Sens
Clôture précédente	6 067,01 USDT	Ancre de reconstruction
Ouverture O	6 064,27 USDT	Première valeur de la bougie
Haut H	6 307,59 USDT	Extrême supérieur observé
Bas L	5 900,00 USDT	Extrême inférieur observé
Clôture C	6 028,10 USDT	Dernière valeur de la bougie
Volume V	18 013,68913 BTC	Quantité de l'actif de base
Transactions	137 478	Nombre fourni par l'archive

Ces nombres décrivent une heure. Ils ne disent pas dans quel ordre le haut et le bas ont été touchés. Plusieurs chemins opposés de stop et de profit sont compatibles avec la même ligne. Aucun tokenizer ne peut récupérer une information absente de sa source.

3.3 Anatomie relative inversible

Avec A la clôture précédente, nous définissons :

```
g = ln(O/A)

b = ln(C/O)

u = ln(H/max(O,C)) >= 0

d = ln(min(O,C)/L) >= 0

v = ln(1 + V/V_ref)
```

V_ref est une unité ou une échelle de volume documentée. Pour l'exemple seulement, V_ref vaut 1 BTC. Pour transférer entre actifs, on utilisera une référence calculée sur le passé disponible et on conservera cette référence. Le « 1 » dans un logarithme doit correspondre à une quantité sans dimension.

Sur la ligne réelle, les résultats sont : g = -0,0004517248 ; b = -0,0059823025 ; u = 0,0393394977 ; d = 0,0214795190 ; v = 9,7989427669. Les quatre premiers nombres sont des log-ratios, pas exactement des pourcentages usuels. Par exemple, un rendement logarithmique r devient un rendement simple `exp(r)-1`.

La reconstruction est déterministe si les nombres ne sont pas quantifiés :

```
O = A × exp(g)

C = O × exp(b)

H = max(O,C) × exp(u)

L = min(O,C) × exp(-d)

V = V_ref × (exp(v)-1)
```

Les contraintes OHLC sont alors respectées lorsque u,d,v sont non négatifs. Un modèle doit aussi pouvoir représenter exactement une mèche ou un volume nul : prévoir une masse en zéro, et non seulement une fonction strictement positive. Ce type de représentation structurée possède déjà des antériorités, dont KiT ; il s'agit ici d'un exemple de conception, pas d'une revendication d'invention.

3.4 De la géométrie au vocabulaire discret

Prenons volontairement un alphabet simple : arrondir les quatre log-ratios au multiple de 0,001 le plus proche. Le mot devient `G_0 B_-6 U_39 D_21`. La taille d'un cran est environ dix points de base pour les petites variations. Pour v, une grille de 0,01 donne `V_980`. Ces identifiants sont illustratifs ; ils ne sont ni un tokenizer entraîné ni une grille recommandée.

Avec A = 6 067,01, les prix décodés sont O = 6 067,01 ; C ≈ 6 030,7169 ; H ≈ 6 308,2979 ; L ≈ 5 905,3924. L'erreur logarithmique de clôture vaut environ **4,34 points de base**. La chart ressemble à l'originale, mais la différence peut être plus grande qu'une variation que nous cherchons à prévoir. Le critère « la forme est bien reconstruite » est insuffisant.

Une branche de résidu conserverait les écarts entre coordonnées exactes et coordonnées quantifiées. Une hiérarchie grossier/fin permet aussi d'affiner seulement certaines dimensions. Une autre possibilité est de quantifier en unités de volatilité passée : la résolution suit alors le régime, mais il faut conserver cette volatilité et les unités de prix dans le contexte. Pour générer plusieurs pas, V_ref et la volatilité sont soit figés à l'émission, soit mis à jour à partir du passé généré selon une règle documentée. Une échelle future calculée sur la trajectoire réelle ne doit jamais être fournie au décodeur.

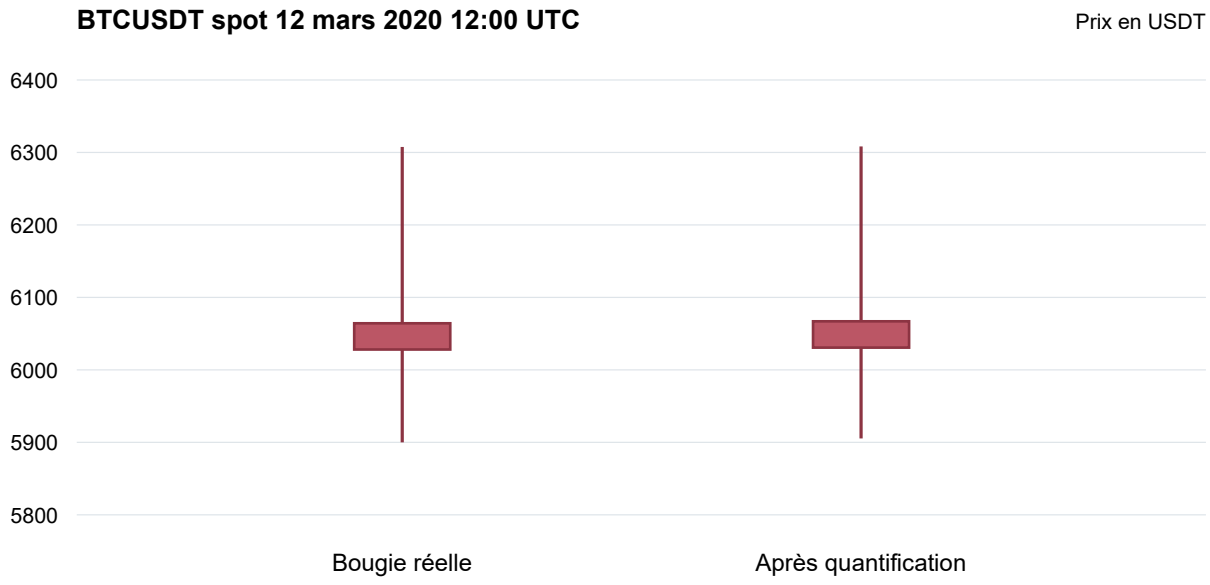


Illustration documentaire : les formes proches masquent une erreur de clôture de 4,34 points de base. Source réelle attribuée à Binance Vision ; transformation décrite dans le texte.

3.5 Du mot à la phrase

La séquence abstraite peut se lire ainsi : `DEBUT_EPISODE, PLACE, INSTRUMENT, UNITE, INTERVALLE, CONTEXTE, MOT_t-255, ..., MOT_t, FIN_CONTEXTE`. Le modèle prédit ensuite une distribution sur MOT_t+1 et ses composantes. Les tokens de métadonnées ne doivent pas utiliser des propriétés calculées avec le futur. L'identité de l'actif peut être masquée dans certaines expériences pour tester si le modèle mémorise plutôt qu'il ne transfère.

Les noms explicites ci-dessus servent au lecteur. En pratique, un codebook appris peut donner un numéro 713 à une région du latent sans signification humaine unique. La bonne interprétation d'un code se fait après entraînement par ses exemples, sa reconstruction et ses effets mesurés, pas en lui attribuant un récit psychologique.

4 Les principales familles de langues

Langue candidate	Ce qu'elle rend facile	Information perdue ou piège	Premier test utile
Prix absolus	Niveaux ronds, tick, barrières nominales	Dépendance aux unités et niveaux historiques	Transfert avec changement d'échelle
Écarts de prix	Mouvement local en monnaie	Comparabilité faible entre actifs	Écarts en tick contre monnaie
Rendements simples	Comparaison d'amplitudes relatives	Asymétrie hausse/baisse et composition	Retour à l'unité de prix
Log-rendements	Additivité dans le temps	Prix nul ou négatif incompatible	Branche spéciale pour instruments concernés
Signes hausse baisse stable	Persistance et alternance	Magnitudes et risque supprimés	Même modèle avec amplitude réintroduite
Quantiles ou rangs	Robustesse à l'échelle	Extrêmes écrasés et seuils instables	Quantiles appris sur train et queues séparées
Écarts en volatilité passée	Formes comparables entre régimes	L'échelle absolue disparaît	Échelle jointe contre échelle omise
Distance aux niveaux	Approches et franchissements	Niveaux définis après coup	Niveaux connus avant chaque observation
Bougie structurée	Relations ouverture corps mèches	Chemin intrabougie absent	Reconstruction et franchissements bornés
Paliers et changements directionnels	Temps intrinsèque et persistance	Durée variable et événements censurés	Prévision conjointe direction durée amplitude
Segments appris	Motifs locaux plus compacts	Frontières qui regardent l'avenir	Segmentation causale en flux
Événements du carnet	Offre demande et files d'attente	Flux incomplet et règles de place	Rejeu déterministe avec continuité
Relations entre actifs	Retards, écarts et facteurs communs	Synchronisation et corrélation de corpus	Familles/calendriers exclus du train

Langue candidate	Ce qu'elle rend facile	Information perdue ou piège	Premier test utile
Images de courbes	Inductif spatial et reconnaissance visuelle	Axes, pixels, couleurs et précision	Rendu standardisé à information identique

Les représentations peuvent coexister. Le prix absolu n'est pas « faux » parce que le rendement transfère mieux ; il peut porter une information de tick ou de niveau rond. À l'inverse, lui donner une place dominante peut faire mémoriser les identités. Un canal relatif principal et des canaux absolus documentés constituent une hypothèse de compromis.

Les prix logarithmiques ne sont pas universels : certains instruments ou épisodes ont des prix non positifs. Une alternative est l'écart divisé par une échelle positive passée, ou une transformation signée de type asinh. On doit documenter son inverse et ses unités. Exclure silencieusement ces observations produirait un corpus artificiellement confortable.

5 Comment apprendre un vocabulaire

5.1 Bins définis à la main

Des intervalles fixes de rendements ou d'amplitudes donnent une référence lisible et reproductible. Ils rendent visibles la résolution et le clipping. Des bins de quantiles occupent le vocabulaire plus uniformément mais changent le amplitude physique des crans et écrasent parfois les queues. Les frontières sont apprises sur entraînement, puis gelées pour validation et test.

Un code d'extrême ne doit pas transformer toutes les crises en une valeur unique. On peut lui associer un résidu, une amplitude logarithmique supplémentaire ou des classes ouvertes avec une distribution conditionnelle. Le taux de saturation sera un diagnostic obligatoire.

5.2 Vocabulaire conjoint par quantification vectorielle

Un encodeur e transforme la bougie en vecteur ; un codebook choisit un prototype ; un décodeur reconstruit. L'apprentissage équilibre reconstruction, engagement vers les codes et diversité d'occupation. Le code peut capturer une relation corps/mèches/activité difficile à fixer à la main.

Ses risques sont le codebook peu utilisé, la quantification d'artefacts de source et la perte d'événements rares. Il faut mesurer l'entropie d'occupation, les codes morts, la stabilité par régime, la reconstruction extrême et la précision des petits écarts de prix et des extrêmes. On ne choisira pas la taille du vocabulaire par perplexité de token seulement.

5.3 Codes factorisés et hiérarchiques

Si cinq dimensions ont chacune 256 valeurs, le vocabulaire cartésien contient 256 puissance 5 possibilités : plus d'un billion. Une table d'embeddings exhaustive serait absurde. Une séquence de cinq codes ou des têtes factorisées évitent ce produit, au prix d'une dépendance à l'ordre et de davantage de positions. Un code grossier partagé et des raffinements spécialisés offrent une troisième voie.

Comparer les coûts en observations sources, nombre de tokens, opérations et latence. Un modèle qui consomme dix tokens par bougie n'est pas comparé honnêtement à un autre en leur attribuant simplement le même nombre de tokens d'entraînement.

5.4 Vocabulaire de segments

Un équivalent de BPE pourrait fusionner des séquences fréquentes de symboles financiers. C'est une piste spéculative : les mots n'auraient pas de longueur calendaire fixe. Apprendre les fusions uniquement sur entraînement est nécessaire mais ne suffit pas ; il faut une règle causale de fermeture des mots. Attendre de connaître le mouvement suivant pour déclarer la fin du motif crée un délai qui doit apparaître dans la décision.

Les meilleurs segments de reconstruction peuvent ignorer les zones où le futur se décide. Une segmentation par changement statistique causal, une durée maximale et un marqueur de segment non terminé doivent être comparés à des patches fixes. Les frontières ne seront jamais optimisées rétrospectivement puis présentées comme connues en direct. À chaque décision, le tokenizer ne reçoit que le préfixe disponible : soit on retokenise ce préfixe, soit une règle en flux ferme les mots avec un état incomplet explicite. Un BPE hors ligne appliqué à toute l'histoire future peut changer le suffixe des tokens passés et viole ce contrat.

5.5 Tokens continus

Un vecteur continu projeté dans l'espace d'embedding joue le rôle d'un token sans dictionnaire discret. Cela simplifie la précision numérique et évite les codes morts. Le modèle doit alors produire une distribution continue, une trajectoire générée ou des quantiles. « Transformer le marché en langage » n'impose donc pas de discrétiser : c'est une des hypothèses du concours.

6 Le temps fait partie du langage

Un mouvement de 1 % en une seconde et en trois semaines ne porte pas le même risque. Une langue à intervalles réguliers conserve implicitement une durée fixe, mais doit marquer sessions et interruptions. Une langue à événements doit conserver le délai depuis le dernier événement et la durée passée sans événement.

Les paliers peuvent définir le prochain mot quand le prix s'écarte d'un seuil. On doit prédire **la direction, l'amplitude éventuelle du dépassement et la durée d'attente**. Le seuil utilisé pour ouvrir un événement est fixé avec l'information courante ; l'ajuster rétrospectivement à la volatilité future est une fuite. À la fin d'un échantillon, un événement non terminé est censuré, pas absent.

Le nombre H d'événements futurs n'est pas l'horizon H minutes. L'évaluation commune doit revenir à des horizons calendaires choisis : distribution à une heure, probabilité de franchissement en quatre heures, maximum de perte en une journée. Autrement, chaque alphabet pourrait choisir implicitement sa propre difficulté. Direction, durée et dépassement ne déterminent cependant pas le chemin intrapalier ni les OHLC horaires. Il faut un décodeur probabiliste de chemins compatibles, des observations auxiliaires ou des métriques limitées aux événements identifiables ; changer d'horloge ne restitue pas l'information perdue.

À plusieurs échelles, une bougie de quatre heures n'est disponible qu'après sa clôture et réception. Pendant sa formation, on peut utiliser une bougie partielle identifiée comme telle, avec âge et couverture ; on ne peut pas lui attribuer son haut, son bas et son volume finaux. Une attention interéchelles ne corrige pas une jointure temporelle erronée.

7 Les hypothèses inhabituelles méritant une expérience

La partition musicale

Interpréter la variation comme hauteur, l'activité comme intensité et le temps entre événements comme rythme. Un réseau pourrait détecter des motifs de répétition ou de rupture mieux qu'avec les nombres bruts. La version raisonnable utilise ces canaux numériques, sans fabriquer un fichier audio. Un préentraînement sur musique ne sera testé que si l'on peut isoler un gain de représentation : la similarité poétique n'est pas une preuve de transfert. Comparaison : même information sous forme de canaux numériques, spectral et audio, à budget égal.

La physique locale

Ajouter vitesse, accélération, courbure, « énergie » de variation ou friction normalisée. Les dérivées discrètes amplifient le bruit ; des filtres centrés regardent le futur. Seuls des filtres unilatéraux sont admissibles en entrée live. Les termes énergie et force sont des analogies calculatoires, sans supposer une loi de Newton pour les prix. Test : bénéfice incrémental au-delà des mêmes retards de rendement.

Une trajectoire géométrique

Traiter prix, volume et temps comme un chemin multidimensionnel, puis représenter son ordre par intégrales itérées ou signatures tronquées. Ces objets peuvent encoder l'ordre et les interactions ; l'ajout du temps empêche certaines invariances d'effacer le rythme. Leur dimension augmente vite et des ambiguïtés demeurent avec troncature. On comparera quelques ordres faibles à des patches simples. Cette piste s'inspire de la littérature des signatures de chemins, pas d'une découverte revendiquée ici. Présentation primaire des signatures.

Topologie et formes persistantes

Construire un nuage de fenêtres passées et chercher des structures qui persistent à plusieurs échelles. Hypothèse : ces descripteurs peuvent signaler des régimes ou transitions. Risques : hyperparamètres nombreux, coût et faible lien avec la cible future. La première expérience vise la détection de régime, puis vérifie si elle ajoute quelque chose à volatilité et corrélation. Une jolie carte de clusters ne suffit pas.

Le langage des contraintes

Prédire des relations ordinales plutôt que des prix : prochain haut supérieur au précédent, clôture dans le quart supérieur, volume au-dessus de sa médiane passée, spread sous un seuil. Une logique de contraintes assemble des scénarios compatibles. Cette langue pourrait être robuste mais grossière. Il faut mesurer sa perte d'amplitude et vérifier que les propositions marginalement probables ont une distribution jointe cohérente.

Le marché comme conversation entre actifs

Représenter chaque actif comme un interlocuteur qui émet un changement de prix et une mesure d'activité ; apprendre quels autres actifs il « écoute » selon le régime. Le graphe doit être appris sur le passé et utiliser les heures de réception. Un lien d'attention ou un retard statistique n'établit pas une causalité économique. Test : actif cible tenu à l'écart, puis familles entières, délais réalistes et interdiction des valeurs contemporaines non reçues.

Les langues parallèles et la traduction

Présenter le même épisode en rendements, bougies et événements. Entraîner une représentation partagée à traduire une vue vers une autre et à prévoir le futur. C'est la piste spéculative prioritaire : elle peut encourager des invariances utiles et détecter des données incohérentes. Les transformations du même OHLCV changent l'inductif ; les événements réellement observés ajoutent de l'information source. Deux ablations séparées doivent mesurer ces effets. Une traduction aller-retour entre vues avec perte ne constitue pas une preuve de réversibilité. Mais traduire OHLC en événements exacts est impossible sans information supplémentaire ; la sortie doit alors être une distribution de réalisations compatibles, jamais une reconstruction unique annoncée exacte.

La grammaire minimale et la surprise

Chercher des descriptions courtes qui compressent un épisode et détecter les ruptures quand la description échoue. Une surprise élevée pourrait annoncer un changement de régime et justifier l'abstention. Elle peut aussi refléter une panne de données ou un simple événement rare sans suite prédictible. Test : capacité à prévoir des erreurs futures du modèle, au-delà des contrôles de fraîcheur et de volatilité.

La symétrie et son contraire

Inverser le signe, changer l'échelle ou accélérer le temps pour tester les invariances. Certaines augmentations sont utiles pour la robustesse, d'autres détruisent la sémantique : hausses et baisses peuvent présenter des dynamiques et des queues différentes ; inverser le temps peut détruire les dépendances temporelles et la chronologie des événements. Les données transformées sont des augmentations identifiées, pas de nouvelles observations réelles, et elles ne remplacent jamais le test réel.

8 Trouver des motifs réellement nouveaux

Le réseau n'a pas besoin de connaître les figures traditionnelles. Il peut apprendre des relations entre amplitude, activité, contexte et durée que l'humain n'a pas nommées. Pour étudier cela, on peut regrouper ses états latents, examiner des exemples proches, entraîner des sondes simples sur des cibles indépendantes et masquer certaines entrées pour mesurer la variation de prédiction.

Ces outils expliquent une dépendance du modèle, pas nécessairement le mécanisme du marché. On exigera trois preuves séparées pour un motif candidat : il se retrouve sur des données indépendantes ; sa valeur survit à des variables de contrôle et à un modèle simple ; son information prédictive se retrouve sur des actifs et périodes réservés. Découvrir un cluster après avoir vu ses rendements puis tester sur les mêmes rendements n'est pas une découverte validée.

Une analyse de compression peut découvrir une structure non aléatoire sans prédictivité directionnelle. Des alternances de volatilité, rythmes de sessions ou dépendances de volumes constituent déjà des régularités. L'ambition supplémentaire est de montrer qu'une partie de cette structure informe une tâche future utile. Le dossier ne postule ni marché entièrement aléatoire ni prédictibilité universelle.

9 Concours initial de langues et priorités

La première ronde comporte quatre familles : rendements continus avec canaux auxiliaires ; bins structurés simples ; vocabulaire vectoriel appris ; langage de paliers avec durée. Même corpus réel, mêmes instants de décision, mêmes horizons, budgets documentés et même nombre d'essais. Les comparaisons porteront sur scores de prévision décodés, calibration, reconstruction et transfert entre marchés.

Les rondes suivantes comparent continu, discret et hybride à plusieurs tailles de GPT et volumes de données. Une faible performance initiale ne suffit pas à éliminer une famille : on étudie sa courbe de progression et ses pertes d'information. Les langues parallèles et le contexte entre actifs sont des axes distincts. La microstructure complète est une branche autonome conditionnée par les données, pas un canal supposé disponible. Les pistes musicales, topologiques et signatures reçoivent de petits budgets exploratoires prédéfinis.

Un résultat est invalidé si son avantage vient d'une information future ou d'une comparaison inégale. Une résolution inadéquate ou un effet non reproduit motive un diagnostic et une nouvelle version de l'expérience ; cela ne réfute pas tous les modèles possibles de cette famille. Il peut être conservé pour une autre tâche si cette utilité est explicitement séparée. L'ouverture aux idées inhabituelles exige cette discipline pour ne pas transformer la recherche en sélection infinie de coïncidences.

10 La proposition retenue à ce stade

TRAME désigne un **programme d'apprentissage du langage des marchés réels**, potentiellement multiactifs et multiéchelles. Sa langue de référence initiale utilise une géométrie relative réversible, le contexte d'échelle, la durée et l'activité. Les versions discrète et continue restent en concurrence. Des langues supplémentaires doivent démontrer leur contribution.

Le point de recherche le plus prometteur est moins « transformer chaque bougie en un mot » que **choisir ce qu'un mot doit conserver pour que sa suite reste prévisible et utile**. Les données réelles, la reconstruction en prix et la prévision hors échantillon constituent le lien permanent entre l'analogie linguistique et le marché.

11 Nouvelle piste : un langage à précision progressive

La comparaison réelle du document 07 montre un piège : des quantiles par champ peuvent bien restituer la majorité des petites variations et beaucoup moins bien certains mouvements rares. Cette observation ne réfute pas les vocabulaires appris. Elle indique que le débit alloué aux queues et la représentation des valeurs hors plage doivent être des paramètres explicites.

Une piste hybride représente chaque coordonnée par un signe, une classe d'ordre de grandeur, un code de forme et un résidu. Une autre réserve un symbole d'échappement aux extrêmes, suivi d'une amplitude continue. Une troisième utilise plusieurs couches de précision, où l'on ne termine le mot qu'après un nombre maximal de raffinements. Ces langages sont des propositions nouvelles pour l'expérience suivante, pas des mécanismes déjà entraînés ou validés.

Le coût doit inclure les échelles, l'ancre, la durée, le codebook et les résidus. Une faible erreur obtenue avec cinq nombres continus supplémentaires par bougie n'est pas une compression gratuite. On cherchera un front précision/débit, puis un front prévision/calcul, à plusieurs tailles de modèle. La reconstruction isolée ne suffit pas à choisir le meilleur langage prédictif.

Le niveau zéro d'une mèche, l'absence de transaction et l'absence de mesure restent des états différents. Un token rare ne doit pas servir indistinctement pour une crise réelle, une valeur impossible et une panne de source. Ces distinctions sont sémantiques avant d'être architecturales.

Faisabilité scientifique et technique de TRAME

Version 2, 14 octobre 2026. Cette analyse dimensionne une recherche multi-marchés sur les prix. Les contraintes de l'ancien projet applicatif ne définissent pas le programme. Aucun entraînement neuronal n'est exécuté à ce stade.

1 Ce qui est réalisable, ce qui reste à établir

Constituer des séquences numériques, entraîner un Transformer et prévoir des distributions de prix est techniquement possible. Les incertitudes portent sur l'information disponible, les erreurs d'observation, le transfert entre familles et le comportement avec la taille. Une infrastructure plus puissante traite plus de séquences ; elle ne suffit pas à établir leur diversité ni leur pouvoir prédictif.

Le premier appareil d'analyse a fonctionné localement sur CPU et environ 16 Gio de mémoire physique. Il compare cinq encodages sur des bougies réelles. Cette mesure de faisabilité concerne la préparation des observations et la reconstruction ; elle ne mesure pas le débit d'entraînement d'un GPT. Aucun budget GPU complet ne peut être déduit de cette exécution.

2 Construire trois couches d'histoire

Couche	Question scientifique	Données souhaitées	Limite à traiter
Longue histoire	Transfert entre régimes et décennies	Prix quotidiens ou horaires multi-familles, incluant 2000, 2008 et 2020 lorsque disponibles	Révisions, instruments disparus, changements institutionnels
Histoire intermédiaire	Formes, rythmes et dépendances	Minutes et heures sur de nombreux instruments	Calendriers et changements de contrats
Détail récent	Information ajoutée par la finesse	Transactions ou cotations permettant des observations à la seconde	Volume massif, prix inchangés, asynchronisme et disponibilité réelle

Ces couches doivent coexister avec des masques de modalité. On ne fabrique pas une histoire à la seconde à partir de clôtures quotidiennes. Un indice calculé, un futur, un cours de référence et un prix d'action possèdent des conventions différentes. Les instruments apparentés peuvent renseigner un même phénomène sans être des doublons interchangeables.

Une profondeur historique réelle existe au-delà des cryptomonnaies. Le catalogue NYSE Daily TAQ annonce des transactions et cotations historiques depuis 1993, sous accès commercial à qualifier. Cela rend l'étude des années 2000 plausible pour certaines actions, sans certifier que toutes les résolutions et tous les champs aient la même qualité sur chaque période. Aucun achat n'a été effectué. Catalogue primaire NYSE.

La BCE fournit des cours de référence quotidiens pour de nombreuses devises ; ils offrent une autre famille et une longue histoire. Ils ne possèdent pas une bougie OHLCV native ni un volume de transactions. Le manifeste de la collecte exploratoire, s'il est présent, distingue données reçues et catalogue théorique. Les références scientifiques des sources et leur état d'accès sont au document 06.

Pour l'or et les indices, la prochaine acquisition doit préciser l'instrument visé : référence spot, contrat daté, série de contrats, indice officiel ou autre mesure. Une série continue de futures résulte d'une règle de

raccordement ; un ajustement utilisant des contrats futurs peut introduire une information rétrospective. Le raccordement et les prix d'origine doivent rester audités séparément.

3 Ordres de grandeur de la seconde

Ces calculs sont des scénarios, pas des volumes déjà acquis. Pour 100 actifs ouverts 24 h sur 24 pendant dix années de 365 jours : 31,536 milliards d'observations à la seconde. Avec vingt champs float32, leur seul payload numérique vaut environ 2,52 To décimaux, avant horodatages, identifiants, masques, index et copies. Pour 1 000 actifs, ce payload devient environ 25,2 To. Une archive comprimée peut être plus petite ; l'espace de travail peut être plusieurs fois plus grand.

Pour 1 000 instruments sur 252 séances annuelles de 6,5 heures pendant dix ans : environ 58,968 milliards d'observations, soit 4,72 To de payload à vingt champs float32. Ce calcul illustre l'effet du calendrier ; il ne représente pas l'ensemble des horaires mondiaux. Le carnet et les messages événementiels peuvent dépasser largement ces tailles.

Le nombre d'observations n'est pas le nombre d'expériences indépendantes. Des secondes sans changement et des centaines d'instruments exposés au même facteur répètent une information. La diversité se mesure par actifs, familles, calendriers, régimes et sources, avec dépendance temporelle et transversale documentée.

4 Pourquoi un GPT naïf ne suffit pas

Une journée de 86 400 tokens produit environ 7,46 milliards de paires d'attention par tête et par couche dans une attention dense. Un tableau matérialisé en deux octets par paire représente environ 14,9 Go. Des noyaux efficaces évitent de matérialiser ce tableau entier, mais ne suppriment pas le coût arithmétique quadratique de l'attention dense. Ce calcul exclut projections et activations.

La piste proposée consiste à garder la haute résolution dans un voisinage récent, puis des patches et mémoires plus espacées dans le passé. L'attention inter-actifs doit également être structurée : groupes, facteurs latents ou agrégation en ensembles, plutôt qu'un aplatissement aveugle de toutes les secondes de tous les instruments. Toute compression devient une hypothèse de langage à tester.

Un contexte récent à la seconde, un contexte moyen à la minute et un contexte long quotidien peuvent couvrir des échelles très différentes. Les résumés anciens sont calculés sur des intervalles déjà achevés. Leur qualité se mesure par ce qu'ils permettent de prévoir, pas seulement par leur capacité à restituer les données.

5 Calcul et mémoire d'entraînement

L'ordre de grandeur `6 × N × D` opérations pour un entraînement dense de Transformer est un outil de planification approximatif, N étant le nombre de paramètres et D le nombre de tokens effectivement traités. Le coût exact dépend notamment de la longueur du contexte, de l'attention, du batch, des objectifs et du recomputing. Un token financier n'a pas une valeur informationnelle fixe.

À titre arithmétique : 100 millions de paramètres et un milliard de tokens donnent environ 6 × 10^17 opérations selon cette approximation. À 100 téra-opérations soutenues par seconde, cela représente environ 1,7 heure de calcul idéal ; à 10 téra-opérations soutenues, environ 16,7 heures. Ces débits sont des hypothèses, pas une mesure ni une promesse de machine. Chargement, attention longue, évaluations, réplications et essais multiplient le temps total.

La mémoire des seuls états entraînables peut atteindre de l'ordre de 16 à 20 octets par paramètre selon les conventions d'optimiseur et précision ; il faut ajouter activations et buffers. Le débit réel doit être mesuré sur un batch représentatif, avec les masques et la longueur de contexte prévus. Aucun choix définitif de fournisseur ou d'accélérateur ne précède ce microbenchmark.

6 Ce qu'un échec signifierait

Observation	Interprétations possibles	Expérience suivante utile
Entraînement et validation faibles	Optimisation, capacité, représentation, cible difficile	Vérification sur tâche contrôlée et courbe de taille
Entraînement bon, validation faible	Surapprentissage, dérive, fuite de sélection, manque de diversité	Nouveaux blocs temporels et famille réservée
Taille accrue sans gain	Données répétées, budget d'optimisation insuffisant, saturation locale	Augmenter nouvelles observations et comparer à calcul équilibré
Reconstruction bonne, prévision faible	Préservation d'information sans apprentissage utile	Langage plus structuré, cibles et références séparées
Échec d'un vocabulaire grossier	Résidus perdus, pas nécessairement échec du discret	Symbole extrême, précision progressive, résidu continu

Aucune ligne ne prouve à elle seule que le projet est impossible. En revanche, une suite d'essais doit produire des diagnostics enregistrés. Poursuivre la recherche peut signifier modifier la cible, le corpus ou le mécanisme partagé, et non répéter le même calcul plus longtemps.

7 Blocages réels et pistes ambitieuses

Les obstacles concrets sont l'obtention d'une histoire large de qualité, la cohérence des dates de disponibilité, la reconstruction de calendriers et la séparation entre instruments dépendants. La densité à une seconde accroît les exigences de provenance ; elle ne résout pas les ruptures historiques.

Les pistes les plus ambitieuses sont un vocabulaire à précision progressive, un état partagé avec résidu spécifique, une mémoire multi-échelle et une étude conjointe de capacité et diversité. Elles restent techniquement plausibles. Leur valeur scientifique devra être établie face à des modèles plus simples et sur des observations effectivement nouvelles.

Construire TRAME comme programme scientifique

Tutoriel du premier appareil de mesure au modèle reproductible

Version 2, 14 octobre 2026. La cible est la prévision des prix sur plusieurs marchés. Les étapes prédictives ci-dessous restent à réaliser ; l'étude de reconstruction du document 07 est la seule expérience quantitative achevée à ce stade.

Étape 1 Écrire une question qui puisse recevoir une réponse

Nous commençons par deux questions distinctes. Le partage d'un modèle entre actifs améliore-t-il les prévisions ? L'observation simultanée des autres actifs apporte-t-elle ensuite une information supplémentaire ? La première teste le transfert de grammaire ; la seconde teste une représentation commune de l'état de marché.

La fiche de chaque expérience précise variable de prix, horizon, dates d'information, représentation, architecture, budget, métrique principale et comparaisons. Une hypothèse plus ambitieuse peut rester ouverte après un échec local ; la fiche doit annoncer exactement ce qui est testé pour ne pas lui attribuer une portée universelle.

Livrable : fiche d'expérience versionnée avec date de gel. **État :** protocole de reconstruction gelé puis amendé de façon tracée ; fiche de prévision multi-marchés encore à figer.

Étape 2 Définir les instruments et trois profondeurs historiques

Construire un registre d'actions, d'indices, d'or ou autres matières, de devises et éventuellement d'autres actifs. Pour chacun : type exact de prix, calendrier, devise, unité, durée de disponibilité, champs et droits de recherche. Le choix n'est pas fondé sur le résultat d'un modèle.

Prévoir une couche historique longue, une couche intrajournalière intermédiaire et une couche récente fine. Réserver des familles entières et des dates futures avant d'optimiser les langages. Les épisodes historiques servent à analyser les différences de comportement ; ils ne remplacent pas les périodes ordinaires.

Livrable : matrice instruments × périodes × résolutions, où disponible, acquis et validé sont trois états différents. **État :** petit corpus témoin réel vérifié ; corpus scientifique général incomplet.

Étape 3 Rendre chaque observation traçable

Conserver les fichiers bruts avec URL, date, taille et empreinte ; enregistrer les versions et les corrections. Le schéma normalisé distingue date du phénomène, fin de bougie et première disponibilité connue. Une donnée historique sans heure de publication attestée reste marquée comme telle.

Contrôler doublons, valeurs non finies, unités, ordre temporel, cohérence OHLC, heures absentes et intervalles incomplets. Une fermeture du marché n'est pas une panne de collecte. Les changements de contrat, de symbole et d'indice ont leurs propres métadonnées.

Le premier appareil de mesure a rencontré des bougies qui se terminent avant leur heure attendue. Elles ont été conservées dans le brut, exclues de la comparaison à durée fixe et consignées avant le calcul des métriques. Cet exemple montre pourquoi un checksum ne certifie pas la cohérence temporelle.

Livrable : manifeste et rapport de qualité. **État :** réalisés pour le témoin décrit dans le document 07 ; à étendre aux autres familles.

Étape 4 Tester les langues sans encore confondre avec prévision

Encoder et reconstruire les mêmes observations avec une branche continue, des quantifications fixes ou adaptées, un vocabulaire empirique et un contrôle volontairement pauvre comme les signes. Mesurer la distorsion, en particulier dans les queues, le nombre de symboles et les informations latérales nécessaires.

L'appareil POC0 et ses tests se trouvent dans research/trame_poc0. Le protocole, les empreintes et les résultats JSON permettent de vérifier le document 07. Les données synthétiques présentes dans les tests servent uniquement à contrôler les calculs ; les résultats scientifiques descriptifs utilisent des observations réelles.

Les prochaines variantes de langage ne seront pas ajustées discrètement sur la même validation. Un protocole suivant pourra ajouter un symbole hors plage, une quantification logarithmique des extrêmes et un résidu continu. Il conservera une référence de débit pour inclure l'ancre, les échelles et le codebook.

Livrable : atlas expérimental des pertes et invariances. **État :** première comparaison réalisée ; aucun vocabulaire déclaré gagnant pour prévoir.

Étape 5 Préparer des cibles identiques pour tous les modèles

Séparer input et cible future avec une convention explicite de disponibilité. À la seconde, une cotation arrivée plus tard que la date de prédiction est interdite même si son timestamp d'événement est antérieur. À l'heure, une bougie partiellement observée ne peut être remplacée par sa valeur finale.

Choisir une première cible principale et quelques diagnostics. Les candidats doivent prévoir les mêmes prix ou accroissements aux mêmes horizons. Les losses internes par token restent des diagnostics propres à chaque langage ; le score commun porte sur les valeurs physiques décodées.

Livrable : constructeur de cibles audité, inventaire des fenêtres et contrôle des dates. **État :** spécification ; aucun label prédictif n'a été calculé pour les mesures du document 07.

Étape 6 Construire les références et le premier GPT

Entraîner des références simples puis un premier Transformer de taille modeste. Le choix d'une taille initiale vise à vérifier l'expérience et l'optimisation. Il ne vise pas à prouver qu'un langage échouera à grande échelle.

Comparer A, modèles par actif ; B, paramètres partagés sans contexte d'autres actifs ; C, paramètres partagés avec contexte inter-actifs ; D, facteurs communs et états spécifiques explicites. Conserver les entrées physiques et rendre visibles les différences de budget. Le document 08 fournit les masques, les mécanismes et les ablations proposées.

Livrable : prévisions sauvegardées, checkpoints, courbes d'apprentissage et scores. **État :** futur. Aucun réseau n'est encore développé ou entraîné dans cette phase.

Étape 7 Mesurer le passage à l'échelle

Prendre plusieurs tailles de GPT, plusieurs volumes d'observations originales et plusieurs niveaux de diversité. Mesurer leur interaction au lieu d'augmenter toutes les dimensions à la fois. Conserver une précision d'encodage suffisante ou la faire varier comme un facteur expérimental séparé.

La première grille complète peut coûter cher ; un plan partiel équilibré sert à estimer les tendances, avec répétitions et points de confirmation. Réserver des configurations pour vérifier l'extrapolation. Les exposants d'une loi de puissance resteront empiriques, limités à la plage observée. Ne pas leur faire prédire mécaniquement une capacité future à une taille mille fois supérieure.

Livrable : courbes loss/capacité/données/diversité et diagnostic d'optimisation. **État :** programme proposé, développé au document 05.

Étape 8 Tester le transfert et les événements rares

Évaluer des actifs et familles réservés, puis des périodes non utilisées. Les observations d'une même crise sur cent actifs partagent un contexte ; elles ne donnent pas cent crises indépendantes. Les intervalles d'incertitude doivent respecter la dépendance en blocs temporels et entre actifs.

Tester la calibration, les queues et les dépendances de trajectoire séparément. Une moyenne favorable peut cacher un échec sur une famille. Une mauvaise moyenne sur un régime nouveau ne dit pas automatiquement si le langage est mauvais : étudier l'information manquante, la représentation et l'adaptation autorisée.

Livrable : rapport de transfert et de robustesse, y compris résultats négatifs. **État :** futur.

Étape 9 Confirmer avec des observations futures

Enregistrer les distributions avant que leurs cibles ne soient observées. Geler les versions, la fréquence des rapports et les critères d'analyse. Une prévision postérieurement reconstruite à partir d'une archive actuelle ne remplace pas cette étape.

Livrable : expérience prospective de prévision, reproductible et datée. **État :** futur. Son rôle est scientifique : mesurer hors des choix rétrospectifs de la recherche.

Étape 10 Mettre à jour les documents après chaque expérience

Pour chaque itération, conserver la version précédente puis mettre à jour la synthèse, le papier, l'atlas, la faisabilité, le tutoriel, le panel et les sources. Ajouter un rapport distinguant prévu, exécuté, observé et interprété. Tout amendement indique son motif et ce qui avait déjà été vu au moment du changement.

Le journal d'expérience doit permettre de répondre à trois questions : quelle observation a fait changer d'avis ; quelle explication concurrente reste possible ; quelle expérience pourrait la départager ? Cette pratique rend les documents révisables et utiles, au lieu de les transformer en conclusions figées.

TRAME - Validation scientifique, panel critique et programme d'échelle

14 octobre 2026. Version révisée selon le recadrage scientifique du projet. Les prix réels bruts, la généralisation entre actifs et temporalités, et l'apprentissage par GPT constituent le cœur de l'étude. Le panel est simulé ; les échanges entre agents logiciels sont identifiés séparément. Les expériences proposées ne sont pas présentées comme réalisées.

1. Contrat scientifique de cette version

L'objet est de comprendre ce qu'un modèle génératif peut apprendre des structures du marché, depuis des observations à la seconde jusqu'à une histoire longue, sur plusieurs familles d'actifs. Les métaux, indices, devises et autres marchés ne doivent pas être traités comme de simples copies de la crypto. Leurs unités, calendriers, sources et fréquences de publication font partie de la définition des observations.

Le choix prioritaire est un Transformer décodeur causal de type GPT. Il n'est pas nécessaire qu'un RNN ou une régression réussisse auparavant pour que cette hypothèse mérite une expérience. Les modèles simples sont des repères pour mesurer un gain ; ils ne décident pas du potentiel ultime d'un langage. Une erreur de reconstruction, un échec à petite capacité et une absence d'amélioration avec beaucoup de données sont trois résultats différents.

Les critères de cette version portent exclusivement sur la validité de l'information, la prévision probabiliste, la représentation, le transfert et les lois d'échelle. Une plage de calcul bornée fixe ce que nous pouvons mesurer ; elle ne fixe pas une limite arbitraire à ce qui pourrait être appris au-delà. La note théorique intégrée à partir de la section 5 fournit les équations, les expériences et les conditions d'invalidation.

2. Dix profils fictifs pour une contradiction structurée

Aucun des profils suivants n'est une personne interrogée. Ce sont des rôles imaginaires qui organisent des objections complémentaires. Leurs arguments sont rédigés par l'assistant ; ils ne constituent ni dix avis indépendants ni une revue par les pairs.

Profil fictif	Compétence et usage du projet	Objection centrale	Preuve qu'il demanderait
Léa, probabiliste et théoricienne de l'information	Étudie ce qui peut être conservé par une transformation du passé et prédit par une distribution conditionnelle.	« Un plateau d'un réseau ne mesure pas l'entropie irréductible du processus. »	Une décomposition des risques, des hypothèses explicites et une distinction entre borne mesurée et limite démontrée.
Malik, chercheur en Transformers génératifs	Conçoit des GPT qui apprennent des séquences numériques à plusieurs tailles et longueurs de contexte.	« Une langue peut être difficile pour le petit réseau et devenir efficace quand sa capacité augmente. »	Croisement langue × capacité, optimisation qualifiée, courbes complètes et cellules supérieures réservées à la vérification.
Nadia, statisticienne des plans d'expérience	Veut attribuer un gain à une cause et estimer la précision de cette attribution.	« Si modèle, données, contexte et budget changent simultanément, le résultat n'explique rien. »	Plan factoriel, comparaisons appariées, réplications, tests extérieurs et registre des choix.

Profil fictif	Compétence et usage du projet	Objection centrale	Preuve qu'il demanderait
Inès, spécialiste des observations de marché	Réconcilie prix publiés, timestamps, unités, calendriers et modifications historiques entre sources.	« Une seconde dans un fichier n'est pas nécessairement une nouvelle mesure du prix. »	Provenance, fréquence réelle, masques de disponibilité, distinction entre valeur inchangée, valeur maintenue et absence d'observation.
Clément, physicien des systèmes complexes	Recherche des régularités communes, des états latents et des transitions de régime.	« Un latent utile n'est pas nécessairement l'unique état causal du marché. »	Hypothèses d'identifiabilité, prédictions réfutables et bénéfice de transfert au-delà d'une visualisation de clusters.
Jonas, chercheur en apprentissage multilingue et multitâche	Examine les actifs comme langues ou dialectes et mesure les gains de partage.	« Ajouter des domaines peut aider la généralisation ou créer du transfert négatif. »	Courbes de quantité locale, familles entièrement exclues, mêmes budgets et scores par domaine.
Mei, chercheuse en séries temporelles à haute résolution	Étudie les dépendances entre observations rapprochées et l'effet du choix d'horloge.	« Davantage de points très corrélés ne remplace pas une histoire plus diverse. »	Comparaison de durée, résolution et contexte ; horizons calendaires communs ; absence de données fines inventées par interpolation.
Sara, responsable de reproductibilité scientifique	Cherche à reproduire chaque courbe d'échelle et chaque représentation avec les mêmes observations.	« Un codebook, une partition ou un schedule modifié silencieusement suffit à changer la conclusion. »	Versions, hashes, règles d'ajustement, seeds, exposition réelle aux données et conservation des essais non retenus.
Georges, historien quantitatif des marchés	Compare les mécanismes et régimes sur des périodes longues et plusieurs classes d'actifs.	« Une décennie et une famille ne constituent pas un univers représentatif de toutes les structures possibles. »	Calendriers et familles exclus, corpus décrit par mécanismes et périodes, limites explicites des généralisations.
Élodie, porteuse du projet et lectrice non spécialiste	Veut comprendre pourquoi une expérience réussit, échoue ou reste indéterminée sans devoir accepter un jargon comme preuve.	« Comment distinguer un mauvais alphabet, un modèle trop petit et un futur simplement encore mal expliqué ? »	Expériences qui isolent ces causes, résultats en prix compréhensibles et formulation précise de ce qui est acquis ou encore ouvert.

3. Six cycles conceptuels de contradiction

Les cycles ci-dessous constituent une structuration explicite du raisonnement et de ses révisions. Ils ne simulent pas des résultats de calcul. Les objections attribuées aux profils sont fictives ; les décisions de conception sont les recommandations du dossier.

Cycle 1 - Passer de l'analogie à une question mesurable

Hypothèse : une succession de prix peut être apprise comme une succession de mots.

Objections simulées : Léa demande quelle variable est prédite et quelle information est disponible ; Élodie demande ce qui compterait comme une réussite. Malik rappelle que l'architecture GPT peut être utilisée sans mots français ni tokenizer linguistique.

Révision : définir une distribution de futurs prix conditionnée par un passé admissible ; conserver une cible commune pour comparer les langues. L'analogie guide une architecture et un objectif d'apprentissage, mais ne démontre pas l'existence d'une grammaire universelle.

Inconnue : quelles structures du corpus seront apprises et transférables ?

Cycle 2 - Séparer information conservée et facilité d'apprentissage

Hypothèse : la meilleure langue est celle qui reconstruit le mieux les prix.

Objections simulées : Léa distingue réversibilité et suffisance prédictive ; Malik souligne qu'un encodage exact peut être difficile à apprendre ; Nadia demande une comparaison à capacité et histoire source définies.

Révision : garder un canal de prix brut exact comme référence, mesurer la perte des autres langues et comparer leurs courbes à plusieurs capacités. La reconstruction devient un diagnostic, jamais le classement final des facultés prédictives.

Inconnue : quelle compression élimine du détail inutile et laquelle supprime une information réellement prédictive ?

Cycle 3 - Rendre les temps et les corpus admissibles

Hypothèse : davantage de séries et des points à la seconde suffisent à fournir beaucoup plus de données.

Objections simulées : Inès distingue observations, remplissage et répétitions ; Mei distingue densité temporelle et histoire ; Sara relève les fuites par normalisation, segmentation et séries corrélées contemporaines.

Révision : enregistrer les temps de publication, la disponibilité et la résolution réelle ; employer des coupures calendaires globales ; compter séparément observations uniques, tokens présentés et périodes représentées. Une courbe quotidienne ne devient pas un historique réel à la seconde par interpolation.

Inconnue : quelle couverture fine et longue existe réellement pour chaque famille, et quel contexte le modèle peut-il exploiter ?

Cycle 4 - Mettre les langues et le marché latent en concurrence

Hypothèse : chaque actif constitue une langue, ou toutes les séries expriment un Marché latent commun.

Objections simulées : Jonas demande des tests de transfert et de transfert négatif ; Clément rappelle la non-identifiabilité possible du latent ; Georges réclame des familles et régimes réellement différents.

Révision : comparer modèles locaux, backbone partagé avec dialectes et représentation commune ; mesurer les courbes d'adaptation sur familles tenues à l'écart. Un latent partagé qui prédit bien peut être scientifiquement utile sans prétendre être l'état véritable et unique du marché.

Inconnue : quelle part des structures est commune, spécifique ou variable dans le temps ?

Cycle 5 - Ne pas condamner une langue avec un petit modèle

Hypothèse : une représentation faible dans le premier POC doit être écartée.

Objections simulées : Malik demande le contraste langue × capacité ; Nadia sépare quantité, diversité et optimisation ; Léa refuse d'identifier le plateau à une limite fondamentale.

Révision : conserver des langues contrastées dans plusieurs régimes de capacité et de données, qualifier l'entraînement, tester le contexte et réserver des cellules supérieures pour évaluer les extrapolations. Les modèles simples restent des contrôles de mesure ; ils ne disposent d'aucun droit de veto sur l'hypothèse GPT.

Inconnue : le classement des langues se stabilisera-t-il, se croisera-t-il, ou dépendra-t-il durablement de la famille et de l'horizon ?

Cycle 6 - Recadrage explicite vers la science des prix et de l'échelle

Nouvelle priorité de l'utilisateur : étudier les prix bruts de plusieurs marchés, leur histoire longue et leurs observations fines ; privilégier GPT ; garder ouvertes les hypothèses de langues distinctes et d'une structure latente commune.

Objections simulées : Georges refuse que la seule disponibilité initiale d'un corpus définisse tout l'objet scientifique ; Mei demande des temporalités réellement observées ; Élodie veut que la puissance de calcul ne soit ni ignorée ni invoquée comme promesse infinie.

Révision : le programme central devient l'étude des interactions représentation × capacité × quantité × diversité × contexte. Les critères portent sur information, généralisation, calibration, transfert et prédiction des lois d'échelle. Les budgets définissent une plage d'expérience ; les verdicts décrivent cette plage. Le prochain essai est choisi pour départager les explications restantes, sans abandon arbitraire ni certitude de réussite universelle.

Inconnue : quelles facultés apparaîtront à une autre échelle, avec quelles données et quelles limites ? La note intégrée ci-dessous fournit le dispositif pour répondre progressivement à cette question.

4. Ce qui a réellement été fait et ce qui reste proposé

Des agents logiciels ont effectivement mené des recherches bibliographiques, écrit des analyses distinctes et échangé des critiques. La relecture de l'article de conception a demandé de préciser le sens d'intégration du flow matching, la différence entre horizons événementiels et calendaires, et les informations nécessaires aux sorties étudiées. La relecture de l'atlas a contrôlé numériquement un exemple d'encodage et relevé les problèmes de références futures, de segmentation BPE et de réversibilité des langues parallèles.

Le présent recadrage a ensuite conduit à une nouvelle analyse théorique et à un plan factoriel. Les références primaires ont été consultées ; aucun corpus n'a été acquis et aucun modèle n'a été entraîné pour cette note d'échelle. Ces échanges logiciels peuvent partager des angles morts : ils ne remplacent pas des expériences, une réplication indépendante ou une revue académique.

Les équations qui suivent sont des identités sous hypothèses explicites ; les plages de modèle, nombres d'expériences et critères proposés restent à fixer dans un protocole avant exécution. Le panel organise la contradiction, mais seul le travail empirique permettra de départager les hypothèses.

5. La conclusion à préserver

L'échec d'un petit modèle ne réfute pas un langage. Il établit seulement qu'un certain couple représentation-modèle, entraîné avec certaines données, un certain contexte et un certain effort d'optimisation, n'a pas démontré la compétence recherchée dans le domaine testé.

La conclusion inverse serait tout aussi excessive : aucune observation ne garantit qu'un accroissement indéfini de puissance finira par rendre le futur entièrement prévisible. Un programme scientifique doit pouvoir distinguer les causes d'un plateau, quantifier les tendances, reconnaître ce qui reste indéterminé et concevoir l'expérience suivante qui départagera les explications.

L'objectif proposé est donc double : apprendre une distribution des futurs prix et découvrir une représentation transférable des structures du marché. On peut tester si chaque actif se comporte comme une langue distincte, si plusieurs familles partagent des dialectes, ou si les séries observées sont des expressions partielles d'un état latent commun. Ces trois possibilités deviennent des hypothèses concurrentes, et non des métaphores tenues pour vraies.

6. Objet scientifique : les prix observés et leur histoire

Notons X l'ensemble du passé admissible : prix bruts réellement observés, horodatages, instrument, unité, fréquence de publication, calendrier de session et masque de disponibilité. Notons Y une trajectoire future définie à une résolution et à des horizons annoncés avant l'expérience. Le modèle apprend une distribution `q(Y | X)`.

La donnée canonique reste le prix brut tel qu'il est publié. L'encodeur peut recevoir un entier décimal exact, des chiffres, des segments de valeurs ou d'autres représentations ; les sorties sont ramenées à la même variable Y pour l'évaluation. Préserver les prix bruts ne signifie pas ignorer leur unité : 100 points d'indice, 100 unités monétaires d'or et un taux de change de 100 ne sont pas la même observation.

Une fréquence de stockage d'une seconde ne prouve pas une nouvelle observation chaque seconde. Une valeur répétée peut être une cotation inchangée, une publication plus lente maintenue à l'écran, une session fermée ou une source interrompue. Le modèle doit distinguer ces situations. Il n'est pas admissible de transformer un historique quotidien ancien en observations « réelles à la seconde » par interpolation, puis de compter ces valeurs comme de nouvelles données.

Un corpus long et un corpus fin répondent à des questions complémentaires. Les données anciennes renseignent des régimes et transitions ; les observations à la seconde révèlent des structures locales. L'architecture peut combiner des fenêtres fines et des descriptions plus lentes de l'histoire, sans prétendre que toutes les résolutions existent sur toute la durée.

7. Une décomposition mathématique de la difficulté

7.1 Décomposition exacte sous score logarithmique

Fixons une représentation `Z = e_R(X)`, où R désigne la langue. Tous les éléments auxiliaires nécessaires à son interprétation doivent être inclus dans Z. Pour une cible discrète Y évaluée sur une grille commune, et sous les conditions d'intégrabilité usuelles :

`E[-log q(Y|Z)] = H(Y|X) + I(Y;X|Z) + E_Z KL(p(Y|Z) || q(Y|Z)).`

Cette identité s'obtient en ajoutant puis retranchant `log p(Y|Z)` dans le score, et en utilisant `H(Y|Z) - H(Y|X) = I(Y;X|Z)` lorsque Z est une fonction de X.

Terme	Interprétation	Ce qu'il faut éviter d'en conclure
`H(Y|X)`	Incertitude restante compte tenu des observations X choisies	Ce n'est pas une propriété métaphysique du marché ; d'autres observations pourraient la réduire.
`I(Y;X|Z)`	Information sur Y perdue lorsque le passé X devient la représentation Z	Une mauvaise reconstruction de X ne signifie pas nécessairement une grande perte sur Y.
`E KL(p(Y|Z)||q(Y|Z))`	Écart du prédicteur appris à la meilleure distribution accessible à partir de Z	Il mêle capacité, données, optimisation et choix de modèle ; un seul essai ne les sépare pas.

L'identité suppose **la même cible et la même mesure**. On ne peut pas remplacer le premier membre par des perplexités provenant de vocabulaires financiers différents puis comparer leurs valeurs directement. Pour une cible continue, on travaille avec des densités par rapport à une mesure commune, et des entropies différentielles éventuellement négatives ; les transformations de cible exigent leurs Jacobiennes. Une solution plus facile à auditer consiste à convertir toutes les prévisions en probabilités sur les mêmes intervalles de prix, avec résolution documentée.

Ces identités appliquent les notions d'entropie et d'information ; leur interprétation ne fournit pas un estimateur magique des trois termes. Shannon, théorie de l'information. Les scores propres donnent un cadre pour évaluer les distributions sans récompenser des probabilités volontairement déformées. Gneiting et Raftery, 2007.

7.2 Une version sous erreur quadratique

Si Y est un prix futur scalaire de second moment fini, posons `m_X = E[Y|X]` et `m_Z = E[Y|Z]`. Alors :

`E[(Y-f(Z))²] = E[Var(Y|X)] + E[(m_X-m_Z)²] + E[(m_Z-f(Z))²]`.

L'orthogonalité des espérances conditionnelles fait disparaître les termes croisés. Cette version illustre bien les trois niveaux, mais ne mesure que la prévision de moyenne. Une représentation peut conserver la moyenne conditionnelle tout en perdant de l'information sur variance, asymétrie ou dépendances entre horizons. Une étude de distributions ne doit donc pas se limiter à la MSE.

7.3 Ce que capacité, données et optimisation ajoutent

Soit `Q_N` une famille de GPT de capacité N, avec représentation R fixée. La meilleure perte théorique dans cette famille vaut `inf_(q dans Q_N) E[-log q(Y|Z)]`. L'écart à `H(Y|Z)` est une erreur d'approximation de la famille.

Le modèle effectivement entraîné subit ensuite l'effet d'un échantillon fini et d'un algorithme d'optimisation. Ces effets se diagnostiquent par interventions expérimentales. Il serait incorrect d'écrire sans conditions une somme de trois erreurs toutes positives « capacité + estimation + optimisation » : un algorithme qui ne minimise pas parfaitement la perte empirique peut mieux généraliser grâce à sa régularisation implicite. La différence de risque entre un modèle optimisé et le minimiseur empirique exact n'est pas nécessairement positive.

On peut toutefois mesurer des contrastes contrôlés : changer N à corpus fixe ; changer le corpus à N fixe ; prolonger l'optimisation à N et corpus fixes ; répéter avec plusieurs initialisations ; modifier seulement la représentation. Le plan factoriel sert à séparer ces effets et leurs interactions.

7.4 Pourquoi un plateau ne mesure pas l'incertitude irréductible

La perte d'un prédicteur donne, au mieux et sous incertitude d'estimation, une **borne supérieure** de la meilleure perte possible à partir des observations. Elle ne fournit pas une borne inférieure certifiant qu'aucun meilleur modèle ne pourrait faire mieux.

De nombreuses lois du futur peuvent être compatibles avec une même histoire finie. Sans hypothèses sur la famille de processus, une période sans amélioration ne prouve ni hasard fondamental ni absence d'une structure inaccessible au modèle essayé. Il faut donc utiliser le terme **plancher observé dans le régime expérimental**. Le paramètre de plateau d'une loi ajustée ne doit pas être rebaptisé « entropie véritable du marché ».

8. Quatre questions différentes sur le langage

Réversibilité

Une langue exacte, munie de son état auxiliaire, peut conserver intégralement l'information de X. Cela ne la rend pas facile à apprendre. Des prix encodés chiffre par chiffre peuvent être réversibles mais nécessiter des dépendances différentes d'une projection numérique. Inversement, une représentation compacte avec perte peut rendre une structure plus accessible à un modèle fini.

Suffisance prédictive

L'idéal est `Y indépendant de X conditionnellement à Z`, équivalent ici à `I(Y;X|Z)=0`. Cela signifie que la langue conserve l'information pertinente pour Y, sans devoir conserver chaque détail de X. Une bonne reconstruction est un diagnostic utile, pas une preuve de suffisance prédictive.

Accessibilité à capacité finie

Deux langues théoriquement équivalentes peuvent demander des tailles de réseau différentes. Une langue peut perdre avec 8 millions de paramètres et gagner avec 128 millions. Il faut donc rechercher une interaction **langue × capacité**, plutôt que classer une fois pour toutes les langues avec un seul petit modèle.

Transfert

Une représentation peut mieux généraliser vers une nouvelle famille d'actifs ou une fréquence différente, tout en étant moins bonne sur la famille dominante du corpus. Le classement dépend de la tâche annoncée. Une moyenne globale ne doit pas masquer une détérioration sur un domaine tenu à l'écart.

9. Comment distinguer empiriquement les causes d'un plateau

Explication candidate	Intervention prioritaire	Observation compatible	Ce qu'elle ne prouve pas
Information perdue par le langage	Ajouter le résidu exact ou une vue brute au même encodeur ; comparer plusieurs capacités	Gain persistant des informations omises	La quantité exacte d'information conditionnelle perdue ; une vue supplémentaire peut aussi faciliter l'optimisation.
Capacité insuffisante	Augmenter N sur même corpus et même contexte, avec optimisation qualifiée	Meilleure perte extérieure et écart de langue qui se réduit ou s'inverse	Qu'une progression continuera indéfiniment.
Quantité insuffisante	Ajouter des observations uniques, même mélange et mêmes périodes admissibles	Courbe de généralisation qui progresse à N fixé	Que répéter les mêmes observations fournirait le même gain.
Diversité insuffisante	Remplacer une part du corpus par d'autres familles à volume et temps comparables	Meilleur transfert vers familles exclues	Que chaque domaine bénéficie du mélange.
Histoire trop courte	Augmenter l'histoire visible en distinguant résolution et durée	Gain à capacité comparable, surtout sur certaines dépendances	Que tout le passé lointain est utile ou stationnaire.
Optimisation insuffisante	Temps d'entraînement accru, schedule qualifié, contrôles d'initialisation	Baisse encore substantielle des pertes de développement	Que le langage était dépourvu d'information.
Changement de distribution	Évaluer plusieurs origines temporelles et groupes de régimes	Variations structurées des gains selon les périodes	Un plafond fondamental de prévisibilité.
Plafond non identifié	Tous les contrastes mesurés deviennent petits et précis	Saturation empirique dans la plage testée	L'atteinte démontrée du risque de Bayes.

Les tests de résidu doivent être conçus avec soin. Réencoder une vue brute en parallèle ajoute aussi des paramètres ou des chemins d'optimisation. Ajouter un canal neutre de taille comparable, maintenir l'effort de

réglage et répéter sur plusieurs capacités aide à isoler l'information supplémentaire. Aucun contrôle unique n'identifie parfaitement la cause.

10. Ce que les travaux d'échelle apportent réellement

Source primaire	Résultat pertinent	Limite pour TRAME
Kaplan et al., 2020	Relations empiriques entre perte, paramètres, données et calcul pour des modèles de langage	Les exposants et allocations ne se transfèrent pas automatiquement aux prix.
Hoffmann et al., 2022	Étude de l'allocation du calcul entre nombre de paramètres et quantité de tokens ; les grands réseaux peuvent être insuffisamment entraînés	Le ratio de tokens par paramètre n'est pas une constante universelle.
Muennighoff et al., 2023	La répétition peut aider dans un régime limité en données, avec valeur marginale décroissante	Des époques répétées ne deviennent pas des années nouvelles de marché.
Edwards et al., 2024-2025	Des Transformers décodeurs temporels présentent des relations d'échelle sur un corpus hétérogène	Ce n'est pas une démonstration d'une loi universelle pour toute famille de prix et toute fréquence.
Yao et al., ICLR 2025	Étudie les comportements dans et hors distribution ; l'architecture influence l'échelle	Le choix GPT est défendable comme axe de recherche, mais sa supériorité générale n'est pas acquise.
Dai et al., prépublication du 4 octobre 2026	Étudie l'interaction de capacité, contexte et horizon ; propose une loi ajustée et une analyse théorique sous régression gaussienne	Travail très récent, hypothèses particulières ; aucune certification d'un plafond des marchés.

Liens : Kaplan, Hoffmann, Muennighoff, Edwards, version 2, Yao, version 3, Dai, version 1.

Le programme principal peut donc utiliser un **Transformer décodeur causal de type GPT**, sans exiger qu'un RNN réussisse d'abord. Les références simples restent des instruments de mesure : leur victoire sur une petite expérience ne ferme pas l'hypothèse d'un modèle de fondation. Une comparaison d'architecture secondaire peut venir ensuite, à données et calcul documentés.

11. Le marché latent commun comme hypothèse mesurable

11.1 Trois organisations concurrentes

M1 - Langues distinctes. Des modèles ou adaptateurs apprennent surtout des dynamiques propres à chaque actif ou famille. Un apprentissage commun n'apporte qu'un gain faible, voire provoque un transfert négatif.

M2 - Grammaire partagée et dialectes. Un backbone GPT apprend des régularités communes ; des identités, embeddings, têtes ou adaptateurs portent les unités, calendriers et particularités locales. Le bénéfice du partage dépend de la famille et de la quantité de données locales.

M3 - État latent commun. Les observations sont engendrées par un état partagé et des composantes spécifiques :

```
S_(t+1) ~ p(S_(t+1)|S_<=t)
```

```
U_(i,t+1) ~ p_i(U_(i,t+1)|U_(i,<=t),S_<=t)
```

$P_{i,t} \sim g_i(S_t, U_{i,t}, \text{metadata}_i)$.

Ce modèle est un cadre d'hypothèses. Rien n'impose que S soit unique, de faible dimension, stationnaire ou parfaitement identifiable. Les marchés peuvent partager certains facteurs tout en conservant des composantes indépendantes et des couplages qui changent.

11.2 Une bonne représentation n'est pas l'état « vrai »

Si une transformation inversible change les coordonnées du latent et que le décodeur compense, les observations peuvent rester identiques. La qualité prédictive ne sélectionne donc pas nécessairement une interprétation unique de S. Les résultats sur la non-identifiabilité des représentations désentrelacées sans hypothèses supplémentaires renforcent cette prudence ; ils ne constituent pas un théorème spécifique aux marchés. Locatello et al., ICML 2019.

Le terme « latent commun » devrait désigner une structure transférable et utile aux tâches mesurées. Prétendre avoir retrouvé la cause réelle des prix exigerait d'autres hypothèses et d'autres preuves.

11.3 Expériences de séparation

1. **Apprentissage local contre partagé.** Comparer performances par domaine avec budget total documenté et effort de réglage comparable. Rapporter aussi les paramètres actifs par prévision : huit modèles distincts de N paramètres ne coûtent pas la même chose qu'un seul modèle de N.
2. **Courbe de données locales.** Adapter un modèle partagé à une famille tenue à l'écart avec plusieurs quantités de données locales ; comparer au même GPT initialisé aléatoirement. Un gain régulier à faible quantité soutient une représentation transférable.
3. **Famille entière exclue.** Garder, par exemple, les métaux, les indices ou le change hors préentraînement selon le fold. Des actifs proches d'une même famille ne suffisent pas à prouver une universalité.
4. **Calendrier global exclu.** Aucune série corrélée ne doit révéler au préentraînement les dates futures utilisées comme test. La séparation entre actifs ne remplace pas la séparation dans le temps.
5. **Perturbation de l'identité.** Masquer ou permuter les identifiants en conservant les unités nécessaires ; examiner la baisse de performance. Une dépendance à l'identité peut être légitime, mais elle doit être distinguée de la mémorisation d'une période.
6. **Ablation du contexte d'autres actifs.** Autoriser uniquement les observations déjà publiées. Mesurer le gain des autres séries, puis la sensibilité à des délais réalistes de publication. Un lien d'attention n'est pas une preuve causale.

Une réussite soutiendrait M2 ou une version opérationnelle de M3. Une absence de gain dans un petit régime ne prouverait pas M1 à toutes les échelles ; elle préciserait où le partage n'a pas encore apporté d'avantage.

12. Plan factoriel à budget borné

Le plan suivant est une **proposition dimensionnelle**, pas une réservation de ressources ni une exigence de disposer déjà de ces volumes. Ses niveaux peuvent être réduits avant toute expérience si la couverture réelle ne les permet pas. L'important est de conserver les contrastes, de publier la plage explorée et de ne pas transformer une limite de budget en loi scientifique.

12.1 Axes à mesurer séparément

Axe	Symbole	Mesure à publier
Langue	R	Représentation exacte ou avec perte, vocabulaire, longueur, état auxiliaire

Axe	Symbole	Mesure à publier
Capacité	N	Paramètres totaux, hors embeddings et actifs par prédiction
Quantité unique	U	Identifiants d'observations sources uniques réellement rencontrées
Exposition d'entraînement	T	Tokens traités, répétitions et chevauchements de contexte inclus
Diversité	M	Familles, instruments, années, sessions et régimes représentés
Contexte	K et durée	Nombre d'observations, nombre de tokens et durée réelle du passé
Résolution	delta_t	Fréquence d'observation réelle, pas seulement fréquence du fichier
Calcul	C	FLOPs estimés, durée, matériel, mémoire et efficacité observée
Optimisation	O	Algorithme, schedule, batch, précision, critères d'arrêt et instabilités

Une quantité d'observations U n'est pas un effectif statistique indépendant. Des fenêtres répétées, des actifs corrélés et plusieurs agrégations d'un même intervalle augmentent T sans créer autant d'épisodes nouveaux. Ne pas inventer un unique « nombre effectif de tokens » censé résoudre toutes ces dépendances ; publier plusieurs dimensions de couverture.

12.2 Bloc A - Langue × capacité × quantité

Choisir **trois langues suffisamment définies**, dont un canal de prix brut à précision source, une représentation réversible ou quasi réversible avec son état auxiliaire et une représentation volontairement comprimée. Ce ne sont pas trois vainqueurs présélectionnés par les résultats d'un petit prédicteur.

Proposition de niveaux GPT : **8, 32 et 128 millions de paramètres**. Proposition de quantités uniques : **10, 40 et 160 millions d'observations sources**, si des données réelles adéquates existent. Mélange de familles, contexte calendaire, périodes et objectifs fixés. Les volumes inférieurs doivent être construits comme sous-ensembles imbriqués et équilibrés du plus grand, sans réduire silencieusement le nombre de familles.

Le croisement `3 langues × 3 capacités × 3 quantités × 2 initialisations` donne **54 entraînements**. Il permet de mesurer un changement de classement des langues avec N ou U. Deux initialisations constituent un minimum de diagnostic, pas une estimation précise de toute la variabilité ; une troisième est réservée à des comparaisons décisives et compte comme essai supplémentaire.

Si ce plan dépasse le budget, un premier bloc `3 langues × 2 capacités × 2 quantités × 2 initialisations` donne **24 entraînements**, puis des niveaux intermédiaires ou supérieurs sont ajoutés selon la question la moins identifiée. Ce plan réduit ne permet pas d'annoncer des exposants asymptotiques fiables. Il sert à choisir l'expérience suivante.

12.3 Bloc B - Quantité contre diversité

Au niveau intermédiaire de N et de U, comparer un corpus concentré et un corpus diversifié, de même volume unique et de mêmes périodes admissibles, pour les trois langues et deux initialisations : **12 entraînements au maximum**, dont certains peuvent être partagés avec le bloc A si les conditions sont identiques.

Pour isoler l'effet de diversité, tenir fixe la dose de données d'un domaine cible et remplacer une quantité égale de données auxiliaires par d'autres familles. Une seconde comparaison peut tenir fixe le volume total en réduisant la dose du domaine dominant. Ces deux questions ne doivent pas être confondues.

Les mots « diversifié » et « concentré » doivent être définis par les proportions de familles et de périodes, pas par le seul nombre de symboles. Cent séries très corrélées à la même date ne constituent pas la même intervention que plusieurs mécanismes de cotation sur des décennies.

12.4 Bloc C - Capacité contre histoire visible

Pour deux langues contrastées, deux capacités et trois durées de contexte, avec deux initialisations : **24 entraînements au maximum**, à retrancher des doublons exacts avec le bloc A. Choisir les niveaux de contexte en durée réelle et en résolution, puis publier leur traduction en tokens pour chaque langue.

À une seconde, 1 024 observations ne couvrent qu'environ 17 minutes ; ce n'est pas une histoire longue. Une variante hiérarchique peut montrer le passé récent à la seconde et des fenêtres plus anciennes à la minute, à l'heure ou au jour. Elle ajoute une hypothèse d'agrégation qu'il faudra comparer à une fenêtre unique, en gardant explicite la perte de précision ancienne.

Le bloc A peut employer un contexte fixe relativement modeste pour maîtriser le croisement N×U ; le bloc C teste précisément si ce choix limitait les langues ou les grandes capacités. Un plateau au bloc A ne doit pas être proclamé plafond du modèle avant ce contraste.

12.5 Plafond d'essais et d'effort

Le programme complet comporte au plus **90 entraînements de base** avant mutualisation des cellules identiques : 54 + 12 + 24. Un budget de réplications, de qualifications d'optimiseur et d'extensions doit être annoncé séparément. Les chiffres proposés bornent le programme de mesure ; ils ne sont pas des règles d'arrêt du phénomène étudié.

Une approximation courante du calcul d'un Transformer dense est proportionnelle à $N \times T$, parfois résumée par $6NT$ pour l'entraînement. Ce n'est qu'un ordre de grandeur : coût d'attention avec longues séquences, embeddings, projections, pertes et matériel modifient la facture. Utiliser les FLOPs ou temps réellement mesurés pour les comparaisons finales. Le nombre de tokens varie selon la langue ; égaliser seulement T pourrait donner à l'une beaucoup moins de temps de marché.

Deux résultats doivent donc coexister : **à même histoire source et même capacité**, puis **à même budget de calcul**. Le premier étudie l'accessibilité d'une information ; le second l'efficacité d'un système. Aucun ne remplace l'autre.

13. Qualification de l'entraînement avant conclusion sur le langage

Pour chaque taille, qualifier le domaine raisonnable du taux d'apprentissage et du batch avec un petit budget commun de développement. Conserver la même règle de qualification entre langues ; une seule architecture mal réglée ne doit pas condamner la représentation qu'elle utilise. Rapporter le nombre de réglages essayés, y compris ceux qui divergent.

Comparer courbes de pertes train et développement, gradient, instabilités numériques, sensibilité à l'initialisation et réponse à une prolongation d'entraînement. Une perte train élevée peut venir d'une limite de capacité, d'une optimisation insuffisante ou d'une cible difficile. Une faible perte train et une forte perte extérieure suggèrent plutôt estimation, décalage ou fuite, sans identifier automatiquement une cause unique.

Des checkpoints précoces ne sont pas toujours substituables à des entraînements courts dont le schedule a été conçu pour un budget plus faible. Une comparaison d'échelle doit contrôler cette différence. Les politiques d'arrêt et de schedule ne doivent pas varier librement après consultation du résultat attendu.

Les réplications doivent partager, lorsque possible, les mêmes partitions, périodes et tirages de sous-corpus. Elles comparent des méthodes sur les mêmes difficultés. Un journal conserve toutes les expositions de données et les décisions de sélection.

14. Mesures scientifiques communes

14.1 Scores sur la même variable

- Score logarithmique sur probabilités de mêmes cellules de prix ou densités correctement transformées.
- CRPS sur le prix futur, avec unités de l'instrument affichées ; comparaisons entre actifs par scores relatifs à une référence commune ou par pondération fixée avant test.
- Calibration des probabilités et couverture/largeur des intervalles.
- Qualité des distributions à plusieurs horizons et des dépendances de trajectoire : distribution de maximum, minimum et amplitude, ordre de franchissement de niveaux prédéfinis, corrélations entre pas futurs.
- Robustesse à des familles exclues, nouvelles périodes et résolutions différentes.

La dernière valeur et une distribution empirique historique constituent des références de mesure. À une seconde, prédire beaucoup de prix inchangés peut être facile ; publier la probabilité de changement et la distribution conditionnelle de son amplitude évite qu'une métrique globale cache cette difficulté. Le sous-ensemble où le prix changera n'est connu qu'après coup : il peut servir au diagnostic, pas à choisir les instants de prévision.

L'évaluation en prix brut doit rester centrale. Une métrique normalisée sert à comparer des unités différentes ; elle n'impose pas que l'entrée du GPT soit elle-même normalisée. Les constantes de normalisation de score sont apprises sur le passé autorisé, jamais sur le test futur.

14.2 Tester la langue, pas seulement le style de sortie

Une image plausible ou une série lisse ne prouve pas une bonne distribution conditionnelle. Une génération inconditionnelle qui reproduit des statistiques historiques et une prévision du futur effectivement observé sont deux tâches distinctes. Il faut tester l'apport du contexte : masque, contexte provenant d'une autre période, contexte lointain, contexte véritable, toujours avec contrôles de dépendance adaptés.

Si toutes les langues convergent vers le même score extérieur à capacité suffisante, elles peuvent rester très différentes en efficacité ou en stabilité. Si leurs classements se croisent, le croisement est un résultat scientifique à conserver. Le concours ne doit pas éliminer à faible N la langue dont la question centrale est précisément l'effet d'une plus grande capacité.

14.3 Incertitude et sélection

Les comparaisons sont appariées sur les mêmes instants. Rééchantillonner des blocs temporels qui conservent ensemble les actifs contemporains ; publier la sensibilité à la longueur de blocs et la dispersion entre périodes. Une distribution non stationnaire ne devient pas stationnaire parce qu'on a appliqué un bootstrap.

Garder une grille de développement pour choisir les expériences, puis des périodes et familles extérieures pour évaluer les conclusions annoncées. Le nombre total de variantes, architectures, langues et métriques explorées doit être visible. Une identité de source exclue du train ne protège pas contre un choc historique déjà vu dans d'autres séries.

15. Ajuster une loi d'échelle sans transformer l'extrapolation en vérité

Une forme de départ est :

```
L_R(N,U) = A_R + B_R N^(-alpha_R) + D_R U^(-beta_R).
```

C'est une hypothèse de modèle statistique, pas une loi physique. Elle ignore notamment contexte, diversité, répétition, optimisation et interactions. Une extension peut inclure ces facteurs, mais ajouter plus de paramètres que les contrastes ne permettent d'identifier produit une formule décorative.

Pratiques proposées :

1. Ajuster d'abord des tendances locales et une forme en puissance simple ; montrer les résidus et incertitudes.
2. Réserver une ou plusieurs cellules à plus grande capacité/quantité pour tester l'extrapolation avant d'utiliser toute la grille pour ajuster la loi.
3. Comparer une forme avec et sans plateau estimé ; vérifier si A_R change fortement quand un niveau est retiré.
4. Rapporter des intervalles sur les gains prévus au **prochain facteur d'échelle**, sans extrapoler plusieurs ordres de grandeur à partir de trois tailles.
5. Traiter un échec de prédiction de la cellule réservée comme une réfutation de la forme ajustée dans ce domaine, pas comme une réfutation du langage.

Les choix de fonction, de points ajustés et d'optimisation modifient parfois fortement les conclusions d'une étude d'échelle. Une analyse méthodologique récente insiste sur cette sensibilité et la documentation nécessaire. (Mis)Fitting: A Survey of Scaling Laws.

16. Critères scientifiques de révision, sans arrêt arbitraire

16.1 Ce qui peut être invalidé nettement

Affirmation	Condition qui l'invalide ou impose une correction
« Cette langue est réversible »	Deux entrées différentes deviennent indiscernables avec tout l'état déclaré, ou l'inverse ne restitue pas la précision annoncée.
« Le modèle n'a pas vu le futur »	Une valeur, normalisation, tokenisation, segmentation ou série corrélée introduit des dates non admissibles.
« La langue R est supérieure dans la plage étudiée »	La supériorité disparaît dans les réplications et tests annoncés, ou le classement s'inverse selon des cellules omises de la conclusion.
« La croissance de capacité améliore le score dans cette plage »	Une comparaison qualifiée et suffisamment précise exclut le gain minimal annoncé sur cette plage.
« Une représentation partagée transfère vers cette famille »	À budget et dose locale comparables, le gain extérieur annoncé est absent avec une précision suffisante ou le transfert est négatif.
« La loi ajustée prédit le niveau supérieur »	La cellule réservée sort systématiquement de la plage de prédiction documentée.
« Des capacités émergent brutalement »	La rupture disparaît avec un score continu approprié ou dépend d'un seuil de métrique choisi après résultat.

Une étude sur l'émergence montre que des seuils de métriques peuvent créer l'apparence d'un saut abrupt. Cela justifie des mesures continues et un examen des effets de seuil ; cela ne prouve pas que toute nouvelle capacité soit illusoire. Schaeffer, Miranda et Koyejo, 2023.

16.2 Gain absent, trop petit ou mal mesuré

Fixer un **gain minimal scientifiquement pertinent epsilon** avant de consulter le résultat : par exemple une amélioration de log-score dont l'amplitude serait distinguable du bruit de mesure et intéressante pour l'hypothèse d'échelle. Sa valeur doit être motivée par la question et la précision accessible, pas par un résultat que l'on espère faire passer.

- Si l'intervalle du gain reste large et inclut des améliorations substantielles, verdict **indéterminé** ; l'expérience suivante devrait réduire cette incertitude ou explorer l'axe confondu.
- Si l'intervalle entier se trouve dans une zone d'équivalence prédéfinie autour de zéro, conclure à une **absence de différence pertinente dans cette plage**.
- Si le gain existe mais sa pente décroît, conclure à une **progression mesurée avec rendement marginal réduit**, sans annoncer sa fin.
- Si le gain augmente avec N pour une langue auparavant faible, conserver l'hypothèse d'un besoin de capacité ; tester un niveau supérieur selon le budget de recherche.

Des consultations répétées d'intervalles ordinaires jusqu'à l'apparition d'un résultat favorable ne constituent pas un protocole valide. Fixer les bilans à l'avance ou utiliser une méthode séquentielle appropriée. La durée et les ressources d'un bloc bornent les connaissances produites ; elles ne décident pas de l'existence d'une structure au-delà.

16.3 Décider de l'expérience suivante

La décision doit être fondée sur la **valeur d'information** : quel contraste départagerait les explications restantes ? Si N et U étaient confondus, les séparer. Si la langue n'a pas accès à une histoire longue, agrandir l'histoire. Si la perte de reconstruction est massive, ajouter un résidu ou une vue exacte. Si le corpus est homogène, tester la diversité à volume constant. Si l'optimisation n'est pas qualifiée, la corriger avant d'acheter de la capacité supplémentaire.

Il est légitime de clôturer un bloc expérimental avec « hypothèse encore ouverte au-delà de la plage testée ». Ce n'est pas une conclusion d'impossibilité. Poursuivre peut signifier changer l'expérience pour apprendre davantage, plutôt que répéter aveuglément la même opération à une taille plus grande.

17. Questions de recherche prioritaires

1. **Existe-t-il une interaction robuste langue × capacité ?** C'est la protection la plus directe contre l'élimination prématurée d'un encodage.
2. **Le partage de familles réduit-il la quantité locale nécessaire ?** La courbe d'adaptation est plus informative qu'une victoire moyenne unique.
3. **Le contexte supplémentaire apporte-t-il de l'information ou seulement des répétitions ?** Séparer durée, résolution et tokens.
4. **Les prix bruts exacts deviennent-ils plus compétitifs avec la capacité ?** Le modèle pourrait apprendre lui-même des invariances qu'un petit réseau exige qu'on lui fournisse ; cette idée mérite un test.
5. **Quelles structures se transfèrent entre prix à la seconde et histoire longue ?** Une architecture hiérarchique peut aider, mais l'agrégation doit rester un choix expérimental explicite.
6. **Peut-on prédire le prochain palier d'échelle avant de l'entraîner ?** Une loi qui anticipe correctement une cellule réservée apporte plus de preuve qu'une courbe ajustée après coup à tous les points.
7. **Un latent partagé soutient-il des tâches multiples sans devenir une simple mémorisation d'identités et de dates ?** Le test doit exclure à la fois des familles et des calendriers.

18. Portée de cette note

Le programme recommandé respecte l'ambition d'un GPT des structures de marché. Il lui donne un dispositif pour apprendre de ses échecs sans les surinterpréter et pour mesurer ses progrès sans présupposer une puissance infinie. Les critères portent sur représentation, généralisation, transfert, incertitude et validité des lois d'échelle.

Les références vérifiées soutiennent l'existence de relations d'échelle dans des modèles séquentiels et temporels, ainsi que la nécessité d'expériences contrôlées. Elles ne démontrent ni la taille nécessaire pour TRAME, ni la quantité minimale universelle de données, ni l'identifiabilité d'un unique état latent du marché. Les expériences proposées sont précisément destinées à réduire ces inconnues, une par une.

État de l’art critique - du langage aux distributions de trajectoires de marché

Recherche principale bornée au 13 octobre 2026 ; compléments sur les sources de données et la disponibilité des poids vérifiés le 14 octobre 2026. Note de recherche, sans entraînement, sans expérience prédictive exécutée. Les performances citées sont celles des auteurs, pas des reproductions indépendantes. Cette revue ciblée ne constitue pas une recherche systématique exhaustive. Les pages évolutives sont décrites telles que consultées ; leur contenu actuel ne prouve pas qu’elles étaient identiques lors de la publication d’un article.

Conclusion scientifique

L’hypothèse « encoder des bougies comme des tokens, puis apprendre à prédire les tokens suivants » est réalisable et possède déjà une antériorité directe : Kronos. La version plus structurée « représenter gap, corps, mèches et volume puis générer une distribution de trajectoires » possède aussi une antériorité très récente : KiT. Le projet reste intéressant : la priorité de recherche est un langage de marché commun à plusieurs actifs et temporalités, dont on peut mesurer ce qu’il conserve, détruit et permet de généraliser. Un modèle fondation multi-marchés, éventuellement couplé à la microstructure et dépassant un milliard de paramètres, reste dans le périmètre si les données et les mesures de scaling le justifient. La disponibilité réelle des informations, la calibration du risque et l’utilité des représentations sont des hypothèses à tester, pas une invention déjà démontrée.

Le choix initial le plus défendable est un comparatif contrôlé de tokenizers et de modèles de taille modeste, suivi d’une montée en charge mesurée. Ces petites expériences servent à qualifier les erreurs, comparer plusieurs régimes d’échelle et estimer une loi de progression avant les dépenses massives ; elles ne fixent pas un plafond d’ambition. Les variantes nombreuses ne doivent pas toutes être optimisées sur le même jeu de test. Aucun résultat publié consulté ne prouve à lui seul la prévisibilité de tous les prix dans tous les régimes.

1. Les antériorités les plus proches

Kronos - Shi et al., 2025. Le papier décrit un autoencodeur de bougies OHLCVA, une quantification binaire sphérique avec sous-tokens grossier/fin, puis un Transformer causal autorégressif. Les auteurs annoncent plus de 12 milliards de bougies, 45 places et plusieurs fréquences. Le gain relatif de 93 % concerne un RankIC de prévision de séries de prix ; ce chiffre ne constitue pas une probabilité de prévoir correctement la prochaine variation. Les métriques de prix, de rendement terminal et de volatilité sont distinctes. L’échantillonnage produit plusieurs continuations possibles. L’annexe décrit le filtrage de segments atypiques : sa pertinence pour des crises de crypto doit être étudiée. Cette lecture couvre l’architecture, les métriques et plusieurs annexes, sans reproduction. Papier, sections 3, 4 et annexes B-D.

Le dépôt distingue aujourd’hui mini : 4,1 M paramètres et contexte 2 048 ; small : 24,7 M et contexte 512 ; base : 102,3 M et contexte 512. Large : 499,2 M figure dans la famille mais est indiqué non publié. Un tutoriel ne doit donc pas promettre le téléchargement de Large. Code et cartes small/tokenizer affichent MIT. Le tokenizer est un artefact distinct du prédicteur. L’accès à ces poids ne donne pas automatiquement les droits ni les fichiers de leur corpus complet. Dépôt officiel, carte small, carte tokenizer.

KiT - Zhang et Li, 28 septembre 2026. Cette prépublication est antérieure à la date de notre étude. Elle génère des trajectoires OHLCV par flow matching, avec représentation continue en log-ratios de gap, corps, mèches et volume, au lieu d’une quantification discrète. Trois tailles annoncées : 31, 101, 284 M. L’évaluation utilise entraînement jusqu’à fin 2023, validation 2024-2025 et test du 1er janvier au 10 avril 2026. Les auteurs annoncent un RankIC moyen de rendement de 0,0571. C’est une revendication récente, à reproduire. Leur

comparaison emploie notamment TimesFM sur clôtures univariées : elle ne prouve donc pas la supériorité contre toutes ses configurations multivariées. Papier, sections 3-4 et annexe A.

Le dépôt KiT consulté contient des dossiers de code, données et checkpoints, et déclare AGPL-3.0. La liste de tâches et les noms de checkpoints ne suffisent pas à établir la disponibilité, la provenance et les conditions de chaque poids. Ne pas remplacer cet audit par « le papier promet une publication ». Les licences des composants effectivement réutilisés devront être examinées séparément. Dépôt officiel et licence déclarée.

FinCast - Zhu et al., 2025. Le dépôt des auteurs décrit un Transformer à décodeur, une spécialisation par mélange d'experts et une perte combinant prédiction ponctuelle et probabiliste, préentraîné sur plus de 20 milliards de points financiers. C'est une autre antériorité à la spécialisation financière et aux quantiles. Nous avons consulté résumé et dépôt, pas validé le protocole complet ni les droits de chaque checkpoint. Résumé, implémentation officielle.

LENS, auparavant PLUTUS dans certaines bibliographies. L'identifiant arXiv 2408.10111 résout actuellement vers *LENS: Large Pre-trained Transformer for Exploring Financial Time Series Regularities*. Employer le titre courant tout en expliquant cette variation évite de compter artificiellement deux preuves indépendantes. La présente note ne reprend aucun chiffre de performance. Notice primaire actuelle.

DELPHYNE - Ding et al., 2025. Les auteurs examinent les limites du transfert de séries générales à la finance et proposent un modèle préentraîné adapté. Le résumé affirme des résultats favorables avec peu d'ajustement. Cela motive notre ablation « généraliste contre financier », mais ne tranche pas celle-ci sur notre futur corpus multi-marchés. Lecture ici limitée à la notice et au résumé. Notice primaire.

MarS et MarketGPT. Ces travaux déplacent la modélisation vers les événements et carnets. La section 7 examine leur tokenisation après consultation supplémentaire des méthodes. Il faut distinguer apprendre à produire un marché plausible, prévoir ce qui va se passer et simuler l'impact de nos propres ordres. Une bonne imitation observationnelle ne garantit pas la validité d'une intervention dans un simulateur. MarS, MarketGPT.

2. Modèles généralistes et choix d'architecture

Référence	Élément vérifié dans les sources primaires	Implication pour notre étude
Chronos, 2024	Normalisation, quantification scalaire, vocabulaire discret, Transformer entraîné par entropie croisée, prévisions échantillonnées.	Antériorité très nette du « langage numérique » ; tester la perte due à la quantification.
Chronos-Bolt, carte officielle	Encodeur-décodeur T5, patches de valeurs et prévision directe de quantiles multi-horizons ; small ≈47,7 M.	Référence rapide ; ne pas l'assimiler au tokenizer de Chronos initial.
Chronos-2, 2025	Encodeur seul, patches continus, attention temporelle et attention entre séries groupées ; cibles, covariables passées et covariables futures connues.	Référence multivariée pertinente ; « attention non causale sur contexte observé » ne signifie pas fuite si aucun futur inconnu n'entre.
Carte Chronos-2	120 M paramètres, poids déclarés Apache-2.0.	Ne pas reprendre des tableaux secondaires qui lui attribuent 205 M ou un encodeur-décodeur.
TimesFM, papier initial	Préentraînement d'un décodeur à patches sur séries réelles et synthétiques.	Un token peut être un vecteur continu de plusieurs observations ; il n'a pas besoin d'être un mot.

Référence	Élément vérifié dans les sources primaires	Implication pour notre étude
TimesFM, dépôt officiel	Version 2.5 : 200 M, contexte jusqu'à 16 k, tête optionnelle de quantiles ; version 3 annoncée en août 2026 avec multivarié et covariables natifs.	Ne pas figer l'état de l'art à la seule 2.5 ; respecter la différence de licence.
TimesFM-3, carte	Attention entre variables, contexte par patches de 32, horizon par patches de 64 ; carte et poids distincts du papier initial.	Départ pour un benchmark de recherche, sans déduction automatique sur l'emploi commercial local.
Moirai initial, 2024	Modèle universel entraîné sur de nombreuses séries, tenant compte de dimensions et fréquences diverses.	Un modèle mutualisé peut traiter plusieurs actifs ; son transfert doit rester mesuré.
Moirai 2.0, 2025	Décodeur seul, patches, quantiles et prédiction de plusieurs tokens ; les auteurs observent des plafonds de gain avec la taille.	Plus grand n'est pas automatiquement meilleur ; choisir selon les ablations et le coût.
Sundial, 2025	TimeFlow Loss par flow matching pour la distribution du patch suivant, sans tokenisation discrète.	Le paradigme prochain élément reste possible en continu ; il faut comparer discret et continu.
Time-MoE, 2024/2025	Modèles temporels à mélange d'experts à grande échelle.	Une option de montée en charge, pas une justification de complexité dans un POC.
TiRex-2, juillet 2026	xLSTM multivarié, covariables et streaming ; coût annoncé constant par patch ; 38,4 M actifs univariés, 44,1 M supplémentaires multivariés.	Alternative à examiner si le coût des fenêtres glissantes domine. Résumé consulté, aucune mesure de latence indépendante.
PatchTST, 2022/2023	Patching et indépendance entre canaux dans le modèle présenté.	Baseline d'architecture légère ; tester ensuite la valeur de l'interaction entre canaux.
TimesNet, 2022/2023	Représentation 2D des variations temporelles pour plusieurs tâches.	Concurrent utile, sans considérer les périodicités comme nécessairement stables en finance.
DLinear, 2022/2023	Des modèles linéaires simples rivalisent avec certains Transformers dans le protocole étudié.	Garder une baseline simple ; ce résultat ne réfute pas tous les Transformers futurs.
TOTEM, 2024	Embeddings temporels tokenisés pour plusieurs tâches.	La reconstruction de données et l'utilité prédictive du codebook sont deux évaluations différentes.

La plupart des lignes ci-dessus sont des lectures de résumés et de cartes. Pour Chronos-2, Moirai 2.0, Kronos et KiT, des sections de méthode ont aussi été examinées. Aucun classement agrégé provenant de ces familles n'est transposé à notre expérience scientifique : données, horizons, métriques, accès aux covariables et budget d'ajustement diffèrent.

TimeGPT et ambiguïté « TimesGPT ». Le papier historique est *TimeGPT-1*. Le dépôt officiel consulté présente désormais *TimeGPT-2.1* et l'accès par un client API. Il ne faut donc pas transformer la disponibilité du SDK en affirmation de disponibilité libre des poids. La recherche ciblée n'a pas établi un modèle canonique distinct nommé « TimesGPT » pertinent pour ce projet. TimeGPT-1, Nixtla officiel.

3. Licences : quatre objets différents

Un article, un programme, des poids et un corpus ne sont pas le même objet juridique. La licence de la page arXiv n'est pas la licence du modèle. L'affichage d'une licence sur la carte reste à enregistrer avec une révision précise au moment du futur téléchargement.

Artefact	Constat vérifié les 13-14 octobre 2026	Conséquence de sélection
Kronos code ; small ; tokenizer-base	MIT dans dépôt et cartes précités	Candidat prioritaire ; provenance du corpus à documenter séparément.
Chronos code ; Chronos-2 ; Bolt-small	Apache-2.0 dans dépôt et cartes précitées	Candidats accessibles pour expérimentation ; auditer les données choisies pour l'ajustement.
TimesFM code et poids ≤2.5	Apache-2.0 selon dépôt officiel	Option de comparaison locale.
TimesFM-3, poids	Licence spéciale limitant les poids téléchargés à des usages non commerciaux et hors production ; utilisation commerciale distincte par services Google autorisés	Vérifier que les usages de recherche envisagés entrent dans le périmètre autorisé. Texte de licence.
Uni2TS code / Moirai-2.0-R-small poids	Code Apache-2.0 ; poids CC-BY-NC-4.0	Ne pas inférer les droits des poids à partir du code. Code, carte poids.
KiT code	AGPL-3.0 déclarée ; droits précis des checkpoints non confirmés ici	Antériorité et piste de recherche, audit complémentaire avant intégration.
TiRex première génération	Dépôt déclarant une licence communautaire NXAI	Ne pas écrire « Apache/MIT » par défaut. Dépôt.
TiRex-2 code et poids	Apache-2.0 dans le dépôt et la carte du checkpoint ; 82,5 M paramètres totaux affichés	Licence différente de la première génération. Les fonctionnalités commerciales PRO ne sont pas automatiquement celles de la version publique. Code, poids.
M3 code et poids	CC-BY-NC-4.0 ; tiny 10 M, small 25 M, base 75 M et tokenizer annoncés publiés, dossiers correspondants présents ; large 366 M et xlarge 1,27 B non publiés	Piste de recherche non commerciale ; permission écrite nécessaire pour l'usage commercial selon la licence. Les fichiers n'ont pas été téléchargés ni exécutés. Licence code, carte poids, arbre des fichiers.
TimeGPT	Client API public, modèle servi à distance dans la documentation consultée	Référence optionnelle ; coût, version fixe et droits d'usage à établir avant tout appel.

Ces constats concernent les artefacts observés. Aucun paquet, poids ou corpus n'a été installé ou redistribué dans cette étude.

4. Ce que la littérature ne permet pas de conclure

Le papier de Tan et al. montre, sur trois méthodes et leurs benchmarks, que retirer le LLM textuel peut conserver ou améliorer les résultats avec un coût moindre. Cela critique un mécanisme particulier : greffer un modèle de langage préentraîné sur texte à des nombres. Ce n'est pas une démonstration d'inutilité des modèles numériques préentraînés, ni une preuve d'impossibilité du projet. Article NeurIPS 2024.

Une étude de mai 2026 sur un instrument de futures et plusieurs années de bougies de cinq minutes rapporte des résultats hors échantillon non significatifs pour LSTM et boosting. Ce résultat négatif est utile contre la présomption « il suffit d'avoir quelques années de données ». Un seul marché, une seule cible et quelques

modèles ne constituent pas une borne universelle sur le volume minimal nécessaire. Lecture limitée au résumé et à la notice. Mesfin, 2026.

Une autre étude 2026 sur Chronos rapporte un gain des entrées multivariées pour actions et taux, mais une dégradation lorsque certains ensembles hétérogènes sont mélangés. Cela suggère une ablation des groupes de covariables. Les métriques rapportées dans le résumé sont RMSE/MAPE ; elles n'établissent pas un profit net. Lecture limitée au résumé. Das et al., 2026.

TIME, prépublication de février 2026, propose des tâches et jeux récents pour traiter notamment contamination, qualité et pertinence opérationnelle. La conclusion utile pour nous est méthodologique : constituer un test privé postérieur aux coupures vérifiables des modèles, avec cibles et horizons correspondant à la question scientifique. Son leaderboard n'est pas un substitut à ce test. Qiao et al., 2026.

5. Synthèse originale : décisions de recherche

Les propositions de cette section sont nos recommandations à tester, pas des résultats expérimentaux ni des revendications de priorité.

Définir l'objet. Une bougie est une observation partielle du marché. De nombreux chemins intrabougie et carnets différents produisent le même OHLCV. Un rendu graphique ajoute une perte liée à la résolution, aux axes et au style. Commencer avec les nombres conserve davantage d'information. Une branche image devient pertinente si l'on teste une information visuelle supplémentaire ou une invariance bénéfique, pas parce que le mot « chartiste » l'impose.

Séparer trois espaces. L'espace observable contient les informations réellement disponibles. L'espace latent les représente. L'espace de sortie contient la distribution des prix futurs. Une reconstruction précise n'établit pas que le latent prédit bien ; une information perdue peut être sans importance pour une cible et indispensable pour une autre.

Préserver la géométrie. Le décodeur doit satisfaire $H \geq \max(O,C)$, $L \leq \min(O,C)$, $V \geq 0$. Une paramétrisation par ouverture, corps signé et amplitudes non négatives peut l'assurer. Pour les mèches et volumes exactement nuls, prévoir explicitement la masse en zéro : une transformation strictement positive ne peut pas tout représenter exactement. L'échelle de normalisation est calculée à partir du passé disponible ; les paramètres globaux sont ajustés sur entraînement uniquement.

Ne pas confondre multi-échelle et information nouvelle. Une heure recomposée à partir de douze bougies de cinq minutes apporte un biais inductif et une compression, pas douze observations indépendantes supplémentaires. À 10 h 35, la bougie complète 10 h-11 h n'existe pas encore. Le modèle doit recevoir la dernière bougie horaire close, ou un état partiel explicitement horodaté et masqué.

Définir « causal ». Il s'agit d'abord de causalité temporelle : aucune entrée inconnue au moment de décision. Cela ne prouve pas une relation causale économique. Une attention bidirectionnelle sur le passé entièrement observé peut être valide. Un masque causal sur un Transformer ne répare pas un scaler calculé avec le futur, un tokenizer ajusté sur le test ou une sélection d'actifs rétrospective.

Choisir le niveau de distribution. Des quantiles par horizon décrivent des marges, pas la distribution jointe du chemin. Deux modèles peuvent avoir les mêmes marges et des probabilités très différentes d'atteindre un stop avant un objectif. Pour des règles dépendantes du parcours, évaluer des trajectoires conjointes et la dépendance intertemporelle. Produire seulement la trajectoire moyenne est insuffisant pour estimer un événement extrême.

Éviter les réglages de génération textuelle mal transposés. Une température et un top-p qui embellissent une continuation peuvent dégrader la calibration financière. Tronquer le vocabulaire peut retirer précisément les événements rares nécessaires à l'estimation du risque. Comparer distributions non tronquées et distributions réglées, avec scoring probabiliste et couverture des queues. Une série réaliste visuellement n'est pas une preuve de probabilité juste.

Trois représentations à comparer à capacité comparable. R1 : tokens scalaires par quantiles ajustés sur entraînement ; R2 : codebook appris sur vecteurs de bougies ; R3 : patches continus avec sortie probabiliste structurée. Ajouter les descriptions humaines de figures comme têtes auxiliaires seulement après une définition reproductible. Éviter d'imposer une grammaire de figures chartistes dont la valeur prédictive n'a pas été mesurée.

Ablations indispensables. Prix seuls contre OHLCV ; covariables de marché ajoutées par groupe ; séquence ordonnée contre perturbation temporelle appropriée ; modèle ajusté contre gelé ; petit contre plus grand à données constantes ; discrétisation contre continu à budget proche ; modèle seul contre ensemble simple ; risque avec abstention contre même risque sans abstention. Chaque test doit expliquer un mécanisme précis ; ne pas lancer toutes les combinaisons sans hypothèse.

Mesures nécessaires. Qualité des données, violations géométriques, erreur de reconstruction par quantile, log-score lorsqu'une densité est disponible, CRPS/WIS pour les marges, scores multivariés ou statistiques ciblées pour les chemins, calibration des événements, stabilité entre périodes et coût de calcul. Les scores de direction, dispersion et trajectoire sont publiés séparément. Un score de token favorable ne garantit pas une meilleure prévision des prix.

Thèse de recherche défendable. « Quelle représentation de marché permet à un même modèle génératif d'apprendre des régularités transférables entre actifs, horizons et régimes, tout en conservant la précision, les contraintes et l'incertitude nécessaires aux tâches futures ? » La prévision des accroissements de prix, de la dispersion et des trajectoires constitue différentes évaluations de cette représentation. Une conclusion négative bien contrôlée sur l'une de ces tâches reste un résultat de R&D.

6. Doutes, points surprenants et journal de vérification

- L'antériorité directe est plus forte qu'attendu : Kronos reprend l'intuition du langage des bougies ; KiT traite déjà plusieurs améliorations structurelles proposées spontanément.
- Une famille moderne n'exige pas des milliards de paramètres : plusieurs références sont de l'ordre de quelques millions à quelques centaines de millions. La taille est une variable expérimentale, pas la définition de la pertinence.
- Des versions d'une même famille changent profondément : Chronos discret, Bolt à patches et Chronos-2 multivarié ne doivent pas être comparés sous une seule étiquette.
- Des poids peuvent être restreints alors que le code est permissif. Moirai 2.0 et TimesFM-3 constituent des exemples concrets vérifiés.
- « LCM » est déjà utilisé pour *Large Concept Models*. Un nom propre accompagné de « modèle fondation des séquences de marché » évite de cantonner le projet à des figures chartistes à un marché particulier ; trois noms de travail sont proposés en section 10. Antériorité du sigle.
- Les dates relatives des moteurs de recherche ne sont pas fiables pour établir une chronologie ; les notices arXiv et annonces datées ont été préférées. KiT (28/09/2026), TiRex-2 (01/07/2026) et TimesFM-3 (08/2026) sont bien antérieurs au 13/10/2026 dans les sources consultées. Les compléments de disponibilité et de données ont été vérifiés le 14/10 ; ils ne constituent pas la preuve d'une disponibilité historique inchangée.
- La version HTML de KiT rend certains signes de tableaux de façon ambiguë ; nous n'en recopions pas les lignes détaillées. Les chiffres retenus proviennent des phrases explicites des auteurs. Ils restent à contrôler au moment d'une reproduction.
- L'historique complet des corpus, leur recouvrement avec nos futurs tests et la disponibilité de tous les checkpoints ne sont pas établis. Un test historique avec coupure de préentraînement inconnue doit être marqué potentiellement contaminé, même si aucun ajustement local n'a utilisé son futur.

Le prochain livrable utile est donc un protocole expérimental préenregistré et un registre des données/checkpoints. Cela donne une voie réaliste vers un POC scientifique ; la prévisibilité et le transfert restent des hypothèses ouvertes.

7. Complément prioritaire : quel langage pour les courbes et les événements ?

Nagy et al., 2023. Un modèle autorégressif de messages du carnet utilisait déjà un tokenizer numérique et des couches de type state space, avec un simulateur Jax-LOB. Le mécanisme de génération événementielle n'exige donc pas, par définition, un Transformer. Notice et résumé consultés. Article primaire.

MarketGPT, détail de conversion. Les messages regroupent horodatage, type, référence d'ordre, côté, taille et prix. Le tokenizer produit 24 tokens par message, avec plusieurs tokens pour prix et temps. Environ 91 millions de messages de 20 actifs deviennent 2,19 milliards de tokens, mais le corpus ne couvre que huit jours. Les auteurs rapportent qu'une variante de type BPE réduisait le temps d'inférence mais dégradait la qualité dans leurs expériences. Ils distinguent explicitement réalisme génératif et prévision du futur. Le vocabulaire annoncé présente une petite incohérence arithmétique dans le texte (12 012 + 98 versus total annoncé 12 111) ; ne pas en reprendre un total comme référence vérifiée. Méthodes et limites.

MarS, détail de conversion. Le modèle d'ordres représente le tuple type/prix/volume/intervalle et ajoute un état du carnet. Les discrétisations annoncées conduisent à 49 152 combinaisons. Un second modèle agrège les ordres en images et apprend des codes VQ-VAE. L'annexe mentionne 16 milliards de tokens d'ordres de 500 actions liquides chinoises sur 2017-2023. Ce sont deux granularités et deux compromis information/calcul, pas une obligation d'utiliser une image de chandelier. Méthode, annexes B-C.

TradeFM, février 2026. Le papier présente un modèle de 524 M paramètres et plus de 9 000 actions. La tokenisation combine catégories, prix relatifs, volumes transformés et temps interévénement ; les indices forment un token composite parmi 16 384 possibilités. Des variables contextuelles restent à côté du token prédit. L'entraînement est indiqué à 10,7 milliards de tokens, avec coupure temporelle et test géographique séparé. Cette antériorité est directement pertinente pour l'ambition multi-actifs. Les données sont propriétaires ; ni les chiffres ni le guide de reproductibilité ne doivent être confondus avec un corpus librement réutilisable. Papier, sections 5-7.

M3, prépublication 2026. Le modèle associe état initial du carnet, tokens d'événements VQ appris et génération autorégressive avec matching déterministe. Encodeur et décodeur du tokenizer sont causaux. Les auteurs soulignent une différence entre ancre mid-price observée à l'entraînement et ancre simulée au déroulement ; ils proposent une ancre d'ouverture fixe pour limiter ce décalage. C'est une antériorité post-Kronos au langage événementiel appris et à son articulation avec un état explicite. La notice affiche 29 juillet 2026 malgré l'identifiant 2608.19227 ; cette discordance de métadonnées doit être conservée dans le registre. Les deux dates restent antérieures à notre borne. Méthode et annexe tokenizer.

Causal Market Simulator, notice du 8 octobre 2026. Un travail tout récent distingue l'impact d'un ordre du prix qui aurait eu lieu sans cet ordre. Il teste un PFN avec un prior synthétique causal puis du transfert. Les auteurs eux-mêmes indiquent que les observations empiriques sont compatibles avec un transfert causal sans le démontrer. Cette piste appartient à une phase avancée de simulation, pas à la preuve immédiate d'un tokenizer de bougies. Seul le résumé a été lu. La conférence mentionnée en novembre 2026 est future à notre borne ; la notice prépublication est déjà datée du 8 octobre. Notice primaire.

Recommandation de conception : une grammaire typée, pas des phrases françaises

Le langage recherché n'a pas besoin de mots humains. Un token est une unité de représentation ; le « sens » utile apparaît lorsque les relations entre ces unités aident plusieurs tâches et généralisent. La première expérience scientifique doit ainsi tester le tokenizer indépendamment du grand modèle. Sinon, les capacités du réseau peuvent masquer un vocabulaire inefficace ou une fuite.

Un alphabet expérimental peut comporter trois familles. Les **tokens de contrôle** décrivent source, modalité, marché, calendrier, intervalle, fin de session, manque de données et révision. Les **tokens d'observation** portent une bougie, un événement ou un petit patch. Les **tokens de contexte** portent état de liquidité, échelle passée et information effectivement connue. Ils ne sont pas tous des cibles à prédire. Leur disponibilité est définie avant l'entraînement.

Le mapping « livre = actif, chapitre = période, phrase = motif » aide l'intuition mais peut induire une mauvaise segmentation. Un actif change de régime ; plusieurs actifs partagent des événements ; un même choc traverse plusieurs places. Il faut plutôt tester « corpus = collection d'histoires synchronisées ; séquence = fenêtre d'observations ; unité = événement ou patch ; contexte = conditions de marché ». Les figures chartistes nommées sont des annotations facultatives de motifs appris, et non l'alphabet obligatoire.

Les cinq niveaux ci-dessous constituent des variantes à départager, pas cinq briques à empiler immédiatement :

1. **Quantification par champs.** Un prix relatif, un corps, une mèche et un volume deviennent des identifiants de bins. Lisible et diagnostiquable, mais augmente la longueur et rend les dépendances entre champs coûteuses.
2. **Token composé.** Les catégories des champs sont combinées en un identifiant unique. Court, mais le vocabulaire croît comme le produit des résolutions : dix dimensions à 32 niveaux donneraient 32^10 états, avant même la temporalité. La parcimonie du corpus rend une table directe inadaptée.
3. **Token appris conjoint.** Un encodeur causal compresse le vecteur d'observation vers un code VQ/BSQ ou des codes factorisés. Plus compact, mais il faut vérifier saturation, utilisation du codebook et stabilité entre marchés. Un vocabulaire qui s'effondre vers quelques codes peut donner une bonne perte moyenne tout en détruisant les événements rares.
4. **Token hiérarchique plus résidu.** Une partie grossière, une partie fine puis un résidu continu conservent une résolution adaptée. L'intérêt attendu est le partage de structure sans sacrifier la précision près des seuils. L'ordre des sous-tokens devient une décision architecturale et doit être ablaté.
5. **Patch continu et sortie continue.** Le réseau travaille sur des embeddings sans dictionnaire discret. C'est une hypothèse concurrente obligatoire : le bénéfice pourrait provenir du préentraînement séquentiel, non de la discrétisation.

Le critère de réussite du tokenizer n'est pas seulement l'erreur quadratique de reconstruction. Il faut une courbe débit-distorsion : nombre de bits ou tokens par observation contre erreur en points de base, déformation des queues, violations géométriques, précision des volumes, perte sur indicateurs calculés et modification de l'ordre des événements. Une compression qui change fréquemment lequel de deux seuils est touché en premier est inacceptable pour cette tâche, même si la courbe reconstruite semble identique à l'œil.

La **fidélité sémantique** doit être définie par des propriétés calculables : signe du rendement, franchissement de barrière, distance au spread, ordre et durée des événements, cumul de volume, cohérence des agrégations. Ces propriétés ne sont pas toutes connaissables à partir d'OHLCV ; lorsqu'elles exigent la microstructure, le tokenizer ne doit pas inventer l'information absente.

Corpus : beaucoup de courbes, mais surtout des informations différentes

L'intuition de réunir de nombreux actifs et horizons est justifiée comme stratégie d'apprentissage partagé. L'expérience doit toutefois dissocier le nombre d'enregistrements du nombre d'expériences indépendantes. Vingt actifs corrélés pendant une même crise ajoutent des observations transversales utiles ; ils n'ajoutent pas vingt crises. Douze versions temporelles du même historique ne créent pas douze fois autant de nouveauté. Le cas MarketGPT ci-dessus illustre pourquoi « milliards de tokens » et « diversité historique » sont des notions différentes.

Construire un manifeste de couverture : classes d'actifs, places, horizons, années, crises, liquidité, règles de cotation, géographies, instruments disparus et interruptions. Mesurer concentrations et dépendances par

blocs. Prévoir des tests qui retirent successivement une période entière, un groupe d'actifs, une place puis une classe d'actifs. Un modèle qui prédit un actif nouveau pendant une période déjà mémorisée ne prouve pas le même transfert qu'un modèle confronté à une période et à un marché inconnus.

Ne pas rendre toutes les séries artificiellement identiques. La normalisation enlève les unités arbitraires, mais l'échelle de volatilité, le tick relatif, le spread, le calendrier, le caractère spot ou dérivé et la maturité peuvent porter une information prédictive. Conserver des canaux de contexte causaux pour ces éléments, ainsi que des masques de disponibilité. Le modèle peut apprendre une structure commune avec des adaptations par famille plutôt qu'un universalisme forcé.

Architecture ambitieuse et rôle exact du calcul

Une direction de R&D cohérente est un système à plusieurs résolutions : encodeur local d'événements ou bougies ; compression causale en tokens ; mémoire lente de sessions/régimes ; attention entre actifs contemporains déjà observés ; décodeurs adaptés aux bougies, à la microstructure et au risque. Les échanges entre échelles doivent respecter l'horloge de connaissance. Un moteur déterministe peut imposer les règles du carnet lorsque l'on simule des événements. Ce schéma est une proposition composite, dont les composants ont des antériorités ; sa valeur dépend d'ablations qui isolent les gains.

Le préentraînement pourrait combiner prochain token, reconstruction masquée dans des fenêtres entièrement passées, cohérence entre agrégations et prédiction de distributions à plusieurs horizons. La perte globale doit éviter qu'une tâche facile et abondante, comme reconstruire un niveau de prix, domine une tâche rare mais importante. Les coefficients sont choisis sur validation et leur sensibilité publiée. Les données manquantes ne deviennent pas de faux zéros ; les actifs sans carnet complet peuvent contribuer à la branche bougies avec un masque de modalité.

Un passage 10 M → 100 M → 1 B+ paramètres est une expérience possible. Il doit varier aussi le volume et la diversité des données : agrandir seulement le réseau ne teste pas correctement le scaling. La littérature étudie déjà les pertes en fonction de taille, données et calcul, avec effet de l'architecture. Elle ne fournit pas une loi universelle transformant FLOPs en profit. Yao et al., notice et résumé.

Le calcul peut réduire les erreurs d'approximation et d'optimisation, permettre plus de contextes et estimer mieux certaines distributions. Il ne restaure pas une annonce future absente des entrées, ne crée pas une histoire de crise supplémentaire et ne supprime pas l'aléa conditionnel. La frontière à étudier relie information disponible, biais de représentation, capacité, diversité et calcul. Une faible performance locale ne suffit pas à en déduire un plafond universel.

8. Corpus réel : voies d'acquisition multi-marchés

Le projet peut partir de données réellement observées et ne dépend pas de la génération de courbes artificielles. Les sources ci-dessous sont identifiées sur leur documentation primaire ; aucun abonnement ni achat n'a été effectué. Ce catalogue décrit des voies d'accès ; le document 07 distingue désormais les petites collectes réellement acquises et auditées. Un futur manifeste distinguera clairement « disponible chez le fournisseur », « droit acquis », « reçu », « contrôlé » et « admis dans l'entraînement ».

Source réelle	Contenu et intérêt scientifique	Limites établies et action de sélection
Binance Public Data / Vision	Archives quotidiennes et mensuelles de bougies, trades et trades agrégés, spot et futures ; l'annonce Binance situe les historiques publics à partir de 2017. La date de début dépend toutefois du symbole et du produit : ne pas attribuer 2017 à tous les contrats. Annonce primaire, dépôt officiel.	Checksums et corrections d'archives documentés ; changement d'unité des timestamps spot à partir de janvier 2025. Surtout, la licence MIT du code n'est pas celle des données : voir le paragraphe dédié ci-dessous.

Source réelle	Contenu et intérêt scientifique	Limites établies et action de sélection
Kraken, archives de trades	Page officielle consultée le 14/10 : tous les trades publics par paire, depuis le premier trade de la paire jusqu'au 30/09/2026, archives et incréments trimestriels. Prix, volumes et timestamps permettent de reconstruire plusieurs granularités depuis une même source élémentaire. Archives officielles.	L'API OHLC est une autre voie, limitée aux 720 derniers enregistrements ; sa dernière bougie est en cours. Les archives résolvent la profondeur historique, sans donner le carnet ni garantir les droits de redistribution des données ou poids. Limite API primaire.
Coinbase Exchange	API primaire de bougies par produit, utile comme autre place, comme contrôle croisé et pour construire un corpus progressif. Documentation des bougies.	Maximum 300 bougies par requête ; granularités déterminées ; historique possiblement incomplet et absence de bougie quand il n'y a pas de tick. Une absence n'est donc pas automatiquement une panne. Distinguer accès public, droit de stockage massif et droits d'entraînement ou de distribution, non établis par cette seule page.
Tardis.dev	Flux crypto historiques capturés : trades, mises à jour du carnet, quotes et autres canaux selon la place. Pour Binance spot, certaines grandes paires depuis le 30/03/2019, toutes les paires depuis le 05/03/2021 selon la fiche ; couverture à examiner par canal. Couverture primaire Binance, API historique.	Les horodatages locaux ajoutés aident l'audit de disponibilité. Des snapshots de carnet sont obtenus par REST et marqués comme générés : ils ne sont pas des événements WebSocket natifs. Samples du premier jour du mois accessibles sans clé ; corpus complet et droits commerciaux à vérifier contractuellement avant engagement.
Databento, actions et dérivés cotés	Catalogue documenté incluant actions, futures, options et FX ; places comme Nasdaq, CME Globex et OPRA. Schémas selon produit : OHLCV, trades, prix/tailles par niveau ou ordres individuels. Des extraits réels sont proposés dans le catalogue pour contrôler la qualité. Catalogue primaire, schémas.	La profondeur, les schémas et l'origine de capture varient par dataset ; on ne généralise pas « tous les ordres, toutes les années » à l'offre entière. La fiche comporte une section de licence et une estimation du coût. L'historique et le live ont des conditions distinctes ; collecter leurs droits avant d'entraîner un produit. Démarrage officiel.

Droits du corpus témoin. Les conditions Binance Vision consultées le 14 octobre 2026 prévoient la recherche personnelle hors production et encadrent séparément les autres usages. Les données dérivées conservent attribution et conditions applicables ; l'utilisation ici est descriptive et scientifique. Conditions primaires.

Pourquoi les données réelles ne suffisent pas à elles seules. Un trade réel peut être dupliqué entre fournisseurs. Un historique d'actifs survivants peut être exact ligne par ligne et néanmoins biaisé. Une correction de transaction reçue le lendemain ne devait pas être connue la veille. Un contrat futures continu obtenu par raccordement peut créer des mouvements qui n'ont jamais été négociables. Le pipeline envisagé doit conserver source, instrument réel, échéance, timestamp d'événement, timestamp de réception lorsqu'il existe, version et règles de correction. Les chandeliers à plusieurs horizons sont des vues dérivées de cette base, et leur parenté reste enregistrée.

Priorité de collecte proposée. D'abord réunir des années et des marchés diversifiés dans une branche bougies/trades, avec instruments disparus lorsque la source le permet ; parallèlement sélectionner quelques sous-corpus riches en microstructure pour tester le langage événementiel. Ensuite étendre actions, indices via instruments cotés, taux, énergie et matières premières par contrats réels. L'extension doit inclure calendriers, maturités, devises et unités, sans prétendre qu'une normalisation efface ces différences. Une table par source consigne couverture par actif/date/champ, part manquante, profondeur du carnet, corrections, droit d'entraînement, droit d'exploitation des poids et droit de redistribution. Les sources synthétiques éventuelles restent séparées et ne remplacent ni le corpus réel, ni son test final.

Le nombre de sources ne doit pas servir de métrique d'avancement : trois fournisseurs des mêmes BTC/USDT sur la même période donnent surtout un contrôle de qualité, alors qu'un historique de crise supplémentaire ou une famille d'actifs peu représentée apporte une diversité différente. L'objectif est la couverture mesurable des mécanismes et régimes de marché.

9. Vérifications récentes : chronologie, fichiers publiés et limites de preuve

Référence	Statut documentaire et artefact au moment de cette étude	Limite à conserver dans le dossier
KiT, 28/09/2026	Prépublication et dépôt primaire accessibles ; dossiers de checkpoints visibles, code AGPL-3.0.	Nous n'avons pas établi une liste complète de fichiers de poids effectivement récupérables avec leurs licences propres. La présence d'un dossier n'est pas une validation d'exécution.
M3, identifiant 2608.19227	Carte et arborescence Hugging Face vues le 14/10 : tiny/small/base et tokenizer présents, modèles 366 M/1,27 B déclarés non publiés ; CC-BY-NC-4.0.	Notice affichant 29/07/2026 alors que l'identifiant correspond à août : discordance conservée, pas corrigée arbitrairement. Aucun poids exécuté.
TiRex-2, 01/07/2026	Dépôt et carte de poids Apache-2.0 ; 82,5 M paramètres totaux ; versions excluant certains jeux de benchmarks documentées.	Décontamination d'un benchmark généraliste ne prouve pas absence de contamination de notre propre corpus financier. Les droits et fonctions de TiRex-1, TiRex-2 et PRO diffèrent.
TimesFM-3, annonce août 2026	Dépôt/carte et licence spéciale de poids accessibles.	Disponibilité publique n'implique pas usage commercial ou production autorisé ; séparer les services hébergés et les poids téléchargés.
Causal Market Simulator, 08/10/2026	Notice prépublication accessible ; seule la notice et le résumé ont été lus.	Une conférence indiquée en novembre est encore future ; ne pas la présenter comme un événement déjà tenu ni attribuer une validation indépendante au papier.
Archives Kraken, page consultée le 14/10	Le corps de page affiche une mise à jour du 12/10 et la couverture jusqu'au 30/09/2026.	Un résultat indexé antérieur indiquait juin : le corps récent est retenu. Il faut dater la capture et vérifier le manifeste du futur téléchargement plutôt que déduire la couverture du seul résumé moteur.

Les résultats empiriques de 2026 cités sont des revendications des auteurs et, pour certains, des prépublications récentes. Nous n'avons trouvé aucune preuve permettant de convertir leur disponibilité en garantie de prévision généralisable sur nos données. Les liens primaires sont fournis à proximité des affirmations dans cette note ; aucune citation secondaire n'a été utilisée pour établir une licence de poids.

Nom retenu pour ce dossier

TRAME est le nom de travail retenu par la synthèse, pour un modèle génératif des structures de marché. Les alternatives Séquora, Traméa, Orvéa, Palimpseste et Morphose restent des propositions éditoriales. Aucune disponibilité juridique ou de domaine n'est revendiquée.

10 Mise à jour du 14 octobre : marché latent, GPT et échelle

Le cadrage actif porte sur la prévision scientifique multi-marchés. L'ancienne annexe d'exploitation est conservée uniquement dans la version 1 archivée. Le papier 01 et le document 08 distinguent partage de grammaire, information croisée et état commun partiel. Aucun modèle prédictif n'a été entraîné pour cette mise à jour.

TimesFM-3, annoncé le 31 août 2026, constitue une antériorité importante pour l'attention entre séries dans un Transformer temporel. Les mécanismes et les limites des sorties marginales sont analysés au document 08. L'annonce est une source primaire des auteurs, pas une reproduction indépendante. Annonce technique.

Les travaux d'Edwards et de Yao motivent une mesure des effets d'échelle. Leurs résultats ne constituent pas une loi universelle des prix financiers ; les détails et restrictions sont discutés dans le document 05. Edwards et al., Yao et al..

La notion de facteur partagé possède une longue histoire économétrique. Stock et Watson proposent de résumer un grand nombre de prédicteurs par des composantes avant de prévoir une série. Cette référence empêche de présenter le seul « Marché commun » comme une idée nouvelle. Notre programme ajoute des questions sur les langues, les masques et le transfert. Article des auteurs.

Le catalogue NYSE Daily TAQ annonce une histoire remontant à 1993, ce qui ouvre une voie de recherche pour les épisodes de 2000 et de 2008, sous conditions d'accès à établir. Il n'atteste pas une qualité uniforme de chaque variable à la seconde sur toute cette période. Les données BCE constituent une voie distincte pour les références quotidiennes de devises. NYSE, BCE : séries de référence.

Les nouveaux manifestes locaux documentent les observations effectivement reçues. Les sources synthétiques mentionnées dans certains modèles de la littérature n'ont pas été substituées aux observations réelles des mesures TRAME. Les petits exemples artificiels des tests de calcul sont identifiés comme tels.

Première mesure des langages et extension du corpus réel

Rapport du 14 octobre 2026, version scientifique 2. Les nombres ci-dessous sont issus d'observations réelles. Ils mesurent reconstruction et qualité des données, pas prévision du prix futur.

1 Rôle exact de cette expérience

POC0 est un appareil de mesure pour la conversion des courbes en représentations. Il prend une bougie déjà observée, l'encode, puis la reconstruit. L'expérience évalue la distorsion créée par le langage. Aucun GPT, RNN, modèle de trajectoire ou codebook neuronal n'a été entraîné. Aucun score prédictif n'a été calculé. Des paramètres de quantification ont été ajustés sur une période de calibration passée.

Le corpus horaire témoin était choisi avant le recadrage multi-marchés approfondi. Il sert à qualifier les calculs et ne constitue ni le corpus cible ni une preuve de transfert. Une seconde acquisition ajoute maintenant une histoire réelle de devises de 1999 à 2020 ; elle fait l'objet d'un audit, sans lui appliquer artificiellement une géométrie de bougie absente.

2 Protocole gelé, puis amendement explicite

La version initiale a été gelée le 2026-10-14T07:54:43.274719+00:00. L'acquisition s'est arrêtée sur une bougie dont l'heure de fermeture ne correspondait pas à une heure complète. Des archives déjà reçues ont alors été inspectées uniquement pour ce contrôle de durée ; aucune métrique de représentation n'avait encore été produite.

La version 1.1 a été gelée le 2026-10-14T09:37:59.694771+00:00. Elle exclut les bougies se terminant avant la fin de leur heure du comparatif à durée fixe, les conserve dans le brut et les signale. Les timestamps hors de l'intervalle prévu restent rejetés. L'amendement ajoute aussi une lecture des bornes de dates depuis le protocole et le contrôle de finitude des reconstructions. La version précédente, son code et ses empreintes sont conservés.

La période janvier-août 2021 ajuste les vocabulaires et les seuils ; septembre-octobre 2021 fournit la mesure de développement. Les archives de novembre-décembre 2021 pour les huit paires n'ont pas été téléchargées. Ce découpage historique n'est pas une validation prospective. Les futures expériences pourront réserver d'autres périodes sans présenter celles déjà examinées comme vierges.

Empreinte SHA-256 du protocole actif : `8d57001eb26df3a2258ba424abafcafbb5ef9cfdd42577a40715f30a5bb14e07`. Empreinte du programme d'analyse : `a89861c3cba24105bc9811cd01bd7ba5057dd93b63d49e5ae99d2c152e3b830e`. Le protocole et le journal d'amendement sont dans research/trame_poc0 ; les résultats complets sont dans son sous-dossier results.

3 Corpus horaire réellement reçu

Quatre-vingts archives mensuelles ont été reçues et leur empreinte vérifiée contre le CHECKSUM publié. Elles concernent BTCUSDT, ETHUSDT, BNBUSDT, ADAUSDT, XRPUSDT, LTCUSDT, EOSUSDT et TRXUSDT, sur janvier-octobre 2021. Source : Binance Vision, documentation primaire. Les manifestes donnent chaque URL, date de réception, taille et empreinte.

- 58 264 lignes sources ; 104 créneaux horaires absents par rapport au calendrier continu, comptés sur les huit séries.
- 24 lignes se terminant avant la fin de leur heure, conservées mais exclues du comparatif.

- 58 240 bougies horaires complètes admises ; 3 185 740 octets d'archives ZIP.
- Aucun remplissage des trous. Un trou réinitialise le contexte. L'agrégation H4 exige exactement quatre parents H1 complets, alignés en UTC.

Les heures absentes et les trois fermetures anticipées par actif se retrouvent sur plusieurs séries. Il ne faut pas compter ces répétitions comme des incidents indépendants ni attribuer leur cause sans preuve. Par exemple, une ligne du 11 février 2021 à 03:00 UTC se termine après 2 454 774 ms ; une autre du 25 avril à 04:00 UTC après 58 147 ms. Le checksum était pourtant correct : intégrité de transfert et qualité du calendrier sont deux contrôles différents.

La géométrie exige un précédent prix et des échelles calculées sur le passé strict. Chaque segment exige 65 bougies de contexte avant la première mesure. En H1 : 43 424 observations de calibration, 11 176 de développement et 3 640 exclues pour l'amorçage du contexte. En H4 : 8 768, 2 392 et 3 360 respectivement. Les exclusions après des trous peuvent retirer des épisodes agités : l'échantillon admis n'est pas présumé sans biais. H4 provient de H1 : les deux résolutions ne sont pas deux corpus indépendants.

4 Cinq représentations comparées

Chaque bougie positive est transformée en g=ln(O/C_précédent), b=ln(C/O), u=ln(H/max(O,C)), d=ln(min(O,C)/L) et v=ln(1+V/V_ref). V_ref est la médiane des 64 volumes strictement précédents, avec plancher 10^-12. Sigma est l'écart-type population de 64 rendements de clôture strictement passés, avec plancher 10^-6. Ces références sont observées et fournies à la reconstruction.

Langage	Règle exacte	Statut
Continu	Cinq coordonnées float64	Contrôle numérique presque identique, pas un vainqueur de compression
Pas fixes	Arrondi au plus proche, égalités vers pair ; pas 0,001 sur g,b,u,d et 0,05 sur v	Entiers sans vocabulaire borné
Quantiles 64	Zéro explicite ; au plus 63 classes non nulles par champ ; médiane d'apprentissage par classe	Vocabulaire fini empirique, non neuronal, séparé H1/H4
Signes / présence	Signe de g et b ; présence ou absence de u,d,v ; amplitude médiane de calibration	Contrôle volontairement destructeur
Adaptatif	Pas 0,1 sigma passée sur g,b,u,d ; pas 0,05 sur v	Entiers non bornés ; échelle fournie comme information auxiliaire

Les quantiles sont ajustés sur janvier-août uniquement, en regroupant les huit actifs pour chaque résolution. Les frontières dupliquées sont fusionnées ; les classes extérieures sont ouvertes et les zéros restent exacts. Un code de classe ne conserve pas la distance à son représentant. Le programme mesure séparément les sorties du support de calibration.

Les 64 observations passées représentent 64 heures en H1 et 256 heures en H4. La comparaison entre ces résolutions ne contrôle donc pas la durée physique de normalisation ; elle n'a pas été conçue pour estimer le seul effet de la fréquence. Une prochaine expérience devra fixer cet axe séparément.

5 Résultats descriptifs

L'erreur est `10 000 × abs(ln(prix_reconstruit/prix_observé))`. Un point de base logarithmique vaut 0,0001 en logarithme. Ce n'est pas exactement un point de base de variation simple pour les grands écarts. La moyenne ci-dessous regroupe O,H,L,C et toutes les bougies admises de développement, avec pondération par leur nombre.

La colonne « queue » sélectionne les bougies dont le corps absolu dépasse le 99e percentile de calibration de leur résolution, sans sélectionner les erreurs après coup. Elle contient seulement 37 bougies en H1 et 7 en H4, potentiellement corrélées entre actifs. Ces très petits effectifs décrivent cet échantillon ; ils ne permettent pas une généralisation statistique sur les crises ni une comparaison prédictive.

Résolution	Langage	Moyenne log-bps	Moyenne queue log-bps	Maximum log-bps
1h	Continu float64	0.0000	0.0000	0.0000
1h	Pas fixes	2.5679	2.9820	14.7401
1h	Quantiles 64	2.2819	199.9714	2456.1238
1h	Signes / présence	33.1419	425.5187	3113.3848
1h	Pas selon sigma passée	2.4212	3.4154	41.3237
4h	Continu float64	0.0000	0.0000	0.0000
4h	Pas fixes	2.5761	2.7443	13.8874
4h	Quantiles 64	4.0039	270.9477	2347.7133
4h	Signes / présence	67.5717	833.5569	2931.5301
4h	Pas selon sigma passée	4.2095	3.8389	31.4523

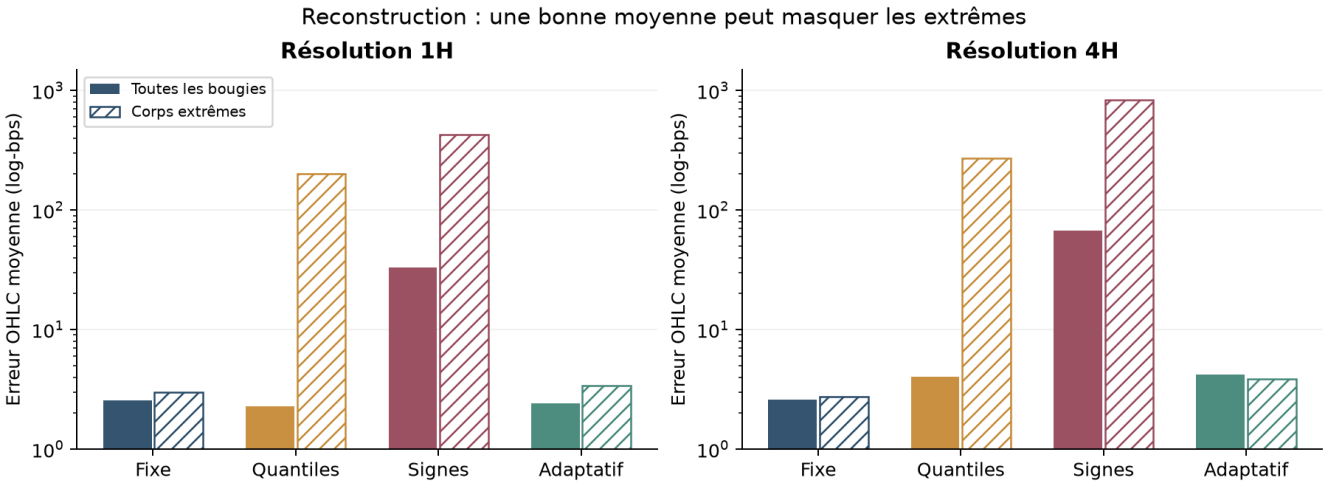


Figure : moyenne et corps extrêmes sur la même période de développement. Axe vertical logarithmique. Reconstruction de données connues, sans prévision. Source : calculs TRAME à partir de Binance Vision.

La branche continue restitue les prix à l'arrondi numérique près. Les prix de toutes les branches respectent ici les contraintes OHLC : c'est en grande partie une propriété du décodeur géométrique, pas une découverte empirique sur la prévisibilité.

Constat majeur : moyenne et extrêmes conduisent à des lectures différentes. En H1, les quantiles sont légèrement meilleurs en moyenne que les pas fixes (2,282 contre 2,568 log-bps), mais leur moyenne sur les corps extrêmes atteint environ 200 log-bps, contre environ 2,98 pour les pas fixes. Le maximum des quantiles dépasse 2 456 log-bps. L'espace des grandes amplitudes est trop grossièrement représenté par certaines classes terminales. Cette observation concerne ce quantificateur marginal précis ; elle ne condamne pas un vocabulaire hiérarchique appris.

L'absence de borne de vocabulaire donne aux pas fixes une propriété différente : l'erreur locale est bornée par 5 log-bps pour O, 10 pour C, et 15 pour H/L, hors erreur numérique. Ces bornes résultent de la somme des arrondis de g, b et des mèches. Il serait incorrect de déclarer ce langage globalement supérieur sans compter son débit et comparer ses capacités prédictives.

Décomposition H1 par actif

Actif témoin	Bougies dev	Moyenne fixe	Moyenne quantiles	Maximum quantiles
BTCUSDT	1397	2.097	1.092	431.806
ETHUSDT	1397	2.136	1.685	799.197
BNBUSDT	1397	2.522	2.105	1050.927
ADAUSDT	1397	3.211	2.516	975.810
XRPUSDT	1397	2.259	2.443	1060.452
LTCUSDT	1397	3.292	3.457	2456.124
EOSUSDT	1397	2.650	2.871	1070.050
TRXUSDT	1397	2.377	2.086	735.689

Toutes les erreurs de ce tableau sont en log-bps. La granularité de la source et les actifs de cette expérience ne définissent pas les futurs marchés d'entraînement. Une répétition sur actions, or ou devises ne peut pas être revendiquée à partir de ces chiffres.

6 Autres diagnostics conservés

Les résultats JSON détaillent erreurs de clôture, quantiles d'erreur par actif, volumes, support de calibration, occupation des codes et dérive cumulative. La dérive réutilise les échelles observées et une ancre vraie au début de chaque segment de développement : c'est une dérive conditionnelle du codec, pas une trajectoire future générée. Pour une génération réelle, les échelles futures devraient être figées ou mises à jour sur le chemin généré selon une règle annoncée.

Un diagnostic séparé repère des paliers sur les seules clôtures, avec seuil de 0,005 logarithmique, soit environ +0,50125 % pour un palier montant. Il agrège les multiples franchissements visibles à une clôture, conserve durée et résidu, et marque l'attente finale comme censurée. Il ne reconstruit pas l'ordre des mouvements intrabougie et ne traite pas les paliers comme des horizons calendaires fixes.

Les informations latérales ne sont pas comptabilisées en bits dans ce premier rapport. Le continu, les entiers non bornés et les quantiles ne disposent donc pas du même débit démontré. Une comparaison débit-distortion reste à construire. La fréquence des tuples inconnus ne prouve ni nouveauté économique ni difficulté prédictive.

7 Extension réelle hors du corpus horaire : devises BCE

Une requête bornée à 1999-2020 a reçu 34 164 lignes pour AUD, CAD, CHF, GBP, JPY et USD contre EUR. Elle contient 33 792 valeurs numériques, soit 5 632 par devise, du 4 janvier 1999 au 31 décembre 2020. Les 372 entrées explicitement vides portent le statut H de non-publication ; elles ne sont pas remplacées par des prix. Le contrôle ne trouve aucun doublon de clé série-date. L'empreinte du brut est `b8a684b6331d3cf0310a1838efdce806495906ead99d672671642c3bf24130de`.

Sur les 5 740 dates du lundi au vendredi de la période demandée, 108 n'ont pas de valeur numérique : 62 sont explicitement marquées H et 46 n'ont aucune ligne. Ces 46 dates ne sont pas toutes certifiées individuellement par un calendrier historique dans cet audit. Les H s'arrêtent en 2012 ; le changement de représentation des absences ne doit pas devenir un faux signal de régime.

Cette acquisition apporte une vraie profondeur historique comprenant les années 2000, 2008 et 2020. Elle ne démontre aucune capacité à prévoir les événements de ces périodes. Les séries partagent l'EUR comme dénominateur : six devises ne sont pas six expériences indépendantes et une partie de leurs relations est mécanique. Aucun cours postérieur à 2020 n'a été reçu dans cette requête.

Ce sont des références quotidiennes, pas des transactions ni des bougies avec hauts, bas et volumes. Leur disponibilité ne doit pas être assimilée au début de la date civile. La publication habituelle a été déplacée vers 16:00 CET à partir du 1er juillet 2016 ; la documentation antérieure indique environ 14:30. Le fichier actuel ne prouve pas la version exacte ni l'heure de réception historique de chaque ligne. BCE : séries, changement de publication.

L'audit et les comptages annuels sont conservés dans research/trame_poc0/ecb_exploratory. Ils n'ont pas servi à ajuster les cinq codecs OHLCV. Ils préparent une branche de recherche distincte, avec masque de modalité et une convention de disponibilité adaptée. Politique de réutilisation des statistiques BCE.

8 Vérification et portée scientifique

Neuf contrôles de calcul ont réussi : intégrité et périmètre d'archive ; schéma et doublons ; exclusion tracée des bougies partielles ; agrégation à quatre parents ; invariance au futur ; réinitialisation après trou ; reconstruction et bornes d'arrondi ; traitement des zéros ; paliers et censure. Les petits exemples construits pour ces contrôles ne font pas partie des observations utilisées dans les tableaux.

Les premières revues entre agents logiciels ont vérifié disponibilité des sources et absence de fuite dans les références passées. Elles ont conduit à expliciter coût des informations auxiliaires, durée différente de sigma selon la résolution et limites des trajectoires reconstruites. Ce n'est pas une revue par des chercheurs humains indépendants.

La conclusion autorisée est que l'appareil de mesure fonctionne sur deux types de données réelles et qu'un quantificateur simple peut perdre fortement les extrêmes malgré une bonne moyenne. La conclusion non établie est qu'un langage, un GPT ou un état latent commun prédit les prix. Les prochaines comparaisons doivent étudier information latérale, précision progressive et corpus multi-marchés, puis tester la prévision à plusieurs échelles de modèle selon le protocole scientifique.

TRAME - hypothèse d’un marché latent et prédiction scientifique des prix

Document de conception du 14 octobre 2026. Périmètre : prix observés multi-actifs, représentation, prévision et généralisation. Six travaux scientifiques et une annonce technique primaire vérifiés ; propositions de recherche distinguées des résultats publiés. Aucune expérience prédictive n’a été réalisée pour ce document. Le premier banc de reconstruction mesure un encodage ; ses résultats ne constituent pas une validation de prévision.

1. Reformulation de l’hypothèse

L’or, un indice, une action et une paire de devises pourraient être différentes expressions d’une dynamique partiellement commune. Leur histoire serait comparable à plusieurs langues : certaines structures se partagent, d’autres restent propres à chaque langue. Un modèle de type GPT pourrait apprendre cette structure par préentraînement sur une grande collection de séquences réelles, puis estimer la distribution des prochains prix.

Cette hypothèse est scientifiquement cohérente et testable. Sa forme la plus défendable est **« une dynamique commune partielle, complétée par des dynamiques propres aux actifs »**. Elle n’exige ni une variable unique qui expliquerait tout, ni que chaque marché soit traduisible sans perte dans chaque autre. « Marché latent » désigne un état mathématique appris, dont la dimension et les composantes sont à déterminer.

Il faut séparer deux mécanismes : **partager une grammaire**, grâce à des paramètres appris sur des historiques différents ; **observer plusieurs vues simultanées**, grâce aux informations disponibles sur d’autres actifs au même moment. Le premier peut améliorer un modèle même lorsque les historiques ne se chevauchent pas. Le second exige un alignement temporel rigoureux. Les confondre ferait attribuer à un « marché commun » un gain provenant seulement de davantage de données d’entraînement.

2. Six travaux et une évolution de 2026, avec leur portée exacte

Source	Résultat ou mécanisme pertinent	Portée pour TRAME
Vaswani et al., 2017 - Attention Is All You Need	Architecture fondée sur l’attention ; traitement parallèle à l’entraînement et représentation de relations dans une séquence. Les expériences initiales concernent notamment la traduction.	Justifie l’étude d’une architecture Transformer ; ne démontre aucune propriété particulière des marchés. Notice et résumé consultés. Source primaire.
Woo et al., 2024 - Moirai	Patches de plusieurs tailles, attention acceptant un nombre variable de séries et sorties probabilistes ; préentraînement sur des domaines hétérogènes. Les auteurs précisent qu’un gain faible avec la taille à corpus fixe ne constitue pas une réfutation solide du scaling.	Appui direct à un modèle partagé entre fréquences et variables ; les performances décrites n’établissent pas notre hypothèse financière. Méthode et analyse du scaling consultées. Méthode et section 4.2.
Liu et al., 2023/2024 - iTransformer	Chaque historique de variable devient un token ; l’attention porte sur les relations entre variables. L’article examine le risque de mélanger trop tôt des mesures de sens différent ou des événements décalés.	Montre que le choix de l’axe des tokens est une variable scientifique majeure. Ce modèle supervisé ne constitue pas à lui seul une preuve de modèle fondation universel. Méthode et introduction consultées. Version du 14 mars 2024.

Source	Résultat ou mécanisme pertinent	Portée pour TRAME
Ansari et al., 2025 - Chronos-2	Alternance d'attention temporelle et d'attention entre séries d'un groupe, patches, masques et covariables connues. Prévision universelle étudiée sur plusieurs benchmarks ; certaines dépendances multivariées de préentraînement sont synthétiques.	Source de conception pour le partage entre actifs et la gestion des données manquantes. Le corpus réel voulu pour TRAME reste une décision propre au projet. Méthode consultée. Rapport primaire.
Jain et Sen, Google Research, 31 août 2026 - TimesFM-3	Modèle de 330 M paramètres, patches de 32 points et alternance d'attention temporelle causale et d'attention entre séries. L'horizon masqué est décodé en une passe.	Exemple récent montrant qu'un décodeur Transformer peut utiliser une sortie non autorégressive. Les neuf quantiles annoncés par cible et horizon décrivent des marges ; ils ne spécifient pas une loi jointe complète. Annonce technique des auteurs consultée, sans reproduction. Source primaire.
Yao et al., ICLR 2025 - Towards Neural Scaling Laws for Time Series Foundation Models	Étudie paramètres, données et calcul sur un corpus non financier filtré à SNR supérieur à 20 dB.	Motive le programme, sans établir une loi pour les prix à la seconde. La version 3 du 18 mars 2025 confirme ce filtre ; les ressources y sont étudiées séparément. Texte primaire.
Locatello et al., ICML 2019 - Challenging Common Assumptions in the Unsupervised Learning of Disentangled Representations	Montre, dans son cadre théorique, la non-identifiabilité du désentrelacement non supervisé sans hypothèses inductives sur modèle et données.	Une représentation efficace ne révèle pas automatiquement les « vrais facteurs » économiques. Cela ne démontre pas l'impossibilité de prévoir ni l'impossibilité d'identifier des modèles temporels sous hypothèses supplémentaires. Notice PMLR et résumé consultés. Publication primaire.

Ces références étayent des composants et des méthodes. Aucun résultat cité ici ne prouve une intelligence générale du modèle, une prédictibilité universelle des prix ou un seuil magique de paramètres.

3. Modèle formel : des vues communes et des dynamiques propres

Notons `a` un instrument réel, `t` un instant physique et `P_a(t)` son prix observé selon une définition documentée. Un modèle conceptuel possible est :

```
P[a,t] = G[a](z[t], u[a,t], m[a,t]) + epsilon[a,t].
```

`z_t` représente les composantes partagées ; `u_a,t` les composantes propres à l'actif ; `m_a,t` les métadonnées observables, dont unité, calendrier et type de mesure ; `epsilon` la part d'erreur ou d'aléa du modèle. Cette équation est une hypothèse de conception, pas une découverte empirique. `G_a` peut partager une grande partie de ses paramètres avec les autres actifs, avec une adaptation limitée par famille.

L'objectif principal est une distribution conditionnelle :

`p_theta({P[a,t+h]} pour a et h | F[t])`, où F[t] contient les observations effectivement disponibles au plus tard à t.

Cette formulation distingue prix futur, horizon physique et information disponible. Un modèle qui prédit chaque actif séparément n'est pas nécessairement un modèle de distribution jointe. Les dépendances entre futurs des actifs et entre horizons doivent être évaluées explicitement si le modèle les revendique.

Multivarié et joint ne sont pas synonymes. L'information d'autres actifs peut améliorer les quantiles marginaux d'une cible sans que le modèle décrive la dépendance entre tous les futurs. Deux processus peuvent avoir les mêmes marges et des corrélations très différentes. Les références à quantiles servent donc au comparatif marginal ; une ambition de trajectoires conjointes exige un générateur ou une structure de dépendance supplémentaire et des évaluations distinctes.

Trois hypothèses concurrentes

H0 - langues principalement distinctes. Le partage n'améliore pas suffisamment les prévisions hors échantillon à ressources comparables. Des modèles par famille ou par actif restent meilleurs.

H1 - grammaire partagée. Un préentraînement commun améliore les prévisions d'actifs réservés ou disposant de peu d'historique, même lorsque l'inférence utilise uniquement leur propre passé. Le gain provient d'une représentation transférable.

H2 - état partagé informatif. En plus de H1, des observations alignées d'autres actifs améliorent la prévision de la cible. Le gain diminue lorsqu'on détruit spécifiquement l'alignement entre actifs en conservant leurs historiques marginaux.

H1 peut être vraie sans H2. H2 peut concerner certaines familles ou certains régimes sans être universelle. Une combinaison de composantes communes et spécialisées est un résultat possible, et ne représente pas un échec du projet.

Identifiabilité : ce que signifie « découvrir le marché »

Si une transformation inversible T remplace z par $z'=T(z)$ et les décodeurs par $G'_a=G_a\ T^{-1}$, les prix décrits peuvent rester identiques. Les observations seules ne choisissent donc pas forcément une unique orientation ou signification des coordonnées latentes. Cette ambiguïté simple est compatible avec une bonne prévision.

Le critère primaire doit être l'information prédictive transférable. Pour interpréter ensuite une coordonnée comme « facteur commun », il faut des tests additionnels : stabilité entre initialisations, transfert vers des actifs absents de l'apprentissage, relation à des variables externes réservées et robustesse aux changements de régime. Des cartes d'attention ou des groupes visuellement séduisants ne suffisent pas. Les hypothèses temporelles, les vues multiples et des contraintes de structure peuvent aider l'identification ; leur efficacité doit être mesurée et leur rôle déclaré.

4. Une famille GPT comme axe principal de recherche

Le choix principal proposé est un **Transformer causal préentraîné sur séquences de marché**. « GPT » décrit ici une famille architecturale et un objectif autorégressif ; les tokens peuvent être numériques appris et n'ont pas besoin d'être des mots humains. Un vocabulaire appris conjoint et une sortie continue restent deux variantes comparables de cette même ambition.

La conversion peut suivre quatre niveaux : observation réelle → petit patch local → token ou vecteur appris → séquence du modèle. Les champs de contexte conservent l'actif ou ses métadonnées, la durée couverte, la disponibilité et les paramètres de normalisation causale. Un actif inconnu ne doit pas rendre le système inutilisable faute d'un identifiant appris : tester des métadonnées et une représentation calculée sur son contexte disponible.

Une architecture ambitieuse à tester comporte :

1. un encodeur local des prix ou patches de chaque actif ;
2. une attention temporelle causale dans chaque série ;
3. une attention entre vues déjà observées, avec masque d'âge et de disponibilité ;
4. une mémoire lente des sessions et régimes, pour les horizons longs ;
5. un décodeur génératif de distributions ou trajectoires, restituées dans les unités des instruments.

Le découpage factorisé est un choix de calcul à évaluer. Avec A actifs et T patches, une attention dense sur tous les couples actif-temps coûte schématiquement $O(A^2T^2)$ en interactions ; des blocs temporels et transversaux séparés donnent $O(AT^2+TA^2)$, hors dimensions cachées et autres couches. Un ensemble de latents partagés plus petit peut réduire encore le coût, au risque de supprimer des relations. Cela justifie une comparaison de représentations, pas l'empilement automatique de toutes les techniques.

Une variante Transformer à futur masqué peut servir de comparaison pour distinguer bénéfice du préentraînement, bénéfice de l'attention et bénéfice de l'autorégression. Cette comparaison ne nécessite pas de faire d'un modèle récurrent la voie principale. Les échecs d'un petit modèle d'une autre famille ne peuvent pas trancher la capacité du système proposé.

Prévoir le prix brut en conservant une représentation adaptée

La cible reste le prix dans son unité originale. Cela n'interdit pas une transformation interne inversible : par exemple $y=(P-P_{ancre})/s$, où l'ancre et l'échelle $s>0$ ne dépendent que du passé disponible. Le décodeur restitue $P=P_{ancre}+s\cdot y$. Pour les séries strictement positives, une variante logarithmique peut être comparée ; la version affine reste définie lorsque le domaine inclut zéro ou des valeurs négatives.

Conserver l'ancre et l'échelle évite de supprimer toute information de niveau. À l'inverse, utiliser directement tous les prix avec la même erreur quadratique donnerait une importance arbitraire aux unités les plus grandes. Si l'on compare des densités après transformation, inclure le jacobien : pour la transformation affine, $\log p_P(P)=\log p_y(y)-\log(s)$. La métrique doit correspondre à la variable réellement revendiquée.

« Prix » nécessite un contrat de données : dernier prix observé, référence quotidienne, milieu de cotation ou autre mesure. Un indice, une action et une série de contrats raccordés ne possèdent pas le même mécanisme de construction. Conserver ces différences comme métadonnées ; ne pas les effacer en les renommant toutes « close ».

5. Asynchronisme et plusieurs échelles

Un événement possède au moins une heure d'observation et, lorsque disponible, une heure de réception ou publication. L'attention à l'instant t n'accède qu'aux données connues à cet instant. Une observation de date civile identique peut avoir été publiée plus tard sur un autre marché. Une normalisation commune calculée sur la journée entière peut également introduire du futur.

Trois représentations temporelles sont à comparer : grille physique commune avec masques ; flux d'événements irréguliers avec délais ; structure hybride où les événements deviennent des résumés à plusieurs échelles. Le forward fill est admissible comme état « dernière observation connue » uniquement si l'âge et l'absence d'une nouvelle observation sont conservés. Il ne doit pas produire une fausse transaction ni une fausse bougie observée.

Le modèle peut utiliser des reconstructions multi-vues pendant le préentraînement, mais il faut séparer deux tâches. Compléter une vue manquante à une date historique en utilisant d'autres vues contemporaines est une tâche de représentation. Prévoir au-delà de l'instant courant doit masquer **tous** les futurs inconnus, y compris ceux des autres actifs. Sinon le résultat mesure la reconstruction d'un futur partiellement fourni.

6. Des décennies et la seconde : deux dimensions complémentaires

Des données fines peuvent révéler des structures supprimées par l'agrégation. Des décennies peuvent fournir des régimes absents d'une courte fenêtre. Collecter uniquement l'un des deux ne remplace pas l'autre. Le corpus doit donc être organisé suivant les axes **profondeur historique, granularité, familles d'actifs, diversité des régimes et qualité de mesure**.

Les épisodes autour de 2000, 2008 et 2020 peuvent constituer des domaines historiques utiles, mais leur rôle expérimental doit être fixé avant d'observer les scores. Pour une simulation de prévision historique de 2008, l'entraînement doit se terminer avant la période évaluée. Un modèle entraîné sur 2009-2026 puis évalué sur 2008 réalise une autre expérience de transfert rétrospectif, à nommer explicitement. Le fait de retirer les lignes de 2008 ne suffit pas à transformer cette seconde expérience en prévision prospective.

Une série à la seconde ne peut pas être reconstruite à partir de données horaires réelles sans inventer les variations intermédiaires. Le corpus doit accepter des résolutions et profondeurs hétérogènes avec masques. Les actifs qui n'existaient pas pendant un épisode ne reçoivent pas d'histoire artificielle. Un échantillon défini

uniquement par les actifs survivants aujourd'hui doit être déclaré comme tel et complété lorsque les sources le permettent.

Calcul d'ordre de grandeur, indépendant de toute disponibilité : 30 ans continus à une observation par seconde représentent environ **947 millions de points par actif**, soit **947 milliards pour 1 000 actifs**, avant champs supplémentaires. Les calendriers de cotation réduisent certains volumes. Ce calcul ne prouve pas qu'un tel corpus existe ou soit uniforme ; il montre l'intérêt de stockage hiérarchique, patching et échantillonnage.

La densité n'est pas l'indépendance. Multiplier les observations voisines pendant une même crise ne crée pas de nouvelles crises. Conserver des statistiques par blocs de temps, familles et régimes ; comparer de l'historique supplémentaire à un suréchantillonnage des mêmes journées. Un corpus plus grand doit être décrit par sa couverture autant que par son nombre de tokens.

7. Plan expérimental qui départage réellement les hypothèses

Question	Comparaison proposée	Observation qui soutiendrait l'hypothèse
Existe-t-il une grammaire transférable ?	Transformer par famille ; Transformer partagé recevant une seule série à la fois. Corpus et budgets de comparaison explicités.	Le partagé améliore les actifs réservés, à plusieurs horizons, sans dégrader systématiquement une famille.
Les autres vues contiennent-elles une information utile ?	Modèle partagé univarié ; modèle multivarié aligné ; version où l'alignement entre actifs est perturbé par blocs.	L'aligné améliore les prévisions ; la perturbation retire une partie du gain sans modifier le passé propre de la cible.
Le marché commun est-il seulement local à des familles ?	Paramètres totalement partagés ; tronc commun et adaptations par famille ; modèles séparés.	Des adaptations limitées améliorent le transfert tout en conservant le bénéfice du tronc commun.
La résolution fine apporte-t-elle de l'information ?	Même période et mêmes actifs en données fines, agrégées et patches multi-échelles ; comparaison à calcul fixé puis à information fixée.	Le gain persiste sur un futur réservé et n'est pas seulement lié à davantage d'étapes d'apprentissage.
Les décennies ajoutent-elles une diversité utile ?	Historique récent ; ancien+récent ; répétition du récent à nombre de tokens similaire.	L'ancien+récent améliore les régimes réservés davantage que la répétition.
Le tokenizer est-il le goulet d'étranglement ?	Quantification simple ; codes appris ; patches continus, avec architectures de taille et budgets documentés.	Les gains de représentation persistent quand la capacité augmente et se traduisent en meilleure prévision.
Les capacités sont-elles limitées par l'échelle ?	Grille de tailles, volumes de données et longueurs de contexte ; plusieurs initialisations aux points clés.	Courbes reproductibles où certaines erreurs diminuent avec capacité ou diversité, et extrapolations confirmées sur une échelle non utilisée pour les ajuster.

Le contrôle d'alignement doit préserver autant que possible saisonnalité, qualité des données et régimes marginaux ; une permutation arbitraire peut créer un problème trop artificiel. Le gain d'un modèle partagé doit être confronté à deux budgets : nombre de paramètres comparable et calcul total comparable. Un ensemble de petits modèles peut avoir davantage de paramètres cumulés qu'un seul modèle partagé.

Réserver séparément : une période future commune à tous les actifs ; des instruments ; une famille entière ; éventuellement une place et un épisode historique. Pour mesurer le transfert vers une classe absente, la classe doit aussi être absente de l'ajustement du tokenizer, du choix des normalisations globales et de la sélection des hyperparamètres.

Les métriques centrales sont prévision en unités d'origine par actif, erreur normalisée par une échelle calculée sur entraînement, score probabiliste approprié, couverture des intervalles et dépendance des chemins lorsque modélisée. Rapporter horizons et familles séparément, puis une agrégation équilibrée. La persistance du dernier prix constitue un repère indispensable : reproduire un niveau presque constant à horizon très court ne suffit pas à établir l'apprentissage des variations.

Pour les distributions marginales, employer par exemple CRPS ou des scores de quantiles comparables. Pour un générateur joint, ajouter score d'énergie, score de variogramme ou diagnostics ciblés de dépendance et de chemins, avec leur propre incertitude. Une victoire sur les marges ne sera pas présentée comme une victoire sur la distribution jointe.

8. Scaling : préserver l'ambition et diagnostiquer les échecs

Une campagne peut explorer, à titre de grille conceptuelle, 10 M, 40 M, 160 M, 640 M puis 1 B+ paramètres. Ces nombres sont des niveaux d'expérience possibles, pas des besoins démontrés ni un engagement d'exécution. À chaque niveau, faire varier les données et le contexte ; augmenter seulement les paramètres à corpus et optimisation insuffisants ne teste pas correctement le potentiel de la représentation.

Une loi exploratoire telle que `L(N,D)=L_inf+a·N^(−alpha)+b·D^(−beta)` peut aider à résumer les mesures. Elle doit comporter une incertitude, des contrôles de résidus et une validation sur un niveau non utilisé pour l'ajustement. Le plan doit suivre volume nominal, diversité par blocs et calcul dépensé. `L_inf` est un paramètre ajusté dans un domaine expérimental limité, pas une connaissance du plafond physique de prédictibilité.

Un petit échec peut venir d'un tokenizer trop destructeur, d'un contexte trop court, d'une optimisation inadéquate, d'un manque d'exemples rares ou d'un modèle incapable d'exploiter des dépendances pourtant présentes. Il ne réfute pas à lui seul H1 ou H2. Symétriquement, remettre tout résultat négatif au compte d'une taille encore insuffisante rendrait l'hypothèse impossible à tester. Chaque étape doit préciser ce qu'elle met à l'épreuve, l'incertitude restante et l'expérience suivante capable de la réduire.

Une erreur irréversible du tokenizer sur un attribut observé ne sera pas réparée exactement par davantage de paramètres ; le modèle pourrait néanmoins prévoir correctement une cible qui n'exige pas cet attribut. Une bonne reconstruction est donc une propriété utile, mais ni nécessaire dans tous ses détails ni suffisante pour une bonne prévision. Le POC de reconstruction existant mesure l'instrument de représentation ; il ne tranche pas encore la possibilité d'un marché latent partagé.

Le résultat recherché est une preuve graduelle : structure transférable, information croisée exploitable, puis progression mesurée avec données et capacité. Une amélioration démontrée sur ces dimensions constituerait un résultat scientifique fort, même sans attribuer une « intelligence » au réseau. Les sorties resteraient des distributions conditionnelles soumises à l'information observée et aux limites de généralisation établies par les expériences.

9. Une objection spécifique au Marché unique : le numéraire

L'acquisition réelle de six devises contre EUR rend une difficulté immédiatement concrète. Toutes les séries partagent une unité de référence. Une partie de leur mouvement commun peut donc provenir du dénominateur, même si les dynamiques propres des devises ne se sont pas rapprochées. Un latent très commun n'est pas automatiquement une découverte sur un mécanisme mondial.

Notons Q[a/EUR] le nombre d'unités de la devise a pour un euro, et Q[b/EUR] celui de b. La conversion dérivée donne Q[a/b] = Q[a/EUR] / Q[b/EUR]. Pour les variations logarithmiques entre les mêmes dates, on obtient exactement :

`r[a/b] = r[a/EUR] - r[b/EUR].`

Cette relation est une identité algébrique sous conventions cohérentes, pas un résultat statistique nouveau. Construire toutes les paires croisées peut multiplier le nombre de séries, mais ne crée pas autant de

nouvelles observations indépendantes. Une approximation due aux arrondis ou à des heures de mesure différentes ne doit pas être interprétée sans contrôle comme un nouveau facteur.

Trois expériences sont proposées. D'abord, changer le numéraire en conservant exactement les mêmes observations et mesurer la stabilité des prévisions ramenées à une cible commune. Ensuite, comparer un modèle qui reçoit explicitement la référence monétaire à un modèle qui doit l'inférer. Enfin, comparer la structure latente à des identités de conversion et à des facteurs linéaires simples ajustés sur le passé. Une amélioration résiduelle, reproduite ailleurs, serait plus informative qu'une visualisation de six séries qui bougent ensemble.

Ce contrôle n'exige pas l'invariance de toutes les coordonnées latentes : leur géométrie peut changer sous une transformation inversible. Il demande que les affirmations prédictives survivent au retour vers les mêmes prix et dates. Une conversion d'unités connue peut être traitée comme une symétrie ; la dynamique propre d'une devise de référence reste une information à modéliser.

La même précaution s'étend aux indices et produits apparentés, sans leur appliquer abusivement la formule des devises. Un indice, ses composants et un produit qui le suit possèdent des dépendances de construction. Ils ne doivent pas être répartis naïvement entre apprentissage et test comme des langues totalement nouvelles. La composition historique, les règles d'indice et les dates de disponibilité définissent le degré de séparation réellement obtenu.

10. Une grammaire cohérente entre résolutions

Une autre proposition est d'exiger que les prévisions fines et grossières décrivent le même futur possible. Soit A_h l'opérateur qui agrège une trajectoire fine en observation sur h secondes, minutes ou heures. La loi grossière devrait être compatible avec la loi obtenue en agrégeant les trajectoires fines :

`Loi_grossiere(. | F[t]) ≈ image_par_A_h(Loi_fine(. | F[t]))`.

Pour des bougies, A_h conserve la première ouverture, le dernier cours, le maximum des hauts, le minimum des bas et la somme des volumes compatibles. Il doit aussi conserver les intervalles incomplets et la définition du volume. Pour des références quotidiennes sans chemin intrajournalier, cet opérateur n'existe pas sous cette forme ; la branche ne reçoit pas une trajectoire fine inventée.

La cohérence s'évalue sur des distributions ou des trajectoires échantillonnées. Agréger des prédictions moyennes ne suffit pas : l'espérance d'un maximum n'est pas en général le maximum des espérances. Des marges bien calibrées peuvent ainsi produire un ensemble de résolutions incompatibles.

Le projet pourrait apprendre un vocabulaire local fin et une grammaire lente avec un objectif auxiliaire de cohérence. Le contraste scientifique serait le même GPT avec et sans ce terme, à calcul documenté, puis la vérification sur des fréquences et actifs réservés. Trop de contrainte peut dégrader les prévisions si l'agrégation, les observations ou le modèle sont mal spécifiés ; la cohérence ne devient donc pas un dogme.

Ces deux axes, symétries d'unité et cohérence d'agrégation, donnent un sens technique à l'idée de plusieurs langues décrivant un même Marché. Ils ajoutent des relations vérifiables entre représentations. Leur nouveauté et leur bénéfice devront être évalués par rapport aux travaux existants ; aucune expérience prédictive ne les a encore départagés dans TRAME.

TRAME : corpus réel, langage typé et protocole de prévision

Complément scientifique 2.1, 15 octobre 2026. Ce document précise et, sur les points indiqués, amende les documents 02 à 08. Il distingue acquisition réalisée, résultat mathématique et expérience proposée. Aucun réseau prédictif n'a été développé ou entraîné.

À lire d'abord : ce qui change

Le langage doit décrire comment un prix a été observé, en plus de sa forme. Une moyenne mensuelle, une clôture, un fixing et une transaction ne sont pas interchangeables. Nous proposons d'ajouter au langage des types d'observation, des unités, des périodes et des instants de disponibilité. Les actifs peuvent partager une grammaire tout en gardant ces différences de sens.

Un nouveau fichier réel a été acquis auprès de la Banque mondiale. Six séries - or, argent, cuivre, Brent, maïs et blé - contiennent chacune 732 valeurs mensuelles entre janvier 1960 et décembre 2020. Cela apporte des périodes historiques très différentes. Cela ne fournit pas leurs trajectoires à la seconde. La définition de l'or change en juin 2025 dans la description du fichier : un symbole constant n'implique pas un instrument de mesure constant.

Une régularité peut venir de la mesure. Le moyennage d'un prix dont les variations sont indépendantes peut produire des variations de moyennes autocorrélées. Ce phénomène classique oblige à comparer un futur modèle à un témoin qui connaît le mode d'observation. Une bonne prévision des moyennes demeure utile scientifiquement, mais ne suffit pas à démontrer une prédictibilité nouvelle du prix instantané.

Pour transformer les courbes en langage, nous précisons un vocabulaire à précision progressive : partie entière, détails successifs, puis éventuellement résidu. Le même prix peut être lu grossièrement ou finement. Une voie spéciale doit conserver les grandes amplitudes. Cette construction est une proposition à tester ; la hiérarchie grossier/fin existe déjà dans des travaux comme Kronos.

Le prochain protocole sépare trois questions : quelle représentation aide le modèle, ce qu'apporte le partage entre actifs, et ce qu'apporte l'observation des autres actifs. Le prix cible, les dates et les informations disponibles restent identiques dans chaque comparaison. Le GPT reste central. Les petites expériences servent à comprendre les conditions de réussite et d'échec, sans condamner une famille entière.

La limite actuelle est précise : nous avons des données réelles et un plan d'expérience plus discriminant, mais aucun résultat de prévision. La constitution d'un corpus de transactions et cotations multi-marchés à haute fréquence reste à réaliser.

1. Une observation n'est pas seulement un nombre

Notons `P_a(s)` une trajectoire conceptuelle associée à l'instrument a. Une observation s'écrit `Y_j = O_j[P_a] + e_j`, où `O_j` désigne son opérateur de mesure. Cette écriture est un modèle conceptuel : un prix efficient unique sous-jacent n'est pas supposé directement accessible, et les différentes places peuvent porter des prix distincts.

Un opérateur peut être la dernière transaction admissible avant une heure, un milieu de fourchette à un instant, un fixing, une moyenne de fixings, le maximum des transactions d'une période ou une formule d'indice. Les modalités de sélection des transactions, les corrections et les conventions de calendrier font partie de cet opérateur. Elles peuvent évoluer.

Le dossier v2 représentait déjà les temps de disponibilité et les valeurs manquantes. L'amendement est d'en faire une **syntaxe obligatoire de la langue**, avec un rôle expérimental mesurable, plutôt qu'un simple nettoyage préalable.

Champ du contrat d'observation	Rôle scientifique
instrument, place, contrat, échéance	Désigner ce qui est observé ; identifier les changements de contrat
unité, devise de cotation, tick	Permettre le décodage physique ; distinguer échelle et précision
opérateur et version	Séparer moyenne, fixing, transaction, clôture, règlement et indice
début et fin de support temporel	Dire quelle période contribue au nombre
horodatage de l'événement et de disponibilité	Exclure une valeur publiée après l'origine de prévision
source, version reçue, correction	Distinguer un historique révisé des observations disponibles à l'époque
état de présence et âge	Distinguer observation nouvelle, valeur ancienne, absence de transaction, fermeture et lacune inconnue
relations structurelles	Signaler les composites, contrats successifs, composantes d'indice et changements de numéraire

Les champs constants peuvent être encodés une fois par séquence, puis modifiés seulement lorsqu'ils changent. Ils ne justifient pas une répétition coûteuse de longs identifiants sur chaque seconde. Une version inconnue est un état explicite ; elle n'est pas devinée à partir d'un résultat futur.

Deux courbes du même actif, issues de fixings et de transactions, peuvent être deux observations différentes d'un phénomène lié. Deux actifs distincts libellés en dollars peuvent partager une fluctuation du numéraire. Le « Marché unique » doit donc être étudié avec des variables communes, des variables propres et des opérateurs de mesure. Une représentation latente qui ignore le dernier terme peut confondre convention de publication et mécanisme économique.

2. Nouvelle acquisition réelle : ce que le fichier prouve

Le classeur mensuel a été téléchargé depuis le site officiel de la Banque mondiale le 15 octobre 2026 à 07:09:25 UTC. Taille : 586 099 octets. La mise à jour indiquée est le 2 octobre 2026. Le manifeste conserve l'URL, les en-têtes et l'empreinte SHA-256 :

`ea1c350827878ea3bbe30e3cda16a13fd3bd5b409b8458940dc94a36b5a33154`

L'audit en lecture seule porte sur les cellules sources. La feuille Monthly Prices comporte 801 mois consécutifs, de janvier 1960 à septembre 2026, et 71 colonnes de séries nommées. Elle contient 50 451 valeurs numériques, 6 416 absences et quatre erreurs Excel. Ces nombres sont des mesures de ce fichier, pas une déclaration générale de qualité de la source.

Série sélectionnée	Unité du fichier	Valeurs 1960-2020	Plage source
Gold	USD / once troy	732	BR7:BR738
Silver	USD / once troy	732	BT7:BT738
Copper	USD / tonne métrique	732	BM7:BM738
Crude oil, Brent	USD / baril	732	C7:C738
Maize	USD / tonne métrique	732	AE7:AE738
Wheat, US HRW	USD / tonne métrique	732	AL7:AL738

Ces 4 392 cellules sont numériques, positives et sans absence. Nous les avons choisies pour leur diversité économique et leur profondeur, sans chercher un résultat prédictif favorable. La présence d'une valeur sous un nom actuel en 1960 ne certifie pas que l'instrument actuel existait alors sous cette définition. Les prolongements historiques et les changements de fournisseur restent à qualifier avant une interprétation causale des ruptures.

Les erreurs `#VALUE!` concernent Rice, Thai 25%, en août 1988, juin 1989, juin 1990 et février 2008, aux cellules AH350, AH360, AH372 et AH584. Elles sont conservées comme erreurs. Les absences sont 6 332 ellipses Unicode et 84 séquences de trois points. Le premier passage du parseur s'est arrêté ; après inspection des caractères et des types Excel, les marqueurs d'absence ont été explicités. Aucun nombre n'a été inventé. La feuille Mismatch Details comporte 152 lignes de comparaison interne : elle n'a pas été interprétée comme une instruction de corriger les observations.

La cellule Description!B103 décrit pour l'or une moyenne de cours spot à partir de juin 2025, précédée d'une moyenne des fixings de l'après-midi de Londres. Ce changement rend nécessaire un indicateur de définition. Il ne démontre ni rupture économique ni erreur de prix. Le bulletin d'octobre 2026 décrit aussi des révisions et remplacements de séries : un historique reçu aujourd'hui n'est pas une archive de chaque publication d'origine.

Le catalogue Banque mondiale déclare cet ensemble public sous CC BY 4.0 et une mise à jour des prix le deuxième jour ouvré du mois. Ce calendrier général ne fournit pas les heures de disponibilité de chaque observation historique. Le catalogue contient aussi des projections : elles ne doivent jamais devenir des prix observés. Ici seule la feuille historique mensuelle a été auditée.

Le classeur entier a été reçu et sa couverture examinée. Il est exploratoire. Aucune partie ne sera présentée comme un test final jamais inspecté. Les 732 mois par série jusqu'à 2020 représentent 732 dates communes, et non 4 392 épisodes macroéconomiques indépendants.

3. Matrice des sources et des questions admissibles

Source et cible concrète	Profondeur et résolution qualifiées	Usage possible et limite
Banque mondiale : six matières premières ci-dessus	Fichier réel 1960-2026 ; sélection documentaire 1960-2020 mensuelle	Histoire longue et conventions ; pas de chemin intrajournalier ni de volume

Source et cible concrète	Profondeur et résolution qualifiées	Usage possible et limite
BCE : USD, JPY, GBP, CHF, CAD, AUD contre EUR	Acquisition antérieure 1999-2020, quotidienne	33 792 valeurs de référence ; numéraire partagé ; disponibilité historique à qualifier
FRED : série SP500	Catalogue : clôture quotidienne, dix années glissantes	Source récente de niveau d'indice ; ne couvre pas 2000/2008 aujourd'hui ; pas acquise ici
NYSE Daily TAQ : actions et fonds cotés américains admissibles	Catalogue depuis 1993 ; transactions et cotations	Peut couvrir 2000/2008 ; accès sous licence, échantillon et conventions non audités ici
Databento GLBX.MDP3 : contrats GC et ES à identifier	Catalogue futures depuis juin 2010 ; schémas transactions/cotations et OHLCV 1 s	Candidats or et indice à haute fréquence ; ne couvre pas 2000/2008 dans ce catalogue ; pas acquis

Les trois dernières lignes sont des qualifications documentaires, pas des fichiers déjà disponibles pour entraîner TRAME. Aucun achat ni compte n'a été engagé. Le prix d'un futur GC est une cible différente d'un fixing de l'or. ES est un contrat à terme lié au S&P 500 ; il n'est ni l'indice lui-même ni une série de ses actions. « S&P 500 » est ici une hypothèse de lecture du « SP550 » cité par le porteur.

La fiche FRED SP500 précise la clôture quotidienne, l'absence de dividendes dans cet indice de prix et la fenêtre de dix ans ; elle impose aussi des restrictions de reproduction. Une vue publique n'établit pas le droit de redistribuer un corpus. La fiche NYSE Daily TAQ donne 1993 comme début d'historique. Le manuel v4.3, section 1.5.5, précise que les horodatages historiques ont évolué de la seconde vers la milliseconde, puis la microseconde et la nanoseconde. Il serait faux de supposer une précision homogène sur trente ans.

Le catalogue Databento annonce la couverture futures CME à partir de juin 2010. La définition OHLCV précise des intervalles de 1 seconde à 1 jour, des barres horodatées au début, l'absence de ligne lorsqu'il n'y a pas de transaction et une journée UTC. La construction utilise les temps de réception des transactions ; le règlement officiel est un objet distinct. Ces conventions devront être enregistrées, pas seulement déduites du suffixe « 1s ».

La documentation des contrats continus conserve les prix non ajustés des contrats successifs. Un saut au changement de contrat n'est donc pas automatiquement un mouvement du même actif. Notre cible proposée reste le contrat explicitement identifié, avec des horizons qui ne franchissent pas son changement d'identité ; l'étude des raccordements sera une expérience distincte.

Les familles d'actions devront inclure des titres sortis de cote et des identités historiques, selon une règle d'univers définie au moment considéré. Choisir aujourd'hui les seules grandes valeurs survivantes sélectionnerait le passé avec une information future. Les composites ne seront pas répartis au hasard entre apprentissage et test si leurs composantes y dévoilent déjà presque la même cible.

4. Un contre-exemple analytique à intégrer au raisonnement

L'effet de l'agrégation temporelle est connu depuis Working (1960) ; Crawley (2019) en expose à nouveau les conséquences. Le rapprochement avec notre corpus est essentiel : une régularité de la série mesurée peut venir de la méthode de mesure. Il ne s'agit pas d'une découverte empirique de TRAME.

Voici une dérivation autonome pour clarifier la cible. Supposons, à titre de contre-exemple mathématique et non comme description de l'or, `P(s) = P(0) + sigma W(s)` avec W brownien standard. Pour des périodes de durée Delta, définissons `A_k = (1/Delta) intégrale P(s) ds` sur la période k, et `D_k = A_k - A_(k-1)`.

Par échange des intégrales, D_k reçoit deux contributions d'incréments indépendants : ceux de la période précédente avec un poids croissant de 0 à 1 et ceux de la période courante avec un poids décroissant de 1 à 0. On obtient :

`Var(D_k) = sigma² Delta (1/3 + 1/3) = 2 sigma² Delta / 3.`

`Cov(D_k, D_(k+1)) = sigma² Delta intégrale_0^1 u(1-u) du = sigma² Delta / 6.`

Donc `Corr(D_k, D_(k+1)) = 1/4`. Les variations entre deux prix de fin de période demeurent indépendantes dans ce contre-exemple. Comme les D sont gaussiens, la prévision utilisant seulement D_k satisfait `E[D_(k+1) | D_k] = D_k/4`. Ce n'est pas la formule du meilleur prédicteur utilisant tout le passé.

On peut ainsi prévoir une partie de la prochaine variation de moyenne sans avoir découvert de dépendance entre les prochains incréments instantanés. Ce résultat analytique n'est ni une simulation ajoutée au corpus ni une mesure sur les données Banque mondiale. La valeur 1/4 dépend des hypothèses ; elle ne sera pas imposée aux vraies données comme une constante universelle.

Conséquence expérimentale : chaque résultat sera attribué à son objet. Prévoir une moyenne mensuelle et prévoir une clôture mensuelle sont deux tâches. Un témoin avec le bon opérateur d'observation devra accompagner les témoins de persistance et de dynamique simple. Un gain résiduel ne prouve pas immédiatement un motif économique inconnu ; il peut aussi refléter un témoin encore mal spécifié.

5. Une grammaire progressive, décodable et conditionnelle

5.1 Alphabet commun et information auxiliaire

L'objet de départ X est un passé réellement observable. Le code est `Z = f(X, S)` ; S contient les informations communes nécessaires au décodage : ancre, échelle passée, unité, temps et métadonnées autorisées. Ces informations ne sont ni gratuites ni optionnelles dans une comparaison. L'hypothèse de recherche est qu'une représentation peut rendre un même contenu plus facile à apprendre sous calcul limité, pas qu'un changement de notation crée de l'information.

Pour une même cible future Y et une même mesure de densité, l'identité du document 01 devient :

`E[-log q(Y | Z,S)] = H(Y | X,S) + I(Y;X | Z,S)`

`+ E_(Z,S) KL[p(Y | Z,S) || q(Y | Z,S)].`

Cette écriture suppose Z déterministe et les quantités définies. Le deuxième terme mesure l'information prédictive perdue dans le code. Le troisième inclut l'écart du modèle et de son apprentissage. Une reconstruction presque parfaite de X ne garantit pas une petite erreur d'apprentissage. À l'inverse, jeter des détails peut aider un modèle fini en régularisant, sans améliorer l'information théorique disponible.

5.2 Construction pédagogique à niveaux emboîtés

Pour un nombre x normalisé causalement, posons `q0 = floor(x)` et `r0 = x - q0`. Pour j de 1 à J : `b_j = floor(2 r_(j-1))`, puis `r_j = 2 r_(j-1) - b_j`. Les détails b_j sont binaires. L'intervalle décodé a pour borne basse `q0 + somme_j b_j 2^(-j)` et pour largeur `2^(-J)`. Son milieu reconstruit x avec une erreur au plus `2^(-J-1)`.

Exemple purement pédagogique : x = 2,70 donne q0 = 2 puis les quatre bits 1, 0, 1, 1. Le milieu de l'intervalle est 2,71875. Si le prix physique est `P = 100 + 10 x`, la valeur est 127 et la reconstruction 127,1875, avec une borne d'erreur de 0,3125. Ces valeurs sont inventées pour expliquer le code ; elles ne sont pas des observations de marché.

La partie entière ne doit pas être écrêtée silencieusement à un vocabulaire fini. Un code entier de longueur variable ou un symbole ESC suivi d'une amplitude conserve les grandes valeurs. Pour x négatif, la même définition par floor reste valide ; le code entier doit porter son signe. Pour les géométries OHLC du document 02, les amplitudes de mèches doivent rester non négatives au décodage. Pour les prix nuls ou négatifs, la transformation affine ou asinh remplace le logarithme.

Cette construction ne définit pas encore le meilleur tokenizer. C'est un témoin interprétable à comparer aux cellules fixes, aux vocabulaires appris et aux entrées continues. Les échelles passées sont strictement

causales ; leur précision et leur transmission sont comptées. Le nombre J devient une variable contrôlée. Si l'on choisit J après avoir vu l'amplitude d'une observation passée, sa longueur fait elle-même partie de l'information transmise. Pour une observation future, on ne peut pas choisir J avec sa vraie valeur avant de la prédire.

5.3 Prédire les mots et prédire le prix

Deux expériences complémentaires sont nécessaires. Dans P1-A, les différentes langues décrivent seulement le passé, puis le même type de tête continue prédit le même prix physique. On isole mieux l'effet de la représentation d'entrée. Dans P1-B, le GPT prédit réellement les composantes du prochain code, puis ses raffinements et éventuellement un résidu : on teste la factorisation générative complète recherchée par le projet.

La loi P1-B se factorise par exemple en `p(q0_future | passé) × produit_j p(b_j_future | passé, q0_future, b_<j_future)`. Pendant la génération, les composantes déjà produites peuvent conditionner les suivantes ; leurs vraies valeurs futures ne sont pas fournies. Un entraînement avec conditionnement sur les composantes cibles précédentes peut représenter une factorisation valide de vraisemblance, mais son évaluation doit ensuite reproduire la génération réelle.

Une distribution de tokens ne donne pas automatiquement une densité de prix comparable. Il faut expliciter la loi à l'intérieur de chaque cellule, les queues, les résidus et le changement d'unité. Une perplexité inférieure avec moins de détails peut simplement récompenser une cible plus facile. Le jugement final porte sur la même variable physique. Les bornes de reconstruction présentées plus haut ne sont jamais des bornes d'erreur de prévision.

L'antériorité est explicite : Kronos utilise déjà une hiérarchie de sous-tokens grossiers et fins pour des données financières et un modèle autorégressif. Le caractère à étudier ici est la combinaison d'une sémantique d'observation explicite, d'une précision contrôlée, de résidus et de comparaisons à information commune. La nouveauté scientifique de cette combinaison n'est pas établie par notre recherche actuelle.

5.4 Mesurer le coût sans confondre les unités

Un rapport devra distinguer bits sérialisés, tokens présentés au GPT, nombre de prix observés, durée historique couverte, paramètres et opérations. Un champ float32 n'est pas un nombre réel de précision infinie. Plusieurs détails binaires peuvent être regroupés en un token ; un token rare à grande amplitude peut au contraire demander plusieurs mots. Les identités et ancres constantes s'amortissent sur la séquence, mais leur coût ne disparaît pas.

On ne peut généralement égaliser tous les axes à la fois. Deux fronts de comparaison sont proposés : même contenu observable et même capacité approximative ; puis même budget de calcul pour une tâche physique donnée. Un budget de tokens identique qui raccourcit fortement le passé pour une langue ne permet pas d'attribuer le résultat au seul vocabulaire. Le rapport exposera ces deux compromis plutôt qu'un classement unique.

6. Protocole P1 proposé, non gelé et non exécuté

6.1 Trois tâches séparées

P1-M : prévoir la prochaine moyenne mensuelle publiée, puis les horizons 3 et 12 mois, en unités natives. Les séries Banque mondiale servent à concevoir ce protocole, avec des versions disponibles à la date d'origine si elles sont retrouvées. Sans ces versions, l'expérience sera désignée « rétrospective sur historique révisé », et sa portée sera limitée en conséquence. Une hypothèse de délai de publication ne corrige pas les révisions futures du passé.

P1-D : prévoir la prochaine référence quotidienne BCE, puis 5 et 20 publications. Un horizon en nombre de publications n'est pas un nombre fixe de jours civils ; les deux durées sont consignées. Six références contre EUR offrent un premier test de transfert et de numéraire, sans prétendre représenter tous les marchés.

P1-S : après acquisition qualifiée, prévoir à 1, 10 et 60 secondes un prix précisément défini pour GC, ES et un univers historique d'actions. Le dernier prix observé à la frontière, le milieu de fourchette et le prochain prix de transaction seront des cibles distinctes. Une seconde sans transaction ne produit pas une transaction fictive. Pour la dernière transaction connue, son âge fait partie de l'état, et les résultats sont séparés selon qu'un nouvel événement intervient ou non dans l'horizon.

Ces tâches partagent des principes et éventuellement des paramètres, pas une cible statistique artificiellement identique. Le résultat primaire ne sera pas une moyenne de dollars, de points d'indice et de taux de change. Les erreurs en unités natives restent disponibles ; les agrégations utilisent des poids d'actifs fixés et des échelles calculées avant le test. Un score relatif au témoin est calculé à l'intérieur de chaque série avant agrégation, avec traitement explicite des dénominateurs nuls.

6.2 Comparaisons qui identifient une question

Pour un actif cible a, notons `L_a` un GPT entraîné seulement sur son histoire, `G_a` un GPT aux paramètres partagés entre actifs mais n'observant que l'histoire de a à l'inférence, et `M_a` un GPT partagé observant aussi les autres actifs disponibles. Les trois emploient la même cible et le même contrat d'observation.

Contraste	Interprétation autorisée	Contrôle nécessaire
G_a contre L_a	Bénéfice du partage et du corpus d'apprentissage élargi	Rapporter exposition de la cible, budget total et nombre de paramètres ; ce contraste seul ne sépare pas tous ces facteurs
M_a contre G_a	Utilité conditionnelle du contexte d'autres actifs	Même architecture M entraînée avec masque des autres actifs comme témoin ; mêmes dates et mêmes origines
M_a contre contexte ancien	Valeur des observations croisées récentes	Retards fixés à l'avance ; historique marginal conservé ; interprétation d'ablation, sans p-value de permutation automatique
Même GPT, plusieurs encodages du même X	Effet de la représentation sous contraintes déclarées	Tête de sortie, fenêtre temporelle et information auxiliaire communes dans P1-A
Même langue, capacité croissante	Effet d'échelle dans la région étudiée	Quantité et diversité contrôlées ; diagnostic de convergence et plusieurs initialisations

Le témoin masqué doit être entraîné dans cette condition : masquer seulement au test un modèle habitué à tous les actifs créerait un décalage artificiel. Le partage H1 sera également étudié sous budget total égal et sous exposition cible égale ; ces comparaisons répondent à des questions différentes. Un expert local reçoit, si nécessaire, davantage de répétitions de sa propre histoire, sans les compter comme de nouvelles observations.

Une permutation aléatoire des secondes détruirait la dynamique. Des décalages de séries peuvent changer saisonnalités et régimes ; ils ne constituent donc pas automatiquement une randomisation valide. Le témoin prioritaire est un contexte absent ou vieilli, entraîné dans les mêmes conditions. Les décalages éventuels restent des stress tests explicitement imparfaits.

6.3 Découpage temporel et dépendances

Pour la mise au point historique mensuelle, une proposition est 1960-1999 pour l'ajustement initial, 2000-2009 pour le développement et 2010-2020 comme pseudo-test rétrospectif, avec origines successives et apprentissage uniquement dans leur passé. Ces périodes ont des significations différentes et ne donnent pas à elles seules une preuve de stabilité. Elles font déjà partie du fichier reçu ; elles ne sont pas un futur test scellé.

Le test final devra être séparé avant la sélection des langues : nouvelle tranche temporelle ou famille non utilisée pour choisir les variantes, avec inventaire des modèles préentraînés et de leurs corpus. Si une famille est réservée pour tester son transfert, ses prix futurs ne peuvent pas être réintroduits comme contexte croisé d'un autre échantillon. Les composantes, composites, dérivés et conversions de devise sont regroupés pour vérifier ce point.

Toutes les séries utilisent la même coupure en temps de disponibilité. Les fenêtres d'apprentissage dont la cible franchit la coupure sont retirées. Un contexte historique antérieur peut légitimement être lu à une origine de test ; interdire arbitrairement tout contexte partagé n'est pas requis par la causalité. Les prévisions à horizons chevauchants et les actifs contemporains restent dépendants.

Les statistiques d'incertitude sont calculées sur des différences de pertes appariées, en rééchantillonnant des blocs temporels communs à tous les actifs. La longueur des blocs doit couvrir au moins l'horizon de chevauchement et faire l'objet d'une sensibilité. La stabilité selon les actifs, les décennies et les conventions est montrée séparément. Plusieurs fenêtres d'un même choc ne sont pas plusieurs crises indépendantes.

6.4 Scores, échelle et droit de ne pas conclure

P1-A pourra utiliser une grille de quantiles commune, évaluée par pertes quantiles, couverture et largeur d'intervalles, avec médiane évaluée en erreur absolue native. La grille et les règles de monotonie seront fixées avant comparaison. Ces sorties marginales ne prétendent pas représenter une loi jointe de trajectoires ; P1-B devra l'évaluer séparément, avec des scénarios complets et leurs propriétés temporelles.

Le premier tour compare un petit nombre d'encodages interprétables sur une capacité diagnostique, puis conserve une branche continue de référence et une branche progressive pour plusieurs capacités. Une variante peu performante à petite taille demeure dans le registre ; elle peut être retestée à une capacité supérieure selon un critère annoncé. Les réglages, essais infructueux et changements de protocole sont comptés, pas seulement les modèles finaux.

Une amélioration sera déclarée localement pour les tâches, périodes, budgets et familles testés. Son absence avec un intervalle large est un manque de précision. Son absence avec un intervalle étroit borne l'effet dans cette configuration. Aucun de ces deux résultats ne réfute toutes les langues, toutes les tailles et toutes les informations possibles. À l'inverse, l'espoir d'une émergence à grande échelle ne remplace pas une hypothèse testable sur la direction et les conditions du progrès.

7. Nouveau cycle du panel critique simulé

Ce cycle est une confrontation raisonnée entre rôles fictifs. Les trois tâches parallèles d'agents tentées pour cette itération ont échoué sur une limite de service et n'ont produit aucune relecture exploitable. Les conclusions ci-dessous ont été élaborées et vérifiées par l'agent principal ; aucune validation indépendante n'est revendiquée.

Rôle fictif	Objection	Modification retenue
Spécialiste de la mesure	Un motif peut venir d'une moyenne ou d'un changement de fournisseur	Opérateur typé et version dans le langage ; témoin avec agrégation

Rôle fictif	Objection	Modification retenue
Chercheur GPT	P1-A ne teste pas encore la génération du prochain token	Ajouter P1-B autorégressif, tout en isolant d'abord la représentation d'entrée
Théoricien de l'information	Les ancres et résidus peuvent cacher presque tout le signal	Inclure S dans les équations et publier le coût total
Économètre	Plus d'actifs ne signifie pas plus de chocs indépendants	Blocs temporels communs et contrôles de numéraire/composites
Ingénieure de données	« 1 seconde » ne signifie pas la même chose selon le fournisseur et l'époque	Vérifier précision, convention de barres, absence de transaction et disponibilité
Porteur du projet	Un protocole trop petit risque d'écarter la bonne langue	Garder un programme d'échelle et limiter chaque conclusion à sa configuration

L'objection la plus forte à notre propre proposition reste le coût de la richesse : multiplier types, résidus et vues peut rendre la langue difficile à apprendre et favoriser la mémorisation des sources. Il faut donc une ablation « avec/sans types connus », un test sur un fournisseur différent et un test sur une version de mesure différente. Les types n'ont pas vocation à identifier secrètement l'année ou le résultat futur ; seuls les changements connus à l'origine sont admissibles.

8. Étapes suivantes et statut de preuve

L'acquisition Banque mondiale et son audit sont achevés. Les scripts de reconstruction POC0, leurs résultats et leur gel n'ont pas été modifiés. Les mois crypto réservés de novembre et décembre 2021 n'ont pas été ouverts. Le résultat sur l'agrégation est analytique et antérieur dans la littérature. Le code progressif et le protocole P1 sont des conceptions, sans entraînement ni comparaison prédictive exécutée.

La prochaine étape documentaire est de transformer P1 en fiche préenregistrable : choisir une première tâche précise, compléter les conventions historiques et la disponibilité, fixer les horizons, les variantes, les budgets de comparaison, les métriques et les règles d'amendement. Une tâche BCE quotidienne est plus proche d'un premier protocole réalisable avec les fichiers actuels ; l'or mensuel apporte un test complémentaire du type d'observation. Le corpus fin GC/ES/actions reste une acquisition future à qualifier par échantillon et conditions d'accès.

Le programme continue à rechercher une grammaire transférable et un modèle GPT capable d'apprendre des dépendances inédites. La nouvelle exigence est de pouvoir attribuer une amélioration à l'information du passé, à sa représentation, à la capacité du modèle ou à la mesure elle-même. Cette attribution donnera un sens scientifique à un futur succès.

Du langage à l'expérience contrôlée

1. Portée de cette édition

TRAME, édition 2.2 du 15 octobre 2026. Consolidation scientifique du candidat P1-D 0.3. Ce texte rassemble les cinq notes de travail du 15 octobre. Il amende les propositions expérimentales des documents 01 à 09 quand elles divergent. Les anciennes versions restent archivées ; leurs résultats effectivement mesurés ne sont pas réécrits.

L'idée directrice demeure un modèle de séquences de type GPT capable d'apprendre des relations entre prix. Le langage peut combiner nombres, géométrie, durée, événements, états de disponibilité et relations entre actifs. La question actuelle est plus précise : comment comparer des écritures sans confondre l'information disponible, leur facilité d'apprentissage et la puissance du modèle ?

Trois avancées structurent la réponse. Des codes contenant exactement la même information n'ont pas nécessairement la même efficacité avec un modèle fini. Un encodage doit être causal par sa construction, pas seulement par le masque du Transformer. Enfin, l'audit réel a révélé une voie de traitement qui n'aurait pas été entraînée, ce qui oblige à corriger le candidat avant son évaluation.

Statut	Ce qui appartient à cette catégorie
Mesuré	Calendriers, précision numérique, support des codes et échappements sur les données BCE existantes.
Déduit	Bijections entre codes, comptes de paramètres, conditions de causalité et borne conditionnelle d'un codec différentiel.
Proposé	Encodeurs hybrides, GPT, témoins, sorties et programme de comparaison.
Non établi	Gain prédictif, découverte de nouveaux motifs, avantage universel d'une langue ou émergence avec la taille.

Le protocole prédictif reste un **candidat documentaire** : il n'est ni préenregistré, ni entièrement gelé, ni implémenté. Le gel réalisé avant l'audit descriptif ne concerne que cet audit. Aucun modèle prédictif ou tokenizer appris n'a été construit ou entraîné.

Cette étape quotidienne est un banc d'essai de concepts. Elle ne remplace pas le futur corpus d'or, d'indices, d'actions et d'autres marchés, ni l'étude de données fines. Les observations réelles déjà disponibles servent à éliminer des ambiguïtés avant d'augmenter les moyens.

2. Même information, apprentissages différents

Notons X le passé numérique, S les informations auxiliaires communes et Y le prix futur. Une écriture discrète K=T(X) peut perdre de l'information. Une autre écriture H=f(K), si f est bijective, ne perd rien par rapport à K. Cette distinction porte sur les données avant l'encodeur appris.

Proposition conditionnelle. Si K et H se déduisent exactement l'un de l'autre, conditionnellement à S, les ensembles de prédicteurs mesurables fondés sur (K,S) et (H,S) sont identiques par composition. Pour une même perte, l'infimum de risque sur une classe non restreinte est donc identique. Un réseau fini n'atteint pas nécessairement cet infimum.

La preuve est constructive : à tout prédicteur g(K,S), associer g(f inverse(H),S), et réciproquement. Si K efface des détails de X, un prédicteur sur X peut toujours reproduire celui sur K ; son risque idéal ne peut donc pas être supérieur, avec les mêmes informations auxiliaires et une classe libre. Une meilleure performance pratique du discret peut venir de la régularisation ou de l'optimisation.

Comparaison proposée	Question effectivement posée
C contre Q	Effet de la quantification avec des encodeurs numériques minimaux comparables.
Q contre H+	Intérêt de corrections hiérarchiques au-delà d'une base numérique, pour les mêmes cellules.
F+ contre H+	Effet du partage entre composants, à cœur GPT identique mais à nombre total de paramètres différent.

La bijection des codes ne garantit pas l'injectivité des vecteurs appris : une table ou une somme de composants peut fusionner des codes. Une conclusion doit donc porter sur un système d'encodage et d'apprentissage, pas sur une information abstraite seule.

xVal, version 2, montre comment intégrer directement une valeur dans un embedding et une tête numérique. Les embeddings numériques de Gorishniy et al. motivent des témoins non linéaires ou périodiques. Ces travaux sur d'autres tâches ne démontrent aucun avantage sur les prix.

L'espace de recherche reste ouvert : arithmétique explicite, coordonnées ordinales, franchissements de seuil, raffinements progressifs et plusieurs écritures d'un même passé. Leurs bénéfices devront être attribués au bon mécanisme, sans compter leurs transformations comme de nouvelles observations indépendantes.

3. Causalité et informations auxiliaires

À l'origine i, le candidat reçoit 256 références positives, de P_(i-255) à P_i. Il calcule une unité s_i sur le passé et recentre l'histoire sur P_i : `x_(j;i)=log(P_j/P_i)/s_i`. Cette entrée est disponible pour prévoir après i.

Elle n'est pas causale à chaque ancienne position j. Pour j inférieur à i, P_i et une partie des observations de s_i appartiennent à son futur. Un masque triangulaire appliqué aux embeddings ne retire pas cette information déjà introduite par le prétraitement.

Conséquence pour P1-A : la perte ne porte que sur des cibles postérieures à l'origine i. On ne transforme pas cette même fenêtre recentrée en exemples next-token à toutes ses positions. Pour P1-B, qui générera un flux de symboles, chaque état et chaque normalisation devront être calculables à partir du préfixe réellement connu ou généré.

Un autre problème, distinct du futur, concerne le contraste entre langages. Si chaque symbole historique reçoit le prix exact précédent, ces ancres répétées réintroduisent presque tout le passé ; avec le dernier prix exact, elles peuvent le restituer entièrement. Le prétendu langage « signe seulement » n'est alors plus la seule source de l'historique.

Le contrat retient une seule ancre P_i et une seule échelle s_i par actif et origine, plus identité, unité, type d'observation et intervalles calendaires passés. Une statistique continue supplémentaire par ancien point modifierait ce contrat. Un indicateur d'échappement dérivé du code n'est pas, lui, une information extérieure au code.

Les cibles sont les prix aux prochaines 1, 5 et 20 publications valides : des horizons d'observation, pas des durées physiques constantes. La date future effectivement observée ne devient pas une entrée. Les absences ne sont pas remplies par des cours inventés.

L'historique BCE a été reçu en 2026. Respecter l'ordre des dates ne certifie pas les versions disponibles lors des premières publications. Le cadre BCE de juin 2026 n'est pas rétroprojeté sur 1999-2020. L'expérience reste rétrospective et conditionnelle à cette version.

Conséquence pour le modèle de langage

La causalité doit être définie au niveau du pipeline entier : acquisition, révision, normalisation, découpage et état de génération. Le Transformer causal est nécessaire pour certaines architectures ; il ne certifie pas à lui seul le respect de cette chaîne.

4. Une cellule, plusieurs écritures exactes

Le candidat utilise l'écart-type de population des 64 derniers incréments logarithmiques, centré par leur moyenne, avec plancher 10^-6. La normalisation est calculée en float64 ; chaque coordonnée est ensuite arrondie une fois en float32. Toutes les variantes partent de ce même x32.

Le code est `k=floor(8*float64(x32))` ; le milieu est `m=(2k+1)/16`. La largeur de cellule vaut 1/8. C reçoit x32 ; Q reçoit m. Quantifier directement x64 alors que C reçoit x32 aurait pu donner au code une distinction que C n'a plus : l'ordre des conversions fait partie de l'expérience.

F écrit l'entier k. H écrit `q=floor(k/8)` et les trois bits de `r=k-8q`, avec r entre 0 et 7. La division avec plancher vaut aussi pour les négatifs. Exemple construit : pour k=-1, q=-1 et r=7 ; une division tronquée vers zéro ne respecte pas cette convention.

Le dictionnaire ordinaire comprend k de -2048 à 2047, soit 4 096 cellules. Le composant grossier q comprend 512 valeurs, de -256 à 255. Hors dictionnaire, une écriture canonique d'échappement conserve l'entier : signe, chiffres décimaux et terminaison, sans zéro initial superflu ni zéro négatif. Sa décodabilité ne garantit pas l'apprentissage du traitement correspondant.

Sous la condition suffisante `-2^23 <= k <= 2^23-1`, m est exactement représentable en float32. Il permet de retrouver k ; Q, F et H contiennent donc les mêmes cellules. Cette condition a été vérifiée sur les fenêtres réelles. Un dépassement futur imposerait un arrêt et un amendement, sans écrêtage ni suppression silencieuse.

La discrétisation donne une erreur maximale 1/16 entre x32 et m. C'est une borne de reconstruction d'une coordonnée, pas de prévision. Elle s'ajoute à l'arrondi préalable et dépend, pour un retour au prix, de l'ancre et de l'échelle.

P1-A fusionne les composants en **un vecteur par observation physique**. Il n'augmente donc pas artificiellement la longueur du contexte Transformer pour H. Tables, opérations locales et tailles de code doivent néanmoins être comptées. Ce n'est pas encore un générateur autorégressif de chiffres ou de bits.

Les mêmes conditions de précision doivent être vérifiées avant toute extension à d'autres actifs. Leur satisfaction sur six séries quotidiennes n'est pas une garantie universelle pour des bougies à la seconde, des prix très faibles ou une autre normalisation.

5. Audit réel des fenêtres et des codes

L'audit descriptif a été figé localement le 15 octobre à 14:38:46 UTC, avant exécution. Il lit la version existante de six séries BCE contre EUR : USD, JPY, GBP, CHF, CAD et AUD, de 1999 à 2020. Aucun téléchargement ni ajustement de modèle n'intervient.

Les fenêtres de 256 prix et les horizons communs produisent les effectifs suivants. Une origine compte ici une date par actif ; les présentations comptent toutes les répétitions dans les contextes.

Période et usage	Origines par actif	Présentations	Échappements
1999-2009, ajustement futur	2 541	3 902 976	0
2010-2014, développement	1 261	1 936 896	195
2015-2020, pseudo-test	1 515	2 327 040	0

Les 8 166 912 présentations proviennent de **33 672 prix sources distincts** dans l'union des contextes. Leur répétition ne constitue pas une augmentation équivalente de l'information historique. Aucun échec de décodage ou d'exactitude du milieu, ni activation du plancher de volatilité n'a été observé. L'ordre d'arrondi modifie 24 cellules, réparties 10/7/7 entre périodes.

Dans l'ajustement partagé entre six actifs, 735 codes plats et 96 codes grossiers sont observés. Au développement, 9 514 présentations ordinaires correspondent à des codes plats absents de l'ajustement ; 8 202 ont un composant grossier absent. Les bits sont tous déjà apparus. Au pseudo-test, ces comptes deviennent 69 et zéro. Les 195 échappements ne sont pas inclus dans ces cellules ordinaires.

Ces résultats renseignent le support des paramètres de tables ; ils ne mesurent ni prévisibilité, ni entropie conditionnelle, ni composition apprise. Ils révèlent cependant un défaut concret du candidat 0.2 : sa branche affine réservée aux seuls échappements n'aurait reçu **aucun gradient de tâche** à l'ajustement. Un module de même forme dans Q ne lui transmet pas automatiquement ses poids.

Le pseudo-test est exploratoire, déjà connu par provenance et désormais examiné pour ses représentations. Il ne sera pas renommé « test final intact ». Le rapport, le protocole d'audit, son script et le snapshot 0.2 sont conservés dans `research/trame_protocol_p1d/audits/preflight_01`.

6. Un extrême de langage et son unité

Les 195 échappements concernent 40 contextes CHF, d'origines comprises entre le 15 juin et le 9 août 2012. Après lecture des agrégats, un diagnostic ciblé a été déclaré puis exécuté. Il est **exploratoire et postérieur** à l'audit initial ; le choix de ce cas n'est pas indépendant des observations.

Le minimum de coordonnée apparaît à l'origine du 1er août 2012, pour le prix historique du 10 août 2011. Les valeurs suivantes viennent du rapport conservé, sans simulation de prix.

Élément du calcul réel	Valeur
Prix historique, CHF par EUR	1,0451
Prix à l'origine, CHF par EUR	1,2013
Logarithme du ratio	-0,1392917291
Écart-type des 64 derniers incréments	0,0003005311
Coordonnée normalisée float64	-463,4853067
Cellule k	-3 708
Écart-type des 255 incréments du contexte	0,0075289986
Rapport des échelles longue/courte	25,0523

Le nombre -463 n'est pas une variation sur une publication de 463 écarts-types. C'est une différence entre niveaux éloignés, divisée par une très petite unité récente. Une vérification scalaire distincte concorde avec le calcul vectorisé dans les tolérances déclarées.

La BNS a annoncé le cours minimum de 1,20 CHF par EUR le 6 septembre 2011, puis confirmé sa politique en février 2012. Ce contexte est compatible avec l'interprétation d'une faible volatilité récente ; l'audit n'identifie pas causalement l'effet de cette politique.

La normalisation définit donc une partie de la difficulté du langage. Si s_i devient petit, un écart de niveau fini peut produire un x très grand. Une représentation combinant échelle courte et longue mérite une expérience séparée. Elle apporterait d'autres statistiques ou une autre résolution ; elle ne serait plus exactement le contraste présent. Aucune date ni unité n'a été modifiée pour faire disparaître ce cas.

7. Le candidat 0.3 : base numérique et corrections

La correction proposée remplace la branche isolée par une base numérique utilisée sur toutes les valeurs. Pour une largeur d, écrire `N(m)=a*m+b`. À l'intérieur de chaque modèle, N est le même module dans et hors du dictionnaire.

Variante active	Vecteur de valeur proposé
Q	N(m), partout.
F+	N(m)+T[k] dans le dictionnaire ; N(m) hors dictionnaire.
H+	N(m)+A[q]+B2[b2]+B1[b1]+B0[b0] dans le dictionnaire ; N(m) hors dictionnaire.

Les tables T, A et B sont initialisées à zéro. Pour chaque répétition, Q, F+ et H+ partent du même cœur GPT et de la même initialisation de N. Ils ont ensuite leurs propres paramètres : pas de transfert de poids entraînés depuis Q ni de partage des poids entre concurrents pendant l'ajustement.

À cette initialisation, leurs vecteurs sont mathématiquement identiques. Les corrections additives peuvent recevoir un gradient même nulles ; aucune seconde porte nulle ne les multiplie. Les lignes jamais visitées doivent rester nulles sous l'optimiseur futur, à vérifier lors d'une implémentation ultérieure.

Une cellule plate inédite reçoit la base seule. Dans H+, un composant grossier inédit peut rester nul tandis que des bits déjà entraînés contribuent. Cette composition peut être utile ou nuisible : couvrir les composants ne prouve pas une bonne extrapolation.

N voit désormais les données ordinaires. Cela corrige l'absence d'exemples pour ses paramètres, sans garantir son extrapolation ni la répartition de l'apprentissage face aux tables. Les paramètres numériques et symboliques peuvent se compenser ; leurs valeurs ne seront pas interprétées directement comme des causes de marché.

F+ et H+ sont hybrides. m provient exactement des mêmes codes : il ne restitue pas l'information continue perdue par quantification, mais donne explicitement une relation numérique au réseau. Q-H+ teste l'intérêt d'une correction hiérarchique au-dessus de cette base, pas la supériorité d'un alphabet purement symbolique.

Les anciens F/H 0.2 restent archivés. Une voie symbolique pure pourrait employer des chiffres partagés dans toutes les valeurs, y compris ordinaires. Il faudrait documenter leur apprentissage, l'ordre de génération et le coût des séquences. Aucun résultat présent ne réfute universellement cette voie.

8. GPT principal et comptes de paramètres

Le gabarit proposé est un Transformer causal pré-normalisé : attention dense avec projections et biais, MLP d vers 4d puis d avec GELU, deux normalisations affines par bloc et une finale, positions sinusoïdales fixes. Il reçoit un vecteur par observation, une identité d'actif et les métadonnées communes. Il reste entièrement sur papier.

Un bloc possède `12*d*d+13*d` paramètres. Avec L blocs, identité, projection de quatre métadonnées, normalisation finale et tête de 21 sorties, le total commun vaut `12*L*d*d+13*L*d+34*d+21`, avant l'encodeur de valeur. C/Q ajoutent 2d ; H+ ajoute 520d ; F+ ajoute 4 098d.

Gabarit proposé	C ou Q	H+	F+
L=4, d=128, 4 têtes	797 717	864 021	1 322 005
L=6, d=256, 8 têtes	4 747 797	4 880 405	5 796 373
L=8, d=512, 8 têtes	25 237 525	25 502 741	27 334 677

Les comptes restent ceux de 0.2 : la base affine existante est utilisée plus souvent, sans ajout de paramètres. Les opérations locales changent néanmoins. Ces nombres ne sont ni une mesure de mémoire réelle, ni un chronométrage, ni une estimation ferme de coût d'entraînement.

Comparer à cœur identique répond à une question d'architecture contrôlée, sans égaliser paramètres totaux ou calcul. Une seconde comparaison pourrait ajuster largeur ou budget sous une contrainte de ressources commune ; elle modifierait alors le cœur. Ajouter des paramètres inutilisés pour afficher des totaux égaux ne serait pas un contrôle valable.

Une base affine peut constituer un témoin trop faible pour conclure à l'intérêt général du symbolique. Des encodeurs numériques non linéaires et périodiques doivent être spécifiés avant une affirmation plus large. Le Number Cookbook, version 2 nourrit la réflexion sur écriture et capacité en arithmétique, sans fournir un résultat de prévision financière.

Cinq initialisations sont proposées. Elles mesureraient une variabilité d'optimisation ; elles ne créeraient pas cinq histoires de marché indépendantes. Budgets, distributions d'initialisation, optimiseur, arrêt et diagnostics de convergence restent à fixer avant le gel prédictif.

9. Sorties, pertes et témoins

Les sorties sont sept quantiles du prix brut : 0,05 ; 0,10 ; 0,25 ; 0,50 ; 0,75 ; 0,90 ; 0,95, pour trois horizons. Une tête de 21 nombres génère des coordonnées ordonnées par incréments softplus ; le retour au prix est `q=P_i*exp(s_i*sqrt(h)*z)`. La médiane n'est pas assimilée à une espérance.

L'objectif proposé moyenne la perte pinball sur actifs, horizons et quantiles, divisée par `P_i*s_i*sqrt(h)`. Le critère primaire reste l'horizon 1. Pertes natives, MAE de médiane, couverture et largeur des intervalles complètent ce score. Sept quantiles ne décrivent ni toute la distribution, ni une loi jointe de trajectoires. La théorie des scores propres ne rend pas cette sortie partielle complète.

Témoin non exécuté	Définition et rôle
B0	Quantiles tous égaux à P_i : persistance, distribution dégénérée.
B1	Logarithme à drift nul : q=P_i exp(s_i sqrt(h) Phi inverse(tau)). Médiane P_i ; moyenne P_i exp(h s_i²/2).
B1m	Retirer h s_i²/2 dans l'exponentielle de B1 : moyenne P_i sous la loi supposée.
B2	Quantiles de 256-h variations historiques transformées en prix terminaux ; interpolation linéaire dans l'espace des prix.
B3	Ridge sur 20 incréments récents standardisés et log(s_i), avec résidus de prévisions chronologiques pour les quantiles.

B3 possède 21 caractéristiques avec l'actif seul, 126 avec six actifs. Sa standardisation utilise seulement l'ajustement. Les résidus de calibration sont prévus sur 2005-2009 ; chaque ajustement ne voit que les cibles antérieures à l'année prévue. Les calendriers donnent par actif 1 255 / 1 239 / 1 179 résidus potentiels aux horizons 1/5/20. Aucun résidu ni coefficient n'a été calculé.

Le développement choisira alpha parmi 0,0001 ; 0,01 ; 1 ; 100, séparément pour B3 propre et croisé, avant gel. Les formules intégrales restent dans la note des témoins. B2 suit NumPy, méthode linear ; interpoler les logarithmes puis exponentier donnerait en général un autre témoin.

Ces témoins sur prix non quantifiés évaluent le dispositif complet, sans avoir exactement l'information de Q/H+. Des blocs de 60 publications, sensibilités 20/120 et rééchantillonnage conjoint des actifs sont proposés pour l'incertitude ; cela ne supprime ni dépendances résiduelles ni effets des essais multiples.

10. Revenir ensuite au prochain token

P1-A étudie l'écriture du passé avec une tête commune. P1-B doit reprendre l'intuition complète : produire les éléments suivants d'une trajectoire. Le découpage est méthodologique ; il ne remplace pas l'ambition du modèle de langage de marché.

Le flux doit préciser son token : variation, palier, composant de bougie, événement ou paquet temporel. Un vocabulaire appris pourrait retenir des motifs, mais devrait être construit seulement sur l'ajustement, en distinguant reconstruction et prévision. Les schémas grossier/fin ont une antériorité dans Kronos : leur simple présence ne constitue pas une invention nouvelle.

Une piste conceptuelle est un codage différentiel à état reconstruit. Pour u_t=log(P_t), calculer `e_t=u_t-u_hat_(t-1)`, quantifier e_t en q_t au pas delta, puis mettre à jour `u_hat_t=u_hat_(t-1)+q_t`. Avec état synchronisé, sans saturation ni erreur de transmission, l'erreur est `u_hat_t-u_t=q_t-e_t`, de valeur absolue au plus delta/2. Elle ne s'accumule pas comme les erreurs de quantification de vrais incréments.

Cette propriété relève du codage prédictif classique, dont Gray, chapitre 10 fournit une référence. Elle ne borne pas l'erreur quand un modèle devine q_t. L'encodeur historique voit u_t ; le prédicteur futur ne le voit pas. Une preuve de codec n'est donc pas une preuve de prévision.

Pour un flux progressif, l'état grossier doit être reproductible sans les détails fins omis. Un résidu grossier calculé depuis un état fin inconnu du décodeur casserait ce contrat. Plusieurs états synchronisés ou une construction fondée sur l'état grossier sont des options à formaliser.

D'autres pistes restent recevables : franchissements de seuil plutôt que secondes régulières, cohérence entre plusieurs écritures, tâches auxiliaires d'addition ou de reconstruction géométrique. Elles peuvent modifier optimisation et résolution, sans créer les nouvelles observations indépendantes nécessaires à une preuve de généralisation.

Avant P1-B, il faudra arrêter la comparaison entre vraisemblance de symboles, trajectoires reconstruites et scores du prix. Un vocabulaire plus fin augmente certaines difficultés de codage ; comparer uniquement les pertes next-token de vocabulaires différents serait insuffisant.

11. Diversité, puissance et décisions scientifiques

H1 compare partage de paramètres entre actifs et modèles séparés, avec le seul passé de l'actif cible. H2 compare contexte croisé et contexte masqué, dans des modèles entraînés séparément selon leurs entrées autorisées. Une permutation arbitraire d'actifs n'est pas automatiquement un témoin nul valide : leurs dépendances et calendriers comptent.

Changer de numéraire produit des relations algébriques, sans créer des marchés indépendants. Un état latent partagé peut être une représentation efficace sans identifier une cause économique unique. Gain prédictif, cohérence entre actifs et interprétation causale sont trois conclusions différentes.

Les six histoires mensuelles de matières premières 1960-2020, dont l'or, ne contiennent pas le chemin intramensuel. Métadonnées et changements de définition font partie du langage. Les sources fines qualifiées dans 09 doivent encore fournir des échantillons contrôlés avant de conclure à une couverture à la seconde pour les crises envisagées.

Le passage à l'échelle devra varier capacité, observations distinctes, diversité, contexte et précision. Répétitions et actifs fortement corrélés doivent être comptés à part. Il faut rechercher courbes d'apprentissage, saturation et changements de classement entre langues, avec budgets de recherche comparables et trace des essais.

Observation future	Conclusion autorisée et suite
Condition d'information ou de causalité violée	Réviser le protocole avant d'attribuer un score au langage.
Apprentissage insuffisant même sur l'ajustement	Examiner optimisation et capacité ; le test ne réfute pas la langue.
Ajustement bon, développement décevant	Examiner surajustement, régimes et représentation dans les conditions testées.
Gain sur corpus déjà exploré	Résultat exploratoire à reproduire après gel sur observations indépendantes.
Gain robuste après réplications prévues	Preuve locale pour le dispositif testé ; aucune universalité automatique.

Le droit de réviser un langage doit s'accompagner de règles de poursuite annoncées. Sinon chaque déception pourrait être attribuée indéfiniment au manque de calcul, rendant l'hypothèse impossible à confronter aux observations. Les seuils chiffrés ne sont pas encore arrêtés : aucun budget ou niveau de puissance statistique n'est inventé sans étude de son adéquation.

12. Panel, traçabilité et prochaine étape

Le neuvième passage du panel est **simulé**, conduit par le principal. Les profils des documents 05 et des notes sont des rôles critiques, pas des experts humains consultés. Les récentes tentatives de relecture par agents auxiliaires ont échoué sur une limite de service ; aucune approbation indépendante n'en est déduite.

Objection du panel simulé	Réponse retenue
« Le vocabulaire écrit l'extrême, donc le cas est traité. »	Vérifier aussi que les paramètres utilisés ont reçu des exemples de la tâche.
« L'hybride résout la prévision. »	Il corrige une confusion ; aucune performance n'est mesurée.
« Même information implique même score. »	Même risque idéal sous bijection, mais pas même apprentissage à capacité et données finies.
« Huit millions de valeurs font un grand corpus. »	Ce sont des présentations répétées de 33 672 prix distincts.
« Réviser après lecture des données invalide tout. »	La révision est exploratoire et archivée ; une confirmation indépendante reste nécessaire.

Le protocole courant est `research/trame_protocol_p1d/protocol_candidate.json`, identifié 0.3. Ses versions 0.1 et 0.2 sont conservées. L'audit descriptif et son diagnostic postérieur ont leurs propres plans, snapshots, empreintes et rapports dans audits/preflight_01. Les cinq notes du 15 octobre conservent dérivations et formules détaillées, avec avertissement sur l'ancienne proposition 0.2.

Les tests de calendrier, d'arithmétique et d'intégrité déjà réalisés ne sont pas des tests de modèle. Cette publication consolide les résultats sans refaire les acquisitions ou mesures. Les anciens dossiers et archives restent conservés. Les mois réservés du premier corpus de reconstruction restent non ouverts.

Prochaine étape de conception : fixer sensibilités numériques, initialisations, budgets d'optimisation, diagnostics de convergence et règles de sélection, puis préciser P1-B avec un état causal autonome. Le contrat d'évaluation indépendante et l'extension multi-marchés devront être résolus avant toute affirmation de fiabilité.

La proposition actuelle est un programme de comparaison contrôlée, appuyé sur des données réelles et déjà amendé par elles. Le langage final reste à découvrir. La preuve recherchée porte sur la prévision de nouveaux prix, avec une chaîne explicite entre information, représentation, apprentissage et évaluation.

TRAME : plan de recherche et premières décisions

1. Objectif et ordre des preuves

15 octobre 2026, édition 2.3. Plan engagé à la demande du porteur. Le programme vise un modèle GPT apprenant un langage des courbes sur plusieurs marchés réels. La première question n'est pas combien de paramètres acheter, mais quelles expériences permettront d'attribuer une amélioration au langage, à l'information, à l'apprentissage ou à leur interaction.

Le travail reste une conception scientifique, accompagnée d'audits documentaires et arithmétiques. La demande de commencer le plan est exécutée dans ce périmètre : aucun modèle construit ou entraîné, aucune dépense engagée. Les étapes de développement apparaissent pour rendre le chemin complet, pas comme des opérations déjà effectuées.

Étape	Livrable et condition de passage
1. Fermer P1-A	Contrastes de représentation, témoins numériques sérieux, initialisations et budgets documentés. Tout gain doit avoir une interprétation précise.
2. Définir P1-B	État causal, token futur, loi normalisée, génération et décodage ; distinguer la vraisemblance d'un code du score sur le prix.
3. Étendre le corpus	Matrice familles × époques × résolutions, petits échantillons réels vérifiés, disponibilité et versions explicites.
4. Geler l'évaluation	Test indépendant identifié, règles de sélection et de poursuite arrêtées, protocole versionné avant les nouveaux scores.
5. Réaliser le POC	Lors de la phase de développement : tests d'information, témoins, petits GPT, calcul mesuré et résultats reproductibles.
6. Étudier l'échelle	Courbes capacité/données/diversité/contexte/précision, transferts entre familles, réplications ; limites du système mesurées.

Les étapes 1 et 2 peuvent avancer en parallèle de la qualification des données. Le gel définitif dépend des trois. Le développement ne doit pas masquer les ambiguïtés de conception ; réciproquement, nous ne chercherons pas à résoudre tout problème théorique imaginable avant une expérience utile.

Le résultat attendu du premier POC sera une réponse locale et interprétable. Une mauvaise prévision par un petit réseau ne condamnera pas la langue. Une bonne prévision sur un corpus déjà exploré ne suffira pas à revendiquer une structure universelle du Marché.

2. Personas : rôles, objections et décisions

Les profils ci-dessous prolongent le panel existant. **Ils sont simulés par l'agent principal.** Les agents auxiliaires restent indisponibles sur une limite de service constatée ; aucune relecture indépendante n'est revendiquée. Les rôles servent à produire des objections différentes, pas à multiplier artificiellement les validations.

Persona et responsabilité	Objection prioritaire	Décision de cette session
Léa, théorie de l'information	Une écriture plus élaborée ne crée pas d'information.	Garder une entrée numérique commune et distinguer précision, représentation et fonction apprise.
Malik, architecture GPT	P1-A ne réalise pas encore le prochain token.	Formaliser dès maintenant un premier générateur conditionnel de vingt codes futurs.
Nadia, statistique expérimentale	Le réglage des concurrents peut décider du classement.	Même grille, mêmes budgets d'exposition et seeds appariées ; sélection sur développement seulement.
Camille, calcul numérique	Le témoin affine est faible et les queues peuvent casser les scores.	Définir des témoins résiduels non linéaire/périodique ; analyser les moments des prix générés.
Inès, données de marché	Une fréquence annoncée ne garantit pas une observation indépendante.	Contrat de données par source et fréquence réellement observée ; pas de secondes interpolées.
Sara, reproductibilité	Modifier le protocole sans conserver l'ancien empêche l'audit.	Archiver le candidat 0.3, créer 0.4 et séparer P1-B de P1-A.
Élodie, lecture et finalité	La théorie peut devenir une suite de reports sans preuve.	Associer à chaque étape un livrable, une limite et une décision vérifiable.

Deux cycles de contradiction effectivement menés

Cycle 10 : témoins et ressources. Proposition initiale : comparer l'hybride au seul numérique affine. Objection de Camille : un avantage pourrait venir d'une non-linéarité disponible seulement d'un côté. Révision : ajouter une petite correction MLP et une correction périodique à C et Q. Nadia demande alors de compter leur réglage et leur calcul : mêmes essais de taux d'apprentissage, comparaisons appariées et paramètres explicités. Ce n'est pas une égalité de FLOPs.

Cycle 11 : futur et valeurs rares. Proposition initiale : prévoir les codes et ajouter une tête spécifique pour les extrêmes. Sara rappelle qu'une tête ne recevant aucun exemple peut rester sans apprentissage. Révision : étudier une distribution numérique définie sur tous les entiers, modifiée par des corrections de probabilité dans le dictionnaire. Camille ajoute une objection : une distribution raisonnable en logarithmes peut avoir une espérance de prix infinie. La note technique donne une condition suffisante pour éviter cette difficulté ; elle ne prétend pas avoir entraîné ce modèle.

3. Ce qui est commencé, et ce qui suit

Étape 1, engagée. Le candidat P1-D passe en 0.4. Deux témoins numériques sont définis par leurs opérations et paramètres. La proposition d'optimisation, la séparation des seeds de réglage et de répétition, le budget initial et son comptage sont explicités. Les hypothèses et chiffres sont des choix de protocole, pas des réglages validés par résultats.

Étape 2, engagée. Un candidat P1-B0 formalise la génération conditionnelle de vingt codes de prix, avec une ancre et une échelle figées à l'origine. La récurrence est causale ; la loi sur les codes est normalisée. Les conditions suffisantes de moments finis en prix sont dérivées. Architecture complète de la tête, constantes de bornage, stabilité numérique et calibration restent à préciser.

Étape 3, à poursuivre ensuite. Constituer une matrice de couverture réelle : matières premières, actions/indices, devises, taux, puis autres familles pertinentes. Conserver deux axes complémentaires : histoire longue et détail récent. Choisir les échantillons par disponibilité documentée, pas par succès observé. Auditer prix de transaction, référence, moyenne ou règlement ; calendriers, changements de définition, instruments disparus et observations manquantes. Les données déjà reçues servent au développement, pas à fabriquer un test intact.

Étape 4, avant toute prétention de confirmation. Distinguer un test de nouvelles dates, de nouveaux instruments et d'une nouvelle famille. Fixer leur priorité, leur accès et les règles de dévoilement. Un historique révisé n'est pas une reconstitution certifiée des premières publications. La taille et le seuil de gain pertinent doivent être justifiés ; le nombre de courbes ne remplace pas l'estimation de leur dépendance.

Étape 5, lors du futur POC. Commencer par les témoins et les tests de causalité. Mesurer temps, mémoire et calcul d'une exécution courte avant le budget complet. Entraîner ensuite les variantes selon le protocole retenu, publier aussi les échecs numériques et les essais non sélectionnés. Comparer les prix et distributions, pas seulement une courbe visuellement plausible.

Étape 6, après qualification du POC. Augmenter séparément les axes d'échelle, puis tester leurs interactions. Vérifier si une langue rattrape les autres avec la capacité, si la diversité aide un actif peu documenté, et si les autres actifs apportent une information contemporaine supplémentaire. Un système scientifiquement fiable exige aussi stabilité, calibration et détection de situations éloignées de l'ajustement.

4. Décisions et livrables attendus

Situation observée à l'avenir	Réponse de recherche
Une fuite d'information ou un canal auxiliaire non déclaré	Corriger avant d'interpréter les performances ; conserver la trace et réviser les résultats concernés.
Le petit GPT n'apprend pas correctement l'ajustement	Diagnostiquer optimisation et capacité ; ne pas conclure contre la langue.
Gain seulement face au numérique affine	Limiter la conclusion à ce témoin ; examiner les contrôles numériques plus expressifs.
Gain qui change avec budget ou initialisation	Étudier l'interaction ; ne pas publier uniquement la configuration favorable.
Gain sur données déjà explorées	Le traiter comme exploratoire ; préparer sa reproduction indépendante.
Absence de gain dans une expérience bien exécutée	Décrire précisément les conditions négatives et choisir une nouvelle hypothèse identifiable.

Livrables produits dans cette session

Le présent plan, la note technique 12, le candidat P1-D 0.4, le candidat théorique P1-B0 0.1 et un rapport arithmétique. Ce dernier vérifie comptes de paramètres, budgets et exemples de récurrence ; il ne lit aucun prix et ne calcule aucun score de prévision. Les nouvelles lectures primaires sont consignées avec leurs limites.

Prochaine tâche précise

Qualifier les bornes et la tête de probabilité P1-B0, puis arrêter un inventaire de tests indépendants multi-marchés. En parallèle, confronter la proposition d'optimisation à une revue technique avant son gel. Les règles de calcul proposées ne sont pas une garantie de convergence ; leur coût réel attend une future mesure.

Nous ne fixons pas une date fictive de modèle fiable. La durée dépendra de l'accès aux données, des ressources mesurées et de ce que révéleront les expériences. En revanche, chaque prochaine session doit fermer une décision ou produire une preuve identifiable, pas simplement reformuler le dossier.

Témoins numériques et génération causale

1. Deux chantiers effectivement ouverts

15 octobre 2026, édition 2.3. Ce texte accompagne le plan 11 et amende le candidat P1-D 0.3 en 0.4. Il ajoute des choix documentaires pour P1-A et une proposition théorique séparée P1-B0. Aucun réseau, tête prédictive ou tokenizer appris n'a été implémenté ou entraîné. Les vérifications exécutées sont arithmétiques, sur des exemples construits et explicitement non marchands.

P1-A demande si une écriture du passé facilite l'apprentissage d'une même sortie en prix. P1-B0 demande comment produire une distribution cohérente de trajectoires en prédisant des codes successifs. Les deux expériences n'ont ni la même tête ni le même objectif ; leurs scores internes ne seront pas comparés comme s'ils étaient interchangeables.

Témoin numérique non linéaire

Pour v=x32 dans C ou v=m dans Q, conserver la base N(v)=av+b et ajouter `W2*GELU(W1*v+b1)`. W1 et b1 ont chacun r=16 composantes ; W2 est de taille d par r, sans biais supplémentaire. W2 commence à zéro ; W1 est initialisé indépendamment avec une distribution normale de variance 1 et b1 à zéro.

Les entrées commencent donc comme celles de la base affine. L'addition ne bloque pas structurellement le gradient de W2, mais son arrivée dépend aussi du démarrage de la tête commune décrit plus loin. W1 attend que W2 devienne non nul. Ce délai n'est pas une impossibilité d'apprentissage. Le nombre de paramètres de valeur est `2*d+16*(d+2)=18*d+32`.

Témoin numérique périodique

Ajouter à la même base `W*phi(v)`, avec phi contenant sinus et cosinus de `2*pi*v/T` pour les périodes T=0,5 ; 1 ; 2 ; 4 ; 8 ; 16 ; 32 ; 64. W comporte 16d paramètres et commence à zéro ; les fréquences sont fixes. Le total de valeur est 18d. Ce choix conserve la coordonnée v comme entrée numérique, sans prétendre que l'encodeur appris sera toujours injectif.

Les mêmes deux contrôles sont proposés pour C et Q : huit variantes au total avec C, Q, F+ et H+. Les périodes et r sont des choix initiaux, non optimisés sur des prix. Gorishniy et al., NeurIPS 2022 motivent l'examen de traitements numériques plus expressifs ; les formules ci-dessus sont nos contrôles proposés, pas une reproduction de leurs expériences.

2. Paramètres et comparaison équitable

Le cœur de P1-D reste inchangé. Les contrôles numériques n'ajoutent ni nouveau passé, ni actif, ni statistique. Ils changent seulement la fonction de représentation d'un scalaire déjà présent. Leur coût local et leur capacité changent réellement.

Gabarit	C/Q affine	C/Q périodique	C/Q MLP
L=4, d=128	797 717	799 765	799 797
L=6, d=256	4 747 797	4 751 893	4 751 925
L=8, d=512	25 237 525	25 245 717	25 245 749

Les comptes F+/H+ de 0.3 restent inchangés. Les chiffres ont été vérifiés par calcul entier sans instancier un modèle. Le contraste primaire historique Q-H+ reste déclaré ; son interprétation est limitée à Q affine. Les contrôles étendus évaluent si l'avantage éventuel dépasse ce témoin. Choisir après coup le meilleur concurrent et lui attribuer un test statistique non corrigé serait un autre problème.

Proposition d'initialisation commune

Dans une même seed et une même taille, les variantes partagent le tirage initial du cœur, des métadonnées, de la base numérique et de la tête. Les paramètres entraînés restent ensuite séparés. Matrices ordinaires : normale centrée de variance inverse du nombre d'entrées ; biais nuls ; gains LayerNorm égaux à 1 et biais nuls. LayerNorm epsilon proposé : 10^-5. Embeddings d'actif : normale centrée d'écart-type 0,02. Base numérique : a de même écart-type 0,02 et b nul. Corrections symboliques, W2 du témoin MLP et W du témoin périodique : nulles.

Pour éviter un écart initial artificiel entre les quantiles, les poids de la tête sont nuls. Les biais donnent z=-1,645 ; -1,282 ; -0,674 ; 0 ; 0,674 ; 1,282 ; 1,645, pour chaque horizon. Le premier biais est libre ; les six autres sont les inverses softplus des écarts positifs. Ce sont des constantes arrondies de conception, pas des estimations du marché. Au premier pas, la tête peut apprendre ; le gradient vers le cœur devient possible quand ses poids quittent zéro.

Cette initialisation doit faire l'objet de contrôles futurs de gradients et de sorties finies. Elle n'est pas déclarée optimale. Une init différente serait une sensibilité explicite, avec le même droit de réglage pour chaque concurrent.

3. Budget initial proposé et coût des essais

Le candidat 0.4 propose AdamW avec beta1=0,9, beta2=0,95, epsilon=10^-8, décroissance 0,01 et clipping de norme globale des gradients à 1. La décroissance vise les matrices ordinaires, bases et embeddings, sauf biais et gains de normalisation. Une ligne symbolique jamais visitée et initialisée à zéro doit rester nulle. L'article AdamW justifie la distinction avec une pénalité L2 dans Adam ; il ne justifie pas ces valeurs pour nos prix.

Dropout proposé nul pour le premier contraste. Les trois taux maximaux sont 10^-4, 3*10^-4 et 10^-3. Le taux augmente linéairement pendant 5 % des mises à jour, puis suit un cosinus jusqu'à 10 % de son maximum. La référence numérique initiale est float32 pour le réseau, avec normalisation des données en float64 déjà spécifiée ; précision mixte différée à une étude de coût.

Chaque époque présente une permutation des 2 541 dates d'ajustement, avec les six actifs. Un lot contient au plus 32 dates, soit 192 exemples ; le dernier lot de 13 dates est conservé. Cela donne 80 mises à jour par époque. Une campagne de 30 époques représente 2 400 mises à jour et 457 380 exemples actif-origine par exécution. Les fenêtres comportent 256 vecteurs ; leur répétition ne crée pas de données indépendantes.

Pour chacune des huit variantes et chaque taille étudiée : trois taux, deux seeds de réglage, puis cinq nouvelles seeds pour le taux retenu. Les seeds proposées sont 1103/2207 pour régler, et 3109/4211/5323/6427/7537 pour répéter. La sélection utilise la moyenne du score de développement h1 au checkpoint final, avec poids égal aux actifs. Une égalité stricte retient le plus petit taux. Les checkpoints intermédiaires servent aux diagnostics ; ils ne sont pas sélectionnés secrètement.

Cela représente **88 exécutions**, dont 48 de réglage et 40 de répétition, pour la seule petite taille : 211 200 mises à jour, 40 249 440 présentations actif-origine et 10 303 856 640 vecteurs de contexte. Ce budget est un plan, pas un lancement. Temps, mémoire et calcul devront être mesurés avant exécution complète.

Deux autres tailles porteraient le même plan à 264 exécutions. Un second budget de 90 époques, retuné de la même manière pour les trois tailles, porterait le total à 528. Cette enveloppe illustre pourquoi on commence par qualifier le petit dispositif. Égalité d'exposition n'est pas égalité de calcul ni preuve de convergence.

4. Diagnostics avant interprétation

Une sortie non finie, un masque incorrect ou une différence d'entrée non déclarée interrompt l'exécution concernée et est enregistrée. Si un taux échoue pour une seed de réglage, il est classé non admissible pour cette variante ; s'ils échouent tous, aucun gagnant n'est produit. Une panne matérielle peut être relancée avec les mêmes paramètres et état ; un changement scientifique reçoit une nouvelle version.

Les cinq répétitions finales sont conservées, y compris une défaillance numérique. On ne les remplace pas par de meilleures seeds. Les courbes d'objectif d'ajustement, de développement, les normes et les incidents servent à distinguer instabilité, sous-apprentissage et généralisation. Trente époques ne prouvent pas la convergence. La campagne longue et les grandes tailles restent des hypothèses d'étude, pas une promesse d'amélioration.

Les intervalles par blocs et scores de 0.3 restent exploratoires. Aucun p-value confirmatoire n'est annoncé sur le pseudo-test déjà inspecté. Les répétitions d'entraînement quantifient l'optimisation, sans devenir de nouvelles trajectoires économiques. Le gel final doit encore fixer la décision de poursuite et le test indépendant.

Ce qui n'est pas fermé par 0.4

L'adéquation de ce budget, le coût réel, les sensibilités d'initialisation, la tête croisée H2, une fusion hiérarchique non additive et la puissance de l'évaluation restent ouverts. Le candidat fournit une première proposition exécutable ultérieurement, pas un plan universellement optimal. Les listes historiques de points ouverts sont amendées sans effacer leurs versions.

Pourquoi commencer P1-B maintenant

Le porteur veut apprendre la suite des éléments de marché. Attendre la fin de tous les essais P1-A avant d'écrire ce générateur risquerait de déplacer indéfiniment le cœur du projet. Les sections suivantes définissent une première solution causale sur papier, afin de pouvoir contester sa sémantique et ses difficultés dès cette phase.

P1-B0 garde le passé disponible à l'origine i, une ancre P_i et l'échelle s_i. Il produit une suite de vingt codes après cette origine. Il ne demande pas de prédire les anciennes positions du contexte avec une normalisation calculée plus tard. Son caractère GPT vient de la factorisation autorégressive conditionnelle ; sa tête n'est pas obligatoirement un softmax de mots linguistiques.

5. P1-B0 : état causal et prochain code

Poser `u0=log(P_i)` et `delta=s_i/8`, connus à l'origine. Delta est figé pour les vingt pas. L'état reconstruit initial est u_hat0=u0. À l'apprentissage futur, le code cible pour le pas h serait :

```
k_h=floor((log(P_(i+h))-u_hat_(h-1))/delta+1/2)
```

```
u_hat_h=u_hat_(h-1)+delta*k_h
```

La convention arrondit les demi-entiers vers plus l'infini. Le code zéro conserve exactement l'état. C'est une quantification différente de la grille à milieux du passé P1-A ; elle n'est pas introduite silencieusement dans ses contrastes.

Le calcul de k_h utilise le prix cible seulement pour créer son étiquette, et les seuls codes antérieurs pour l'état précédent. En apprentissage teacher forcing, le prédicteur du pas h reçoit les codes vrais jusqu'à h-1, jamais k_h. En génération, il reçoit les codes qu'il a lui-même produits. Recalculer un état futur depuis un vrai prix encore inconnu serait une fuite.

La loi proposée est `p(k_1,...,k_20|H_i)=produit_h p(k_h|H_i,k_<h)`, H_i étant le passé et les métadonnées connus à i. Après génération, `P_hat_h=exp(u_hat_h)`. Les niveaux 1, 5 et 20 proviennent de la même trajectoire. Une nouvelle origine après observation d'un vrai prix peut recalculer son ancre ; cela constitue une nouvelle prévision.

Avec l'encodeur historique défini ci-dessus, l'erreur de reconstruction en log-prix est au plus delta/2 à chaque pas, sans accumulation, puisque le résidu se mesure depuis l'état reconstruit. **Ce n'est pas une borne de prévision.** Le modèle peut produire une suite de codes très différente de celle du futur réel.

Les vérifications de cette session utilisent des logarithmes rationnels construits pour contrôler la récurrence, notamment les demi-entiers et les signes. Aucun exemple n'est présenté comme une cotation. Le codec théorique repose sur une arithmétique exacte ; sa stabilité float et la gestion des exponentielles devront être étudiées avant développement.

6. Une loi sur tous les entiers, sans tête abandonnée

Une catégorie ESC seule ne définit pas la valeur du futur extrême. Une tête de queue séparée peut aussi ne recevoir aucun exemple. Nous proposons d'étudier une base numérique sur tout entier, utilisée dans la probabilité de chaque cible, puis des corrections dans le dictionnaire.

Pour un état conditionnel donné, soient mu réel et sigma strictement positif. Définir une normale arrondie par :

`q(k)=Phi((k+1/2-mu)/sigma)-Phi((k-1/2-mu)/sigma)`

Les cellules partitionnent la droite : q(k)>0 et la somme sur tous les entiers vaut 1 en arithmétique exacte. Pour I={-2048,...,2047}, poser `w(k)=exp(a_k)` dans I et w(k)=1 ailleurs. La loi corrigée est `p(k)=q(k)*w(k)/Z`.

Le normalisateur ne nécessite pas une somme infinie : `Z=q(hors I)+somme_(k dans I) q(k)*exp(a_k)`. Les deux queues de q se calculent avec la fonction de répartition aux frontières -2048,5 et 2047,5. Cette écriture positive est préférable conceptuellement à une soustraction de nombres proches. L'évaluation numérique stable de log q, des queues et de log Z reste à spécifier.

À a_k=0, p=q. Les paramètres mu et sigma interviennent aussi dans les observations ordinaires : il n'y a plus une tête réservée uniquement à des exemples ESC absents. Cela ne garantit pas que leur apprentissage soit bon ; les corrections peuvent absorber une partie de la structure. L'identifiabilité et les interactions devront être examinées.

Un échantillonnage exact sur papier choisit parmi les cellules centrales et les deux queues agrégées, puis utilise une normale tronquée et l'arrondi dans la queue sélectionnée. Le support demeure non borné : on n'écrête pas les prix extrêmes au bord d'un dictionnaire. Les paramètres des corrections pourront être plats ou hiérarchiques, mais la tête complète n'est pas encore arrêtée.

Le principe de masses obtenues par différence de CDF a notamment une antériorité dans PixelCNN++, section 2.1. Cet article traite des pixels bornés avec des mélanges logistiques ; il ne valide pas notre loi non bornée, le transfert au prix ou les corrections proposées. Aucune nouveauté absolue n'est revendiquée pour cette famille de constructions.

7. Les queues du logarithme ne suffisent pas

Une loi discrète dont la masse de queue positive est asymptotiquement proportionnelle à exp(-k/b) peut sembler régulière. Mais le prix contient `exp(delta*k)`. Son espérance diverge lorsque `delta*b` est supérieur ou égal à 1. Une loi valide sur les codes peut donc produire une espérance de prix infinie. Le passage au prix brut est une partie de la conception probabiliste, pas une simple opération d'affichage.

La normale arrondie proposée évite cette difficulté pour un état conditionnel fixé : ses moments exponentiels sont finis. Cela ne suffit pas automatiquement pour une trajectoire autorégressive, car ses paramètres futurs dépendent des codes générés. Nous donnons une condition suffisante, encore à paramétrer expérimentalement.

Supposons pour tous les états autorisés `|mu|<=M`, `0<sigma<=S` et `|a_k|<=A`, avec M,S,A finis, et delta figé. Une normale Y vérifie K=arrondi(Y)<=Y+1/2. Donc :

```
E_q[exp(delta*K)] <= exp(delta/2+delta*M+delta^2*S^2/2)
```

Comme exp(-A)<=Z<=exp(A), le rapport p/q est au plus exp(2A). Il existe ainsi une borne uniforme C sur `E_p[exp(delta*K)|passé]`, égale au produit des deux bornes. Par espérance conditionnelle itérée : `E[P_hat_h|H_i] <= P_i*C^h`, pour chaque h fini.

Cette démonstration borne les paramètres des distributions, **pas les codes ni les prix générés**. Des transformations tanh et sigmoïdes pourraient imposer ces contraintes ; M,S,A, le plancher de sigma et leur adéquation restent ouverts. La borne peut être très large : existence d'un moment ne signifie ni calibration, ni faible erreur.

Le critère d'apprentissage P1-B0 porterait sur la vraisemblance des codes. On ne l'appellera pas densité des prix continus sans définir la mesure et le traitement à l'intérieur des cellules. Les quantiles, couvertures et scores de trajectoire devront être rapportés en prix, avec l'erreur de quantification et l'incertitude Monte-Carlo.

Décisions issues du panel

Retenir cette loi comme candidat théorique, pas comme architecture gagnante. Conserver les pistes de génération grossier/fin et d'autres familles de distributions. Étudier ensuite les bornes, les gradients, le calcul stable et la comparaison avec un témoin sans corrections. Les résultats de marché restent entièrement à produire.

TRAME : une sortie générative définie et des cibles réelles auditées

Édition 2.4 - 16 octobre 2026. Complément au plan 11 et à la proposition 12. P1-D reste en révision 0.4 ; le candidat génératif séparé P1-B0 passe de 0.1 à 0.2. Ce document précise la conception et présente un audit de reconstruction. Aucun GPT, aucune tête prédictive et aucun entraînement ne sont implémentés. Les anciennes éditions restent archivées.

1. Ce qui change, en langage courant

Nous avons maintenant une définition plus concrète de ce que le GPT pourrait produire : un nombre entier décrivant le déplacement depuis le dernier prix reconstruit, puis un autre entier, et ainsi de suite. Le modèle aurait accès au passé connu et à ses propres codes précédents. Il produirait des probabilités sur les prochaines possibilités, pas une unique courbe présentée comme certaine.

Trois sorties sont proposées : une loi numérique simple, une correction par case du dictionnaire, et une correction qui partage des composantes entre cases. Les trois lisent exactement le même passé dans cette première comparaison. L'objectif est de savoir ce qu'apporte la structure du langage de sortie avant de modifier simultanément toutes les entrées.

Le codage a été vérifié sur six séries réelles de devises, dans leur seule partition d'ajustement 1999-2009. Les 304 920 présentations de cibles proviennent de 15 360 cotations distinctes ; leurs fenêtres se recouvrent. La reconstruction respecte sa borne numérique dans tous les cas testés. Cela démontre une cohérence du codage sur cet échantillon, aucune capacité de prévision.

Deux réserves modifient la conception. Seuls 156 codes centraux apparaissent parmi 4 096 possibles. Et une distribution peut autoriser mathématiquement tous les extrêmes tout en leur donnant une probabilité presque nulle par construction. La prochaine étape doit donc qualifier la distribution et son évaluation, plutôt que supposer que le mot « génératif » résout ces difficultés.

2. Un invariant simplifie le langage

À une origine i, on connaît le prix P_i et l'échelle s_i : écart-type population des 64 derniers incréments logarithmiques, avec plancher 10^-6. On fixe delta=s_i/8 pour les vingt publications futures. On définit u_h=log(P_(i+h)), u_0=log(P_i), et R(x)=floor(x+1/2), avec demi-entiers vers +inf.

La proposition 0.1 utilisait la récurrence suivante, en notant uhat le prix logarithmique reconstruit :

```
k_h = R((u_h - uhat_(h-1))/delta)
```

```
uhat_h = uhat_(h-1) + delta*k_h.
```

Or, si n_(h-1) est entier et uhat_(h-1)=u_0+delta*n_(h-1), l'identité R(x-n)=R(x)-n donne :

```
n_h = R((u_h-u_0)/delta) ; k_h = n_h-n_(h-1)
```

```
uhat_h = u_0+delta*n_h ; n_0=0.
```

C'est exactement le même codec en arithmétique réelle. Il est donc possible de conserver un état entier cumulé et d'éviter de faire dépendre la définition canonique de l'accumulation des arrondis flottants. Cette formulation 0.2 a été consignée avant le nouvel audit. La récurrence flottante antérieure a été comparée, sans correction silencieuse des écarts éventuels.

La borne reste |uhat_h-u_h| <= delta/2 pour les vrais codes, sans accumulation. Elle ne borne pas l'erreur d'une suite de codes prédits. Les 3 609 transitions rationnelles construites vérifient l'identité et la borne, y compris pour des niveaux négatifs ; elles ne constituent pas des données de marché.

Un code delta n'apporte donc pas plus d'information qu'un niveau quantifié cumulé, lorsque l'ancre et le pas sont connus. Le choix peut néanmoins changer la difficulté statistique de la prédiction : modéliser un petit déplacement et modéliser un niveau cumulé ne sont pas les mêmes biais d'architecture.

3. Attention aux motifs créés par le codec

Écrivons e_h=uhat_h-u_h. L'incrément reconstruit satisfait exactement :

`delta*k_h = (u_h-u_(h-1)) + e_h-e_(h-1).`

Le signal codé contient donc des différences d'erreurs de quantification. Sous une approximation supplémentaire d'erreurs indépendantes, centrées et uniformes sur [-delta/2,delta/2], le bruit ajouté a une variance delta²/6 et une covariance à un retard de -delta²/12. Cette approximation n'a pas été testée sur le corpus et n'est pas une propriété universelle des erreurs de quantification ; elle illustre un mécanisme possible de dépendance artificielle.

Un GPT peut apprendre des régularités de codage sans améliorer la prévision des prix. Un gain de compression des codes devra être confronté aux scores en prix natifs et aux témoins numériques. L'état initial exact e_0=0 rend également le premier pas particulier. Ni une entropie de codes plus faible ni une autocorrélation des codes ne suffiraient à conclure à un motif économique découvert.

4. Architecture proposée : un GPT, trois sorties

Le cœur reprend le Transformer causal documenté dans P1-D : L blocs, largeur d, attention multi-têtes, MLP de largeur 4d, normalisations avant blocs et positions sinusoïdales fixes. Le passé contient 256 observations Q, chacune issue du même quantificateur et de la même projection affine. Le contexte est causal à l'origine de prévision ; aucune perte next-token n'est appliquée à ses anciennes positions recentrées sur cette origine.

En teacher forcing, la séquence possède 276 positions : 256 observations historiques, un BOS, puis 19 états futurs déjà codés. BOS prédit k_1 ; l'état n_h/8 prédit k_(h+1), pour h de 1 à 19. Le masque interdit de regarder les codes ultérieurs. En génération, les états proviennent uniquement des codes tirés par le modèle. La vingtième cible n'est jamais un input nécessaire à sa propre prédiction.

Une projection numérique N(v)=a*v+b est commune aux types de positions dans chaque modèle. Le passé utilise les milieux Q, le BOS utilise zéro, les positions futures utilisent n_h/8. Ce changement de convention est explicite : Q emploie des cellules par floor pour le passé, les cibles futures un arrondi au plus proche. Toutes les sorties comparées partagent ces conventions.

Les métadonnées sont quatre scalaires projetés par une transformation affine : log(P_i), log(s_i), log1p du délai calendaire, indicateur de sortie du dictionnaire. Les délais futurs inconnus sont remplacés par une sentinelle zéro, identifiée par le type FUTURE. Pour ces positions, l'indicateur est calculé depuis n_h, pas depuis un prix futur inconnu. Trois embeddings de type HISTORY/BOS/FUTURE s'ajoutent aux six embeddings de devise. Il n'y a aucune date future réalisée introduite comme information.

Sortie	Valeurs affines produites à chaque pas	Rôle
BASE	2	Moyenne et écart-type de la normale arrondie
FLAT	4 098	BASE et une correction par code central
HIER	520	BASE, 512 composantes grossières et trois paires binaires

Pour k central, écrire q=floor(k/8), puis décomposer le reste de 0 à 7 en trois bits. HIER forme g_k=g_q+g_bit2+g_bit1+g_bit0. FLAT apprend g_k directement. HIER impose une classe de fonctions plus restreinte ; l'égalité de données conditionnantes ne signifie pas égalité d'expressivité. Les composantes

additives ont aussi des redondances de paramétrage : déplacer une constante d'une composante vers une autre peut laisser leur somme inchangée.

La sortie utilise a_k=A*tanh(g_k/A), un choix résiduel dont la dérivée en zéro vaut un. Les sorties BASE, FLAT et HIER constituent un nouveau contraste sur la génération ; ce ne sont pas les encodeurs d'entrée Q, F+ et H+ déjà décrits dans P1-D.

5. Probabilités normalisées et bornes proposées

Sur tous les entiers, la base est la normale arrondie :

`q(k)=Phi((k+1/2-mu)/sigma)-Phi((k-1/2-mu)/sigma).`

Sur I=[-2048,2047], w(k)=exp(a_k) ; ailleurs w(k)=1. La loi finale vaut p(k)=q(k)w(k)/Z, avec Z=q(hors I)+somme_I q(k)exp(a_k). Les deux queues commencent aux limites continues -2048.5 et 2047.5. BASE utilise simplement q, avec Z=1.

La masse par différence de CDF a des antécédents dans les modèles génératifs. PixelCNN++ l'utilise pour des pixels et des mélanges logistiques ; cela ne valide ni une base gaussienne ni les hypothèses financières proposées ici. Source primaire, section 2.1.

La révision 0.2 propose M=256, S=64, sigma_min=0.25 et A=4. On pose `mu=M*tanh(g_mu/M)`, et `sigma=sigma_min+(S-sigma_min)*sigmoid(g_sigma)`. Une sensibilité S=256 est inscrite avant l'audit. Ces valeurs sont des choix de conception non ajustés : une unité k représente s_i/8, donc les bornes centrales correspondent à 32 échelles s_i pour la moyenne et huit pour l'écart-type. Elles ne plafonnent pas le support des codes.

À l'initialisation proposée, les matrices de sortie sont nulles ; mu=0, sigma=8, a_k=0. Le biais de g_sigma est log((8-.25)/(64-8)). La sensibilité S=256 doit adapter ce biais pour conserver sigma initial égal à huit. L'initialisation identique en distribution permet de comparer le départ ; elle ne prouve pas que l'optimisation soit équitable ou convergente. Les gradients du cœur sont retardés au premier pas par les matrices de sortie nulles, comme signalé pour P1-D.

Sous des bornes uniformes M,S,A à tous les états générés, la preuve de 12 reste valable, conditionnellement à l'origine et à son delta fixe : `E[P_hat_h | H_i] <= P_i*C^h`, avec `C=exp(2A+delta/2+delta*M+delta²*S²/2)`. Cette borne peut être extrêmement large. Finitude mathématique des moments et précision d'une estimation Monte-Carlo sont deux sujets différents.

Une limite substantielle : support infini ne signifie pas extrêmes bien représentés

À l'extérieur du dictionnaire, w=1 et Z>=exp(-A). Donc p(hors I)<=exp(A)*q(hors I). On peut borner chaque queue gaussienne uniformément sur |mu|<=M et sigma<=S, puis additionner ces deux bornes conservatrices.

Configuration proposée	Borne supérieure de p(hors I), par état
M=256, S=64, A=4	9.0844 × 10^-171
M=256, S=256, A=4	1.3977 × 10^-10

Ce sont des conséquences des hypothèses, pas des probabilités mesurées sur les marchés. La loi admet tous les entiers mais impose des queues très faibles au-delà du dictionnaire. Même la sensibilité plus large ne constitue pas une garantie de calibration extrême. Le statut de cette tête reste **candidat de comparaison**, et non solution universelle aux changements de régime. Des mélanges gaussiens à paramètres bornés ou une autre loi à moments exponentiels contrôlés restent des pistes distinctes à spécifier ; elles ne sont pas réputées supérieures sans test.

6. Un symbole absent n'est pas une ligne de sortie sans gradient

Pour une correction indépendante a_j centrale et la perte -log p(k), la dérivée vaut p(j)-1(k=j), à base q fixée. Un code jamais observé comme cible positive peut donc recevoir un gradient par le normalisateur. En calcul machine, une masse sous-fluée ou une saturation peut néanmoins annuler ce signal numérique.

Cela diffère des tables d'entrée : une ligne jamais consultée peut rester sans gradient de tâche. La règle P1-D qui garde nulles les lignes d'entrée jamais visitées ne doit pas être transférée à la tête de sortie. HIER redistribue les gradients par ses composantes partagées.

Un gradient ne remplace pas une observation. Pour un symbole jamais réalisé, il s'agit surtout d'ajuster la masse concurrente des cibles vues. Cela ne démontre ni estimation fiable de sa probabilité ni généralisation à une crise absente. La base mu/sigma participe à toutes les masses et peut apprendre sur les cibles ordinaires ; cela ne résout pas les compensations possibles avec les corrections centrales.

7. Taille et coût : compter deux choses différentes

Le commun, hors tête de sortie, compte $12Ld^2+13Ld+18d$ paramètres. Les 18d rassemblent projection numérique 2d, devises 6d, projection des métadonnées 5d, normalisation finale 2d et types 3d. Une tête à r sorties ajoute $r(d+1)$. Les comptes ont été recoupés par un inventaire séparé des modules, sans instancier de réseau.

L, d	BASE	HIER	FLAT
4, 128	795 650	862 472	1 324 034
6, 256	4 743 682	4 876 808	5 796 354
8, 512	25 229 314	25 495 048	27 330 562

HIER utilise moins de poids de sortie. Cependant sa somme de normalisation comporte encore 4 096 masses centrales par pas, soit 81 920 contributions pour les vingt positions cibles d'une origine. La dépendance de q(k) à k et la correction bornée empêchent de remplacer directement cette somme par 518 termes indépendants. BASE n'a pas cette somme centrale.

Pour une attention dense sur n=276 positions, les principales multiplications du cœur valent approximativement $L*(24nd^2+4n^2d)$ opérations flottantes en forward, en comptant multiplication et addition séparément. Cela donne environ 0.590, 3.073 et 15.140 milliards d'opérations pour les trois tailles. Ces estimations excluent rétropropagation, normalisations, softmax et fonctions spéciales.

À petite taille, les matrices de sortie ajoutent respectivement 10 240, 2 662 400 et 20 981 760 opérations pour BASE, HIER et FLAT. Le coût des CDF, de leurs dérivées et des réductions vient en plus ; aucun temps GPU, débit, mémoire ou budget monétaire n'a été mesuré. Les 88 exécutions proposées pour P1-D ne doivent pas être attribuées automatiquement à P1-B0.

8. Audit réel : déclaration et résultats

Le protocole, le candidat 0.2 et le script ont été scellés localement le 16 octobre à 02:59:37 UTC, avant de calculer les nouveaux codes cibles. Ce gel d'intégrité n'est pas une préinscription externe, et le corpus avait déjà été exploré pour d'autres représentations. La source reste le fichier BCE de SHA-256 b8a684b6331d3cf0310a1838efdce806495906ead99d672671642c3bf24130de, reçu en 2026, sans certification des versions historiques initiales.

Le filtre 1999-2009 est appliqué avant conversion des prix en nombres. Les 16 950 lignes hors période sont ignorées pour les valeurs ; le calcul de l'empreinte lit seulement leurs octets. Aucun nouveau prix de

développement ou pseudo-test n'a été analysé dans cette opération. Les 16 896 prix numériques admis représentent 2 816 dates par devise.

Avec 256 observations historiques et vingt publications futures entièrement contenues dans la partition, on retrouve 2 541 origines par devise, du 27 décembre 1999 au 2 décembre 2009. Les cibles correspondent à 2 560 dates distinctes par devise. Leur réutilisation sur vingt horizons explique les 304 920 présentations ; ce ne sont pas 304 920 observations indépendantes.

Devise par EUR	Code minimal	Code maximal	Codes distincts	Maximum absolu de n
USD	-38	44	81	152
JPY	-59	56	102	227
GBP	-35	67	91	158
CHF	-82	58	122	217
CAD	-32	47	78	190
AUD	-80	101	131	247

L'union comprend 156 codes, de -82 à 101, sans sortie de [-2048,2047]. La valeur absolue a pour quantiles 50 %, 90 %, 99 % et 99.9 % les valeurs 5, 14, 25 et 45. Il y a 18 155 codes nuls, soit 5.954 %. Ces fréquences sont celles de présentations recouvrantes, conditionnées par l'origine et son échelle.

Zéro divergence de codes a été trouvé entre la définition canonique et la récurrence flottante. Zéro dépassement de borne avec la tolérance déclarée, et aucune activation du plancher d'échelle. L'erreur maximale observée est 0.499992732*delta. La tolérance prévue est un diagnostic d'ingénierie fondé sur l'epsilon float64, pas une preuve générale d'erreur flottante. Ces succès ne couvrent pas tous les niveaux, toutes les devises ni les futurs états générés.

Le plus grand code absolu est +101 pour AUD/EUR, cible du 16 août 2007, depuis une origine du 24 juillet, à l'horizon 17. Son échelle s_i vaut environ 0.00325958. Ce code représente un incrément par rapport au dernier état reconstruit, avec échelle fixée à l'origine ; ce n'est pas le rendement cumulé de dix-sept jours. Le rapport conserve les prix et les états nécessaires à l'interprétation. Aucune causalité événementielle n'en est inférée.

Le support des cibles n'est pas celui des contextes P1-D : l'ancien cas de grand déplacement historique divisé par une petite volatilité récente concernait des niveaux passés. On ne peut ni transférer ses nombres aux nouveaux incréments cibles ni conclure que les extrêmes ont disparu du problème scientifique. Réduire le dictionnaire d'après cette seule partition compromettrait une comparaison multi-marchés non encore réalisée.

9. Stabilité : une spécification, pas encore une qualification complète

Soustraire deux CDF proches de un est dangereux. Sur l'intervalle normal standard [10,11], le calcul direct en float64 avec erf donne zéro dans l'illustration exécutée ; une différence de fonctions de survie calculées par erfc donne environ 7.61966*10^-24, de logarithme -53.23131. Ce sont des arguments construits pour l'analyse numérique, pas des données de marché.

La documentation SciPy explique l'intérêt d'un calcul direct de log-CDF et montre des pertes de précision dans l'approche naïve. Documentation officielle log_ndtr.

Pour a=(k-.5-mu)/sigma et b=(k+.5-mu)/sigma, la spécification proposée utilise logPhi(b)+log1mexp(logPhi(a)-logPhi(b)) si b<=0, et la symétrie des fonctions de survie si a>=0. Quand

l'intervalle traverse zéro, une somme d'erf peut éviter la soustraction de valeurs voisines de un. Pour d<=0, log1mexp(d) se calcule avec log1p(-exp(d)) loin de zéro, et log(-expm1(d)) près de zéro.

La normalisation utilise ensuite une réduction logsumexp des masses centrales corrigées et des deux queues. Documentation officielle logsumexp. Ces primitives et leur composition doivent encore être vérifiées dans le futur moteur différentiable.

SciPy et mpmath n'étaient pas installés dans le runtime utilisé. Aucune comparaison haute précision ni vérification de gradients n'a donc été effectuée. Quatre illustrations ont employé la bibliothèque standard math ; elles ne remplacent pas un audit des fonctions spéciales. erfc sous-flue aussi pour des arguments suffisamment grands. Des limites de cellules distinctes en arithmétique réelle peuvent se confondre en machine ; l'exponentielle du log-prix peut déborder. Un échec doit être signalé, pas transformé en écrêtage invisible du support.

10. Quel succès pourrait réellement être revendiqué ?

La perte proposée est la moyenne des vingt -log p(k_h | passé,codes précédents). Elle évalue une loi de trajectoire quantifiée fixée. Elle ne constitue pas une densité de prix continus. Comparer directement cette NLL entre pas delta différents favoriserait ou pénaliserait aussi la résolution du langage ; il faut une mesure commune.

Pour rester fidèle à l'objectif de prix brut, la future évaluation devra aussi porter sur les prix natifs aux horizons 1, 5 et 20 : pinball, quantiles, couverture et largeur. Les prix reconstruits forment une loi sur une grille ; aucune distribution intra-cellule n'est ajoutée implicitement. Une éventuelle interpolation ou désquantification serait une nouvelle hypothèse à déclarer.

La génération libre doit être évaluée en plus de la vraisemblance sous vrais préfixes. Le nombre de trajectoires Monte-Carlo et sa précision ne sont pas fixés ; les erreurs de simulation doivent être suffisamment faibles pour distinguer les modèles. La condition de moments ne remplace pas ce contrôle. Il n'y a encore aucun score de prévision ou vainqueur.

11. Cycle 12 du panel simulé

Persona fictif	Objection	Décision prise
Léa, information	Le résidu semble annoncé comme une information nouvelle	Dériver l'équivalence à la grille de niveaux ; distinguer représentation et information
Malik, GPT	Des cibles pourraient entrer dans leur propre contexte	Écrire les 276 positions, les vingt sorties et le décalage causal
Nadia, statistiques	Le codec peut créer des dépendances et la NLL changer avec la résolution	Ajouter le mécanisme de bruit différencié et l'évaluation en prix natifs
Camille, calcul numérique	Support infini, queues négligeables et CDF instables sont confondus	Dériver la borne de queue ; garder le statut de candidat non qualifié
Inès, données	Les cibles recouvrantes gonflent artificiellement la taille du corpus	Rapporter présentations et 15 360 cotations distinctes séparément
Sara, reproductibilité	Les choix risquent de suivre les résultats	Sceller candidat, métriques et script avant l'audit ; préserver 0.1
Élodie, lecture du projet	« Audit réussi » pourrait faire croire à une prédiction réussie	Résumé initial et résultats explicitement limités à la reconstruction

Ces personas sont des perspectives simulées par l'agent principal, pas des personnes consultées ni une validation indépendante. Les auxiliaires connus étaient indisponibles pour limite de service ; aucun avis supplémentaire d'un agent n'est inventé.

12. Livrables et travail restant

Les fichiers de cette étape se trouvent dans research/trame_research_plan/20261016 : p1b0_candidate.json, audit_protocol.json, freeze.json, audit_targets.py, target_audit_report.json, check_design.py et design_report.json. Les sources et choix sont qualifiés dans source_audit.json. Les fichiers 20261015 et leurs rapports restent inchangés.

Le prochain bloc doit fermer le contrat de scores en prix et la précision de simulation, puis qualifier numériquement les fonctions de probabilité et leurs gradients lors de la future phase technique. Le choix des bornes doit être challengé sur une matrice de corpus et de régimes déclarée, sans utiliser les tests finaux pour le régler. Les témoins à calcul comparable, le protocole d'optimisation de P1-B0 et une évaluation indépendante restent ouverts.

La grammaire partagée entre actifs et le Marché latent commun restent les hypothèses générales. Cette étape vérifie une brique univariée partagée ; elle n'a pas testé l'information croisée entre actifs, l'or, un indice actions, les observations à la seconde ni un effet d'échelle. Aucun résultat local n'est extrapolé à ces questions.